

Resumen y Aplicación del Modelo de Mortalidad de Lee-Carter (LC)

Jaime H

14 de octubre de 2025

Resumen

Este documento resume la formulación matemática del Modelo de Lee-Carter, sus métodos de estimación (Descomposición en Valores Singulares y Máxima Verosimilitud) y su aplicación utilizando diferentes medidas de mortalidad ($\ln(m_{x,t})$ y $\text{Logit}(q_{x,t})$).

1. Introducción

Las tablas dinámicas de mortalidad son una herramienta demográfica y actuarial avanzada que se utiliza para modelar y proyectar la mortalidad futura de una población, a diferencia de las tablas de mortalidad tradicionales (estáticas o de período) que solo describen la mortalidad en un momento específico del pasado o presente. La principal característica que las hace dinámicas, es que consideran el tiempo cronológico como un parámetro adicional, además de la edad:

- Doble dependencia: Las probabilidades de muerte no solo dependen de la edad (x , el tiempo biométrico), sino también del año calendario (t , el tiempo cronológico) en el que se alcanza esa edad.
- Proyección de la longevidad: Permiten reflejar la tendencia a la disminución del riesgo de mortalidad a lo largo del tiempo, es decir, el hecho de que las personas que nacen hoy probablemente vivirán más tiempo que lo que sugiere la mortalidad actual, debido a avances médicos y mejoras en el estilo de vida (el llamado efecto cohorte).
- Predicción futura: Las tablas dinámicas proyectan las tasas de mortalidad al futuro, a menudo utilizando modelos estocásticos como el Modelo de Lee-Carter, que es muy popular en este campo.

1.1. Información Necesaria (Datos Históricos)

Para estimar tablas dinámicas de mortalidad se requiere esencialmente información histórica detallada de las muertes y la población expuesta al riesgo clasificadas por las dos dimensiones clave: edad y año calendario. Esta información es la base para calcular las tasas centrales de mortalidad ($m_{x,t}$) y aplicar posteriormente un modelo estocástico de proyección, como el Modelo de Lee-Carter. Los datos brutos deben recopilarse para un período extenso de años y deben estar desagregados de la siguiente manera:

- Número de Defunciones ($D_{x,t}$). Es el número de fallecimientos observados. Debe estar clasificado por edad exacta (x) y por año calendario o período de observación (t).
- Población Expuesta al Riesgo ($E_{x,t}$ o $L_{x,t}$). Es la población promedio que estuvo en riesgo de morir a la edad x durante el año t . En demografía, a menudo se usa la población a mitad de año (30 de junio) como una aproximación.

En resumen, se necesita una matriz de tasas de mortalidad con suficientes datos históricos para distinguir claramente la influencia de la edad y el tiempo sobre la mortalidad.

2. Planteamiento Teórico del Modelo de Lee-Carter (LC)

El modelo Lee-Carter (Lee & Carter, 1992) es una propuesta “lógica” y empíricamente justificada, no una ley que salga de “primeros principios biológicos”. El modelo se basa en la Descomposición en Valores Singulares (DVS), para determinar una descomposición parsimoniosa edad-tiempo de las tasas de mortalidad ($m_{x,t}$). Usa el $\ln m_{x,t}$ para linealizar la relación multiplicativa de la mortalidad y garantizar tasas positivas. Puede derivarse de manera matemática como:

- La mejor aproximación de rango 1 (en el sentido de mínimos cuadrados) a la superficie de log-mortalidad una vez restado el nivel por edad, y/o
- El MLE (máxima verosimilitud) de un modelo Poisson log-bilineal bajo un constraint de rango 1 (más tarde formalizado por Brouhns et al., 2002).

2.1. Descomposición en Valores Singulares (DVS)

Es una técnica que descompone cualquier matriz $\mathbf{A}$ en el producto de tres matrices: dos matrices ortogonales $\mathbf{U}$ y $\mathbf{V}$ y una matriz diagonal $\mathbf{\Sigma}$ que contiene los valores singulares de $\mathbf{A}$ en orden decreciente (un valor singular de una matriz rectangular o cuadrada, es una raíz cuadrada positiva de un valor propio de la matriz simétrica $\mathbf{A}^T \mathbf{A}$ o $\mathbf{A} \mathbf{A}^T$). La fórmula de la descomposición es $\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$, donde:

- $\mathbf{A}$: La matriz original, que puede ser rectangular o cuadrada.
- $\mathbf{U}$: Una matriz ortogonal (sus columnas son vectores ortonormales) cuyos valores son los vectores singulares izquierdos de $\mathbf{A}$. Estos son los autovectores de $\mathbf{A} \mathbf{A}^T$.
- $\mathbf{\Sigma}$: Una matriz diagonal que contiene los valores singulares de $\mathbf{A}$ en su diagonal, ordenados de mayor a menor. Estos valores son las raíces cuadradas de los autovalores de $\mathbf{A}^T \mathbf{A}$ o $\mathbf{A} \mathbf{A}^T$.
- $\mathbf{V}^T$: La transpuesta de una matriz ortogonal $\mathbf{V}$. Las columnas de $\mathbf{V}$ son los vectores singulares derechos de $\mathbf{A}$, que son los autovectores de $\mathbf{A}^T \mathbf{A}$.

La SVD descompone una transformación lineal compleja en operaciones más simples: $\mathbf{V}^T$ rota o refleja el espacio, $\mathbf{\Sigma}$ escala el espacio en direcciones específicas (los valores de la diagonal), y $\mathbf{U}$ rota o refleja el resultado final. En total, la matriz $\mathbf{A}$ realiza un escalado y una rotación o reflexión del espacio.

Sus principales usos están en la reducción de dimensionalidad y compresión de datos. Se puede aproximar la matriz original utilizando solo los valores singulares más grandes, eliminando el ruido”. La Descomposición en Valores Singulares (DVS) está directamente relacionada con el Método de Componentes Principales (MCP), siendo el MCP una aplicación específica de la DVS. La DVS de la matriz de datos centrada produce los componentes principales, que son los vectores singulares izquierdos de esa matriz. Ambas técnicas son métodos de reducción de dimensionalidad que buscan las direcciones de máxima varianza en los datos.

2.2. Derivación por SVD (mínimos cuadrados, rango 1)

Se centra la información para obtener la matriz de desviaciones solo con la variación temporal: $\mathbf{A}_{x,t} = \ln(m_{x,t}) - \alpha_x$, donde α_x es el promedio simple de $\ln(m_{x,t})$ a lo largo del tiempo. La descomposición se obtiene encontrando vectores β_x y κ_t que solucionen

$$\min_{\beta, \kappa} \|\mathbf{A} - \beta \cdot \kappa^T\|_F^2$$

donde $\|\cdot\|_F$ es la norma de Frobenius (suma de cuadrados de residuos). **La norma de Frobenius** es una medida de la magnitud de una matriz, calculada como la raíz cuadrada de la suma de los cuadrados de todos sus elementos. Es equivalente a aplicar la norma euclidiana a la matriz aplanada en un vector.

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}$$

La DVS se aplica a $\mathbf{A}_{x,t}$ para encontrar la mejor aproximación de **rango uno** que explica la mayor parte de la varianza. Por el teorema de Eckart-Young-Mirsk, la mejor aproximación de rango 1 de $\mathbf{A}$ en norma de Frobenius es

$$\mathbf{A}_{x,t} \approx \lambda_1 \mathbf{u}_1(x) \mathbf{v}_1(t)$$

donde λ_1 es el mayor valor singular de $\mathbf{A}$, y $\mathbf{u}_1$ y $\mathbf{v}_1$ sus primeros vectores singulares (izquierda / derecha). Por tanto, una solución natural es

- $\tilde{\beta}_x \propto \mathbf{u}_1(x)$ (vector de edad)
- $\tilde{\kappa}_t \propto \lambda_1 \mathbf{v}_1(t)$ (índice de tiempo)

Como la factorización $\beta \cdot \kappa^T$ no es única, entonces LC fija las restricciones:

$$\sum_x \beta_x = 1 \quad \text{y} \quad \sum_t \kappa_t = 0.$$

Para obtenerlas, se reescalan

$$\hat{\beta}_x = \frac{\tilde{\beta}_x}{\sum_x \tilde{\beta}_x} \quad \text{y} \quad \hat{\kappa}_t = \tilde{\kappa}_t - \bar{\kappa}$$

Reconstruyendo

$$\ln(\hat{m}_{x,t}) = \hat{\alpha}_x + \hat{\beta}_x \hat{\kappa}_t \quad \longleftrightarrow \quad \ln(m_{x,t}) = \alpha_x + \beta_x \kappa_t + \epsilon_{x,t} \quad (1)$$

Es decir, LC es la mejor descomposición edad-tiempo de rango 1 (tras quitar el promedio por edad) en el sentido de mínimos cuadrados.

2.2.1. Resumen del Modelo

El modelo de Lee-Carter es una formulación estocástica bilineal que busca descomponer la variación de la mortalidad en componentes de edad y tiempo. Se aplica al logaritmo natural de la tasa central de mortalidad ($\mathbf{m}_{x,t}$):

$$\ln(m_{x,t}) = \alpha_x + \beta_x \kappa_t + \epsilon_{x,t}$$

$\mathbf{m}_{x,t}$: Tasa central de mortalidad para la edad x en el año t .

α_x : Componente o patrón de edad. Representa el **perfil promedio** de la mortalidad por edad a lo largo del tiempo. Se estima usando el promedio de las tasas de mortalidad a lo largo de todos los años para cada edad x : ($\alpha_x = \frac{1}{T} \sum_{t=1}^T \ln(m_{x,t})$).

κ_t : Componente o tendencia temporal. Es el **índice de mortalidad**, que capta la tendencia general de la mortalidad a lo largo del tiempo. Muestra el nivel general de la mortalidad en el año t y su evolución histórica. Es una serie de tiempo que se proyecta estocásticamente. Se estima a partir de la variabilidad de las tasas a lo largo de los años. Este factor se proyecta a futuro mediante modelos de series de tiempo (como ARIMA) y es lo que hace que la tabla sea "dinámica".

β_x : Componente de interacción edad-tiempo, o sensibilidad a la tendencia. Mide la **sensibilidad** de la edad x a los cambios en el índice κ_t . Se estima para indicar cuánto afecta el cambio de la tendencia κ_t a cada edad x , esto es, mide la velocidad con la que la mortalidad de una edad x reacciona al cambio general del índice de mortalidad κ_t .

$\epsilon_{x,t}$: Término de error, asumido $\epsilon_{x,t} \sim N(0, \sigma^2)$ o modelado por distribuciones de conteo.

Los parámetros β_x y κ_t no son directamente observables a partir de los datos brutos de defunciones y población. Son parámetros latentes (ocultos) que deben ser estimados a partir de la matriz de tasas de mortalidad históricas $\ln(m_{x,t})$. Para la estimación se utiliza un método estadístico, a menudo la Descomposición en Valores Singulares (DVS) o la Máxima Verosimilitud (Poisson), minimizando el error del modelo bajo las restricciones impuestas.

Restricciones de Unicidad: Debido a que existen infinitas combinaciones de β_x y κ_t que podrían producir la misma tasa de mortalidad $\ln m_{x,t}$, se requiere imponer restricciones de unicidad para que el modelo tenga una solución única y bien definida.

$$\sum_x \beta_x = 1 \quad \text{y} \quad \sum_t \kappa_t = 0$$

2.2.2. Método de Estimación

La estimación de los parámetros β_x y κ_t en el modelo de Lee-Carter se realiza mediante un proceso estadístico que descompone la matriz histórica de tasas de mortalidad. El modelo se puede estimar de diferentes formas, dependiendo de los datos disponibles y el rigor estadístico deseado. El método más tradicional y el propuesto originalmente por los autores utiliza la Descomposición en Valores Singulares (DVS), aunque también se emplean los Modelos Lineales Generalizados (MLG) con distribución de Poisson.

El objetivo es descomponer el logaritmo de las tasas centrales de mortalidad $\ln m_{x,t}$ en sus componentes de edad, tiempo e interacción, bajo las restricciones de unicidad. Es simple y no requiere datos brutos de muertes o exposición, solo requiere la matriz $\mathbf{m}_{x,t}$ o $\mathbf{q}_{x,t}$. NO requiere $\mathbf{D}_{x,t}$ ni $\mathbf{E}_{x,t}$, ya que opera directamente sobre la matriz de logaritmos de las tasas ($\ln(m_{x,t})$) o probabilidades ($\text{Logit}(q_{x,t})$) ya calculadas. Los pasos para la estimación son:

- Paso 1: Cálculo del Patrón de Mortalidad por Edad (α_x). Se calcula el perfil promedio de la mortalidad por edad a lo largo de todo el período de estudio:

$$\hat{\alpha}_x = \frac{1}{T} \sum_{t=1}^T \ln(m_{x,t})$$

- Paso 2: Creación de la Matriz de Desviaciones. Se resta el patrón de edad $\hat{\alpha}_x$ de los logaritmos de las tasas observadas para obtener una matriz $\mathbf{A}$ que contiene solo las desviaciones, y representa los cambios en la mortalidad a lo largo del tiempo que son específicos para cada edad:

$$\mathbf{A}_{x,t} = \ln(m_{x,t}) - \alpha_x \quad (\text{o } \text{Logit}(q_{x,t}) - \alpha_x)$$

- Paso 3. Aplicación de la Descomposición en Valores Singulares (DVS). La DVS (o Singular Value Decomposition) es una técnica de álgebra lineal que descompone la matriz $\mathbf{A}$ en tres matrices:

$$\mathbf{A} \approx s_1 \mathbf{u}_1 \mathbf{v}_1^T$$

$\mathbf{u}_1$ es el primer vector singular izquierdo (dependiente de la edad)

$\mathbf{v}_1$ es el primer vector singular derecho (dependiente del tiempo)

s_1 es el valor singular principal.

- Paso 4. El modelo de Lee-Carter solo utiliza el primer componente (el que explica la mayor parte de la varianza). Los parámetros se estiman de la siguiente forma:

$$\hat{\beta}_x = \mathbf{u}_1 \quad \text{y} \quad \hat{\kappa}_t = s_1 \mathbf{v}_1$$

- Paso 5. Aplicación de las Restricciones de Unicidad. Dado que β_x y κ_t son estimados sin escala, se ajustan para cumplir con las restricciones necesarias para garantizar una solución única.
- Paso 6. Para hacer proyecciones, se modela κ_t mediante un ARIMA y se proyecta para los años requeridos, en la estimación en (1).

2.3. Derivación por Verosimilitud Poisson log-bilineal

Un método alternativo y más riguroso, que a menudo se prefiere en la práctica, es la estimación mediante un Modelo Lineal Generalizado (MLG), asumiendo que el número de muertes sigue una distribución de Poisson, $D_{x,t} \sim \text{Poisson}(\lambda_{x,t})$. El valor esperado de muertes $\lambda_{x,t}$ se relaciona con la tasa de mortalidad $m_{x,t}$ y la población expuesta $E_{x,t}$ mediante: $\lambda_{x,t} = E_{x,t} m_{x,t}$, así $D_{x,t} \sim \text{Poisson}(E_{x,t} m_{x,t})$, y $\ln E[D_{x,t}] = \ln \lambda_{x,t} = \ln[E_{x,t}] + \ln m_{x,t}$.

El modelo de Lee-Carter introduce en la $E[D_{x,t}]$, la relación latente para el logaritmo de la tasa de mortalidad $\ln(m_{x,t}) = \alpha_x + \beta_x \kappa_t$. Sustituyendo esto en la ecuación de $\lambda_{x,t}$ y tomando el logaritmo, obtenemos la ecuación clave del MLG-Poisson, del logaritmo del valor esperado de muertes como:

$$\ln E[D_{x,t}] = \underbrace{\ln E_{x,t}}_{\text{Offset}} + \alpha_x + \beta_x \kappa_t$$

Los datos requeridos son datos brutos de $\mathbf{D}_{x,t}$ (Muertes) y $\mathbf{E}_{x,t}$ (Población Expuesta), con $\mathbf{D}_{x,t}$ como respuesta y $\ln(\mathbf{E}_{x,t})$ como *offset*. Los parámetros α_x , β_x y κ_t se estiman simultáneamente utilizando algoritmos de optimización para maximizar la siguiente función de log-verosimilitud de Poisson, bajo las restricciones de unicidad

$$l(\alpha, \beta, \kappa) \propto \sum_{x,t} [D_{x,t}(\alpha_x + \beta_x \kappa_t) - E_{x,t} \cdot \exp(\alpha_x + \beta_x \kappa_t)]$$

Si todas las exposiciones fueran iguales y se ignoran pesos, la solución se alinea con la SVD. Con pesos distintos (exposiciones heterogéneas) el MLE difiere y es estadísticamente más eficiente. En la práctica, hoy se estima LC con MLE Poisson y, pedagógicamente, se muestra la conexión con SVD.

2.4. Uso de $q_{x,t}$ para la Estimación del Modelo

La estimación de los parámetros puede llevarse a cabo utilizando la probabilidad de muerte $q_{x,t}$ de varias tablas de mortalidad. Aunque el modelo original de Lee-Carter utiliza la tasa central de mortalidad $m_{x,t}$ como variable de entrada, existen adaptaciones y transformaciones para utilizar $q_{x,t}$. Una alternativa directa al modelo de $\ln m_{x,t}$ es modelar el logaritmo de la probabilidad de muerte:

$$\ln(q_{x,t}) = \alpha_x + \beta_x \kappa_t + \epsilon_{x,t}$$

Este enfoque es estructuralmente idéntico al modelo original y se puede estimar de las mismas dos maneras principales:

- Descomposición en Valores Singulares (DVS): Aplicando DVS a la matriz de desviaciones $\ln q_{x,t} - \hat{\alpha}_x$.
- Modelos Lineales Generalizados (MLG): Esto requiere asumir una distribución que se ajuste a $q_{x,t}$. Dado que $q_{x,t}$ es una probabilidad y está acotada entre 0 y 1, el enfoque de Poisson ya no es el más apropiado.

2.4.1. El Enfoque Logit (Mejor Práctica)

El método más recomendado y robusto cuando se trabaja con $q_{x,t}$ es utilizar la transformación logit (o log-odds) de la probabilidad de muerte. Esta transformación convierte el rango de la probabilidad (0,1) en el rango de los números reales, lo que es ideal para un modelo lineal como el de Lee-Carter. El modelo transformado queda así:

$$\text{logit}(q_{x,t}) = \ln \frac{q_{x,t}}{1 - q_{x,t}} = \alpha_x + \beta_x \kappa_t + \epsilon_{x,t}$$

El modelo original basado en $\ln m_{x,t}$ (o $\ln q_{x,t}$ directamente) puede, en teoría, llevar a la predicción de $\ln q_{x,t}$ mayores que 1, lo cual es imposible para una probabilidad de muerte. El logit garantiza que la probabilidad de muerte proyectada siempre esté entre 0 y 1.

Este modelo puede ajustarse mediante un MLG asumiendo una distribución Binomial para $\mathbf{D}_{x,t}$, el número de "éxitos" (muertes) en una serie de ensayos (población $\mathbf{E}_{x,t}$), luego $\mathbf{D}_{x,t} \sim \text{Binomial}(\mathbf{E}_{x,t}, \mathbf{q}_{x,t})$. Una vez obtenida la estimación de $\text{logit}(q_{x,t})$, se obtiene $q_{x,t}$ mediante:

$$\hat{q}_{x,t} = \frac{1}{1 + \exp(-\hat{\text{logit}}(q_{x,t}))}.$$

Sin $\mathbf{D}_{x,t}$ y $\mathbf{E}_{x,t}$, solo se tendría la probabilidad $\mathbf{q}_{x,t}$ como un simple ratio y se debe recurrir a la Descomposición en Valores Singulares (DVS) sobre $\ln \mathbf{q}_{x,t}$ o $\text{logit}(\mathbf{q}_{x,t})$, un método que no aprovecha la estructura de varianzas de los datos de conteo. Por lo tanto, para el método Logit más robusto, los datos brutos son esenciales.

2.4.2. Restricciones

- Imposibilidad de Deducir $\mathbf{D}_{x,t}$ y $\mathbf{E}_{x,t}$ solo con $\mathbf{q}_{x,t}$. Si solo se tiene $\mathbf{q}_{x,t}$, es **imposible** obtener los valores exactos de $\mathbf{D}_{x,t}$ y $\mathbf{E}_{x,t}$ de forma única y precisa. Esto se debe a que $\mathbf{q}_{x,t}$ es un ratio ($\approx \mathbf{D}_{x,t}/\mathbf{E}_{x,t}$), y un ratio puede ser el resultado de infinitas combinaciones de numerador y denominador.
- Uso de Componentes de la Tabla de Mortalidad ($\mathbf{l}_{x,t}$ y $\mathbf{d}_{x,t}$). Se podría sustituir $\mathbf{E}_{x,t}$ por $\mathbf{l}_{x,t}$ (supervivientes teóricos) y $\mathbf{D}_{x,t}$ por $\mathbf{d}_{x,t}$ (muertes teóricas) para forzar un ajuste MLG. Sin embargo, esto **no mejora el rigor estadístico** del MLG, ya que $\mathbf{l}_{x,t}$ y $\mathbf{d}_{x,t}$ no representan la escala ni la varianza de la población real. En este caso, es mejor usar la **DVS** sobre $\text{Logit}(q_{x,t})$.
- Limitación Crítica del DVS con Pocos Años ($T = 2$). **No se puede** aplicar el DVS de forma efectiva ni confiable con solo $T = 2$ años de datos.

Inviabilidad Práctica: Con $T = 2$, la matriz de desviaciones solo tiene dos columnas, lo que significa que el rango máximo es 2. La DVS simplemente descompondría la diferencia entre el Año 1 y el Año 2, sin poder aislar una **tendencia robusta** de largo plazo.

Falta de Confianza para Pronóstico: Una estimación de κ_t basada en dos puntos es insuficiente para modelar una serie de tiempo estocástica (como $\text{ARIMA}(0, 1, 0)$) y carece de validez para generar pronósticos con intervalos de confianza significativos.