

UNIVERSIDAD NACIONAL DE COLOMBIA

MODELOS DE SUPERVIVENCIA UNIVARIADOS

Jaime Abel Huertas

2025

1. CONCEPTOS BÁSICOS

1.1. LA FUNCIÓN DE SUPERVIVENCIA

Si una unidad funciona en el tiempo $t = 0$, la probabilidad que la unidad funcione más allá de un tiempo t se nota por $S(t)$, y es llamada “función de supervivencia”. La variable aleatoria considerada se llama “tiempo de fallo” y se nota por T . La probabilidad que una unidad funcione más allá del tiempo t es:

$$S(t) = Pr(T > t). \quad (1.1)$$

Es claro que $T \geq 0$, que $S(0) = 1$ y que $S(t)$ es no creciente. Además se asumirá que $\lim_{t \rightarrow \infty} S(t) = 0$. La función de distribución de T o $F(t)$ define la probabilidad de fallar antes del tiempo t .

$$F(t) = Pr(T \leq t) = 1 - S(t). \quad (1.2)$$

La función de densidad de probabilidad se denota por f y formalmente se define con el siguiente límite:

$$f(t) = \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} Pr(t \leq T < t + \Delta t). \quad (1.3)$$

Intuitivamente $f(t)\Delta t$ aproxima la probabilidad que un evento ϵ ocurra entre t y $t + \Delta t$. Si T es continua, $f(t)$ es la velocidad de cambio de la función de distribución, es decir:

$$f(t) = \frac{d}{dt} F(t) = -\frac{d}{dt} S(t) \quad (1.4)$$

$$S(t) = \int_t^{\infty} f(u) du. \quad (1.5)$$

Si T es discreta con valores $t_1 < t_2 < \dots$, entonces:

$$S(t) = Pr(T > t) = \sum_{t_j > t} Pr(T = t_j). \quad (1.6)$$

Aunque tanto la función de supervivencia como la de distribución pueden adoptar formas diferentes y aunque la velocidad de decrecimiento (o crecimiento) varía de acuerdo con el riesgo de ocurrencia del suceso ϵ , se hace difícil, por simple inspección ocular, distinguir el patrón de fallo ϵ . Por este motivo se dice que la curva de supervivencia (o la de distribución) es poco informativa y se recurre a otras funciones para comparar distintos patrones de fallo.

1.2. LA FUNCIÓN DE RIESGO

Una forma de estudiar T es mediante la función de riesgo definida como la probabilidad de morir en un pequeño intervalo, dado que la persona está viva al inicio del mismo. Este análisis se puede hacer a través de la función de riesgo, que formalmente se define como:

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} Pr(t \leq T < t + \Delta t \mid T \geq t). \quad (1.7)$$

Con $h(t)\Delta t$ se puede aproximar la probabilidad que una entidad de edad t le ocurra el evento en el próximo instante, es decir, fallar entre un tiempo infinitesimal, por esto también se le menciona como probabilidad instantánea de fallo. Cuando T es continua, la densidad condicional de fallar en t dado que se sobrevive a t , es:

$$h(t) = \frac{f(t)}{S(t)} = \frac{-\frac{d}{dt}S(t)}{S(t)} = \frac{-d}{dt} \ln(S(t)) \quad (1.8)$$

$$S(t) = \exp \left(- \int_0^t h(y) dy \right). \quad (1.9)$$

La función de riesgo no es una densidad, y como propiedades básicas se pueden citar que $h(t)$ es no negativa, $\int_0^s h(u) du < \infty$ para algún $s > 0$ y $\int_0^\infty h(u) du = \infty$. Se conoce también como la tasa de fallo condicional en fiabilidad industrial, o la fuerza de mortalidad en demografía, o la función de

intensidad en procesos estocásticos, o la tasa de fallo en epidemiología, así como por la inversa de la proporción de Mill en economía. En el caso de la fuerza de mortalidad la función de riesgo se nota como $\mu(x)$ o μ_x , donde x es la edad del individuo. La función de riesgo expresa cómo el riesgo cambia con el tiempo y contiene la misma información que la supervivencia pero en términos de su velocidad (o tasa) de cambio. Cuando la supervivencia decae rápidamente el riesgo es alto, mientras que si la curva de supervivencia es plana el riesgo es cero. Si T es discreta con valores $t_1 < t_2 < \dots$, se define la función de riesgo por:

$$h(t_j) = Pr(T = t_j \mid T \geq t_j) = \frac{Pr(t_j)}{S(t_{j-1})} = \frac{S(t_{j-1}) - S(t_j)}{S(t_{j-1})} = 1 - \frac{S(t_j)}{S(t_{j-1})}. \quad (1.10)$$

Si T es discreta, $h(t)$ corresponde a la proporción de unidades que fallan entre t y $t + 1$, entre todas aquellas entidades supervivientes en el momento t . Por otra parte también se tiene que si T es discreta:

$$\begin{aligned} S(t_j) &= Pr(T > t_j) \\ &= Pr(T > t_j, \wedge, T > t_{j-1}) \\ &= Pr(T > t_j \mid T > t_{j-1})Pr(T > t_{j-1}) \\ &= (1 - Pr(T \leq t_j \mid T > t_{j-1}))S(t_{j-1}) \\ &= (1 - h(t_j))S(t_{j-1}). \end{aligned}$$

Similarmente se obtiene que, $S(t_{j-1}) = (1 - h(t_{j-1}))S(t_{j-2})$, y por tanto recursivamente:

$$S(t_j) = \prod_{i=1}^j (1 - h(t_i)) \quad (1.11)$$

y en general,

$$S(t) = \prod_{j:t_j \leq t} \frac{S(t_j)}{S(t_{j-1})} = \prod_{j:t_j \leq t} (1 - h(t_j)). \quad (1.12)$$

La función de riesgo es muy útil para describir la mortalidad de una población pues permite la comparación de individuos de edades diferentes. Por ejemplo, se puede comparar la probabilidad de que dos individuos de 30 y 60 años mueran al cabo de un año.

La función de riesgo, o las tasas de riesgo, juegan un rol fundamental en análisis de supervivencia. Entre muchos otros patrones o formas que la función de riesgo puede tomar se citan:

- (a) Función de riesgo constante: Corresponde a poblaciones que no presentan envejecimiento. La función de densidad que corresponde a T es la exponencial.
- (b) Función de riesgo creciente: corresponde a poblaciones que envejecen con la edad o por desgaste. Se dice que la distribución tiene una tasa de fallo creciente.
- (c) Función de riesgo decreciente: Corresponde a poblaciones con una verosimilitud de fallo muy temprana. Los individuos se fortalecen con el paso del tiempo, por ejemplo pacientes después de un trasplante. Los modelos con esta función de riesgo se encuentran en el inicio de vida de cualquier ser.
- (d) Función de riesgo con forma de joroba: Corresponde a aquellas poblaciones cuya función de riesgo crece al inicio y al cabo de un tiempo empieza a decrecer. Apropia para modelar la supervivencia después de la cirugía, ya que al inicio hay un gran riesgo de muerte debido a las infecciones y posibles hemorragias, y éste decrece a medida que el paciente se recupera. También es un modelo para tasas de divorcio.
- (e) Función de riesgo con forma de bañera: Corresponde a aquellas poblaciones cuya función de riesgo es decreciente al inicio, constante durante un largo periodo de tiempo y creciente al final de la vida. En humanos las tasas de muerte en recién nacidos son altas, luego se estabilizan y después se sigue un proceso creciente debido al envejecimiento de la población.

La Función de Riesgo Acumulada

Aunque es muy útil técnicamente para el proceso de estimación de las demás funciones de supervivencia, carece de interpretación intuitiva. Su definición y propiedades básicas son:

$$H(t) = \int_0^t h(u) \, du. \quad (1.13)$$

- (a) $H(t)$ Es una función no negativa y monótona creciente.
- (b) $H(t) = -\ln[S(t)]$, o equivalentemente, $S(t) = \exp(-H(t))$.

(c) Si T es discreta y toma los valores $t_1 < t_2 < \dots$, se define:

$$H(t) = \sum_{j:t_j \leq t} h(t_j). \quad (1.14)$$

Es claro que la relación $S(t) = \exp(-H(t))$ en este caso no se cumple. Pero como:

$$S(t) = \prod_{j:t_j \leq t} (1-h(t_j)) = \exp \left(\ln \left[\prod_{j:t_j \leq t} (1-h(t_j)) \right] \right) = \exp \left(\sum_{j:t_j \leq t} \ln(1-h(t_j)) \right),$$

entonces para hacer que la relación en cuestión se cumpla, Cox y Oakes definen:

$$H(t) = - \sum_{j:t_j \leq t} \ln(1-h(t_j)). \quad (1.15)$$

Luego se tiene que: $\exp(-H(t)) = \prod_{j:t_j \leq t} (1-h(t_j)) = S(t)$. Las definiciones en (1.14) y (1.15) producen valores muy cercanos cuando las tasas de fallo instantáneas son pequeñas.

1.3. MOMENTOS Y PERCENTILES DE T

La esperanza de la variable aleatoria T definida en $[0, \infty)$, o primer momento con respecto al origen, está dada para variables continuas por:

$$\mu = E[T] = \int_0^\infty t f(t) dt = \int_0^\infty S(t) dt \quad (1.16)$$

si la integral existe. La expresión de la esperanza en términos de $S(t)$ se obtiene integrando por partes tomando $u = t$ y $dv = f(t)dt$, luego $du = dt$ y $v = -S(t)$, así que $E(T) = -tS(t) \big|_0^\infty + \int_0^\infty S(t)dt$, y como $S(\infty) = 0$, entonces el primer término del lado derecho de la igualdad es cero. El segundo momento de T y la varianza están dados por:

$$E[T^2] = \int_0^\infty t^2 f(t) dt \quad (1.17)$$

$$Var[T] = \int_0^\infty (t - E[T])^2 f(t) dt = E[T^2] - (E[T])^2. \quad (1.18)$$

La r - *cuantila* o percentil r de la distribución de T es el valor t_r tal que $S(t_r) = 1 - r$, y la vida mediana o percentil 50, es entonces un valor $t_{0,5}$ tal que $S(t_{0,5}) = F(t_{0,5}) = 1/2$. Sobre la distribución condicional de $T - t \mid T > t$, tenemos lo siguiente:

- Vida residual media (*vrmd*): define la esperanza de vida de una unidad que ha alcanzado un tiempo t sin el fallo, luego para variables continuas tenemos que:

$$vrmd(t) = E(T - t \mid T > t) = \frac{\int_t^\infty (u - t)f(u)du}{S(t)} = \frac{\int_t^\infty S(u)du}{S(t)}. \quad (1.19)$$

Similar a la deducción de $E(T)$ tenemos para el numerador de la ecuación anterior que: $\int_t^\infty (u - t)f(u)du = -(u - t)S(u) \big|_t^\infty + \int_t^\infty S(u)du$, siendo la primera parte igual a cero. Es claro que en $t = 0$, $vrmd(0) = \mu$.

- Vida residual mediana (*vrmd*): es un valor $t_{0,5}$ tal que $Pr(T - t > t_{0,5} \mid T > t) = 0,5$, esto es $S(t_{0,5} + t \mid T > t) = 0,5$, o $S(t_{0,5} + t)/S(t) = 0,5$.

Para variables discretas tenemos que el percentil r es el valor t_r más pequeño tal que $S(t_r) \leq 1 - r$, esto es, $t_r = \inf\{t : S(t) \leq 1 - r\}$. La vida residual mediana se determina usando la distribución condicional en la anterior ecuación. La vida residual media tiene la siguiente expresión:

$$vrmd(t) = \frac{(t_{i+1} - t)S(t_i) + \sum_{j \geq i+1} (t_{j+1} - t_j)S(t_j)}{S(t)} \quad \text{para } t_i \leq t < t_{i+1}. \quad (1.20)$$

1.4. DISTRIBUCIONES PARAMÉTRICAS

Para modelar los tiempos a evento, cualquier distribución sobre los positivos es una candidata posible, aunque de hecho cualquier distribución, que tome también valores sobre los negativos, es una distribución posible para $Y = \ln T$. Algunos modelos paramétricos se expresan mejor en términos del logaritmo de fallo. Todas las distribuciones consideradas son absolutamente continuas. A continuación se hace una enumeración de los modelos más usados en supervivencia.

Distribución Uniforme de T

También es conocida como la ley de Moivre en reconocimiento al autor Abraham De-Moivre que la propuso en 1725. La mención de distribución uniforme obedece a que la densidad sigue una ley uniforme, $f(t) = 1/w$. La ley simplifica los cálculos asumiendo que el comportamiento de $S(t)$ es lineal y decrece en progresión aritmética.

$$S(t) = 1 - \frac{t}{w} \quad 0 \leq t \leq w \quad (1.21)$$

$$h(t) = \frac{1}{w - t} \quad 0 \leq t \leq w. \quad (1.22)$$

La Distribución Exponencial

Es una de las más importantes distribuciones en análisis de supervivencia. Se ha descrito como un buen modelo en estudios de enfermedades infecciosas y para analizar la vida de sistemas electrónicos. También describe adecuadamente el tiempo entre fallos para reparar productos.

Como la distribución exponencial es fácil para ajustar los datos, es frecuentemente mal aplicada para modelar situaciones que requieren distribuciones más complejas. Por ejemplo, modelar la supervivencia en humanos únicamente con la distribución exponencial no es apropiado, sólo es válido para aproximar la mortalidad en intervalos pequeños y en edades específicas. La función de densidad es:

$$f(t) = \frac{1}{\theta} e^{-t/\theta} \quad t \geq 0, \theta > 0 \quad (1.23)$$

donde el parámetro θ es llamado la media de la distribución, y debe ser expresado en las mismas unidades de T , es decir minutos, horas, etc. La densidad exponencial también es escrita como:

$$f(t) = \rho e^{-\rho t} \quad t \geq 0, \rho > 0. \quad (1.24)$$

donde $\rho = 1/\theta$ es llamado la tasa de fallo. De la ecuación anterior se puede deducir fácilmente que, $S(t) = e^{-\rho t}$, $h(t) = \rho$ y $H(t) = \rho t$. También que la media es igual a $1/\rho$, la mediana es $\ln(2/\rho)$ y la varianza es $(1/\rho^2)$. Una variable que siga una ley exponencial no tiene memoria, es decir, la edad del sujeto no afecta la supervivencia posterior. Fácilmente se puede comprobar que $Pr(T > t + l \mid T > t) = Pr(T > l)$.

La Distribución Exponencial Trasladada

Si T tiene distribución exponencial, la transformación $T + G$ tendrá función de densidad $\rho e^{-\rho(t-G)}$. Aquí a la distribución de T se le ha cambiado la localización para obtener una forma más general de la ley exponencial. El parámetro G se denomina tiempo de garantía y es tal que antes de él no ocurren fallos. Otras funciones de interés son: $S(t) = e^{-\rho(t-G)}$, $h(t) = \rho$ y $H(t) = \rho(t-G)$. La media es $G + 1/\rho$, la mediana $(\ln 2 + \rho G)/\rho$ y la varianza $1/\rho^2$.

La distribución de Weibull

Fue inicialmente propuesta por Rosen y Rammner en 1933. Posteriormente en 1939 Waloddi Weibull discute su aplicabilidad en varias situaciones de fallo. Ha sido usada para estudiar la resistencia de ciertos tipos de materiales, así como en experimentos de carcinogénesis y para modelar la mortalidad específica de una enfermedad. La ley de Weibull es una generalización de la distribución exponencial, que resulta cuando la función de riesgo constante igual a k depende de una potencia de tiempo, es decir $h(t) = \alpha k(kt)^{\alpha-1}$ con $k > 0$ un parámetro de escala y $\alpha > 0$ un parámetro de forma. La supervivencia es $S(t) = e^{-(kt)^\alpha}$. Es común encontrar diferentes parametrizaciones para la distribución de Weibull. Por ejemplo, al definir $\rho = k^\alpha$ se obtiene:

$$f(t) = \rho \alpha t^{\alpha-1} \exp(-\rho t^\alpha) \quad (1.25)$$

$$S(t) = \exp(-\rho t^\alpha) \quad (1.26)$$

$$h(t) = \rho \alpha t^{\alpha-1} \quad (1.27)$$

$$E[T] = \rho^{1/\alpha} \quad ; \quad Var[T] = \rho^{2/\alpha} [\Gamma(1 + 2/\alpha) - \Gamma^2(1 + 1/\alpha)].$$

Se puede ver fácilmente que si $\alpha = 1$ se obtiene la distribución exponencial y por tanto tendría un riesgo constante. Para valores diferentes de α el riesgo es monótono, decreciente para $\alpha < 1$ y creciente para $\alpha > 1$. También se le conoce como la primera distribución de los valores extremos. Como se ilustrará en el capítulo de regresión paramétrica, si T es Weibull, entonces $Y = \ln T$ tiene distribución valor extremo.

La simplicidad de la función de supervivencia y de su forma de riesgo, hace de la distribución de Weibull una buena opción de trabajo. Otra razón de su popularidad es la gran variedad de formas que se pueden obtener de ella.

La Distribución de Weibull Traslada

Cuando los fallos no se producen hasta transcurrido un cierto tiempo, puede ser más apropiado un modelo Weibull trasladado. Las funciones de densidad, de supervivencia y de riesgo son con $t \geq G$:

$$f(t) = \rho\alpha(t - G)^{\alpha-1}e^{-\rho(t-G)^\alpha} \quad (1.28)$$

$$S(t) = e^{-\rho(t-G)^\alpha} \quad (1.29)$$

$$h(t) = \rho\alpha(t - G)^{\alpha-1} \quad (1.30)$$

La Distribución Lognormal

Esta distribución ajusta muchos tipos de datos adecuadamente, porque tiene gran variedad de formas. Se ha aplicado con éxito en estudios de cáncer, en particular se ha observado que la distribución del tiempo de supervivencia de la enfermedad de Hodgkin y de la leucemia crónica se ajustan de forma apropiada a una lognormal debido a la pronunciada asimetría por la derecha. También se ha comprobado que la distribución de la edad de inicio de la enfermedad de Alzheimer se ajusta a un modelo lognormal. Si una variable Y tiene distribución normal de media μ y varianza σ^2 , entonces por el teorema de la transformación es fácil ver que $T = e^Y$ tiene distribución log-normal con funciones de densidad, de supervivencia y de riesgo

$$f(t) = \frac{1}{\sigma t \sqrt{2\pi}} \exp\left(-0,5 \left(\frac{\ln t - \mu}{\sigma}\right)^2\right) \quad (1.31)$$

$$S(t) = 1 - \Phi\left(\frac{\ln t - \mu}{\sigma}\right) \quad (1.32)$$

$$h(t) = \frac{(\sigma t \sqrt{2\pi})^{-1} \exp\left(-0,5 \left(\frac{\ln t - \mu}{\sigma}\right)^2\right)}{1 - \Phi\left(\frac{\ln t - \mu}{\sigma}\right)} \quad (1.33)$$

Con Φ la distribución normal estándar acumulada. Haciendo $\rho = 1/e^\mu$ se obtiene otra expresión común para la log-normal, claramente $\ln t - \mu = \rho t$ y por tanto $S(t) = 1 - \psi\left(\frac{1}{\sigma} \ln(\rho t)\right)$.

La propiedad más importante de la log-normal en el contexto de los modelos de supervivencia, es que la función de riesgo tiene forma de joroba. En el ajuste de los datos a esta distribución, hay que tener en cuenta que el

modelo lognormal es simple de aplicar cuando no hay censura, en caso contrario los cálculos son complicados. La exponencial no es un caso especial de la lognormal, sin embargo, serían necesarios una gran cantidad de datos para poder discriminar de forma empírica entre una exponencial y una lognormal con σ cercano a $\sqrt{\ln 2}$.

Distribución Log-Logística

La distribución logística como la normal es simétrica, pero tiene más probabilidad en sus colas. Si Y tiene distribución logística con parámetro de localización μ y de escala σ su densidad es

$$f(y) = \frac{\exp(\frac{y-\mu}{\sigma})}{\sigma[1 + \exp(\frac{y-\mu}{\sigma})]^2} \quad (1.34)$$

Por el teorema de la transformación es fácil ver que la distribución de $T = e^Y$ es log-logística. Definiendo $\rho = e^{-\mu/\sigma}$ y $\alpha = 1/\sigma$, las funciones de densidad, supervivencia y riesgo de T quedan dadas por:

$$f(t) = \frac{\exp(\frac{\ln t - \mu}{\sigma})}{t\sigma[1 + \exp(\frac{\ln t - \mu}{\sigma})]^2} = \frac{\rho\alpha t^{\alpha-1}}{(1 + \rho t^\alpha)^2} \quad (1.35)$$

$$S(t) = \frac{1}{1 + \rho t^\alpha} \quad (1.36)$$

$$h(t) = \frac{\rho\alpha t^{\alpha-1}}{(1 + \rho t^\alpha)} \quad (1.37)$$

La distribución se parece bastante a la ley lognormal pero con la función de supervivencia matemáticamente más tratable. El numerador de la función de riesgo es el riesgo de una Weibull. Si $\alpha \leq 1$, la función de riesgo es monótona decreciente, pero si $\alpha > 1$ crece de 0 hasta $t = (\alpha - 1)^{1/\alpha}/\sigma$ y después decrece hacia 0, esto es, tiene forma de joroba.

La Distribución Gamma

Se ha usado frecuentemente como modelo estadístico para problemas de fiabilidad industrial. Tiene por función de densidad, de supervivencia y de riesgo:

$$f(t) = \frac{\rho}{\Gamma(\alpha)} (\rho t)^{\alpha-1} \exp(-\rho t) \quad (1.38)$$

$$S(t) = \int_t^\infty \frac{\rho}{\Gamma(\alpha)} (\rho y)^{\alpha-1} \exp(-\rho y) dy \quad (1.39)$$

$$h(t) = \frac{\frac{\rho}{\Gamma(\alpha)} (\rho t)^{\alpha-1} \exp(-\rho t)}{\int_t^\infty \frac{\rho}{\Gamma(\alpha)} (\rho y)^{\alpha-1} \exp(-\rho y) dy} \quad (1.40)$$

Aunque para muchos propósitos estadísticos la distribución gamma es de las funciones absolutamente continuas más importantes, el uso en análisis de supervivencia queda limitado por la complejidad de la expresión de la función de supervivencia.

Si $\alpha = 1$ se obtiene la distribución exponencial, y si $\alpha = v/2$ y $\rho = 1/2$ la distribución Ji-cuadrado con v grados de libertad. Si α entero, se obtiene una distribución gamma de parámetros α y ρ , con la suma de α exponenciales independientes de parámetro ρ , y si se suman dos gammas de parámetros α_1 y ρ , y α_2 y ρ se obtiene una gamma de parámetros $(\alpha_1 + \alpha_2)$ y ρ . La función de riesgo es monótona creciente si $\alpha > 1$, monótona decreciente si $\alpha < 1$, y para t grande se aproxima a ρ .

La Distribución Exponential Power

La distribución puede proporcionar funciones de riesgo en forma de bañera.

$$S(t) = e^{1-e^{(\rho t)^\alpha}} \quad (1.41)$$

$$h(t) = \rho \alpha (\rho t)^{\alpha-1} e^{(\rho t)^\alpha} \quad (1.42)$$

1.5. DISTRIBUCIONES TRUNCADAS

Muchas aplicaciones trabajan bajo una condición que filtra la presencia de ciertos individuos. Este es el caso de las aplicaciones actuariales, donde existe la necesidad de obtener probabilidades condicionadas a la supervivencia de los individuos a una edad particular x . La condición en mención se denomina truncamiento. Obviamente en la estimación máximo verosímil de modelos, las distribuciones condicionales surgidas por el truncamiento deben ser tenidas en cuenta dentro de la verosimilitud.

1.5.1. Truncamiento por Izquierda

El truncamiento es por la izquierda cuando sólo los individuos de una cierta edad entran en el estudio porque cumplen un requisito determinado con anterioridad al evento de interés. Si por ejemplo Y es el tiempo de truncamiento, solamente los individuos con $T \geq y$ son observados. Aquí la distribución truncada permitirá obtener probabilidades de ocurrencia condicionadas a que los individuos superen la edad específica y .

Las tablas de mortalidad son modelos tabulares de supervivencia que ilustran probabilidades condicionales obtenidas desde distribuciones truncadas. Este capítulo centra la descripción del tema de probabilidades condicionales a la supervivencia en humanos descritos a través de la tabla de mortalidad. Aquí la variable X representa el tiempo futuro de vida de un recién nacido (edad de muerte), y la variable $T(x)$ un lapso adicional de tiempo vivido por una persona de edad x . Por simplicidad se acostumbra notar a $T(x)$ por T .

$T(x)$: Tiempo futuro de vida de una persona en edad x

$$T = X - x. \quad (1.43)$$

En general una persona con edad x se referirá como (x) . La edad final de un modelo de supervivencia o edad mínima a la cual una persona no puede sobrevivir, es notada por w , esto es w es el más pequeño de los x para el cual $S(x) = 0$ ($S(w) = 0$ pero $S(w - 1) > 0$).

Cuando se habla de probabilidades (o densidades) condicionadas a la supervivencia de una edad x , se trabaja con la distribución de un subconjunto de la muestra de la variable aleatoria X , caracterizada por los valores de X que fallan en exceso de x . En la condición impuesta ha ocurrido un filtro de individuos, permitiéndose analizar sólo aquellos que han superado la edad x , los demás se descartan y no se tendrán en cuenta para los análisis subsecuentes, ignorándose por completo la información de su supervivencia. Las funciones de T (truncadas) serán deducidas a partir de las funciones definidas para X .

La probabilidad de sobrevivir t años más dado que se ha alcanzado la edad x es ${}_t p_x = Pr(T(x) > t)$ y la de morir antes de t años dada una edad x , ${}_t q_x = Pr(T(x) \leq t)$. Estas funciones de supervivencia y distribución condicionadas, junto con la función de densidad y de riesgo tienen las siguientes expresiones:

$$\begin{aligned} {}_t p_x &= S_T(t) = Pr(T(x) > t) = Pr(X > x + t \mid X > x) \\ &= S_X(x + t \mid X > x) = \frac{S_X(x + t)}{S_X(x)} \end{aligned} \quad (1.44)$$

$$\begin{aligned}
{}_tq_x &= F_T(t) = \Pr(T(x) \leq t) = \Pr(X \leq x+t \mid X > x) \\
&= F_X(x+t \mid X > x) = 1 - \frac{S_X(x+t)}{S_X(x)} = 1 - {}_t p_x
\end{aligned} \tag{1.45}$$

$$f_T(t) = \frac{d}{dt} {}_tq_x = \frac{-S'_X(x+t)}{S_X(x)} = \frac{f_X(x+t)}{S_X(x)} \frac{S_X(x+t)}{S_X(x+t)} = {}_t p_x h(x+t). \tag{1.46}$$

Es claro que ${}_x p_0 = S(x)$ y que el término ${}_t p_x h(x+t)dt$ permite aproximar la probabilidad que (x) muera entre $x+t$ y $x+t+dt$. Dada la naturaleza dinámica de los datos de supervivencia, una caracterización de la distribución vía función de riesgo es en general muy conveniente ya que esta función no cambia al condicionar la variable a la supervivencia de un tiempo, pues ya está condicionada en el tiempo. Por ejemplo si la condición es que X es mayor que un tiempo particular x' , aplicando el criterio de probabilidad condicional:

$$h(x \mid X > x') = \frac{f(x \mid X > x')}{S(x \mid X > x')} = \frac{f(x)/S(x')}{S(x)/S(x')} = \frac{f(x)}{S(x)} = h(x). \tag{1.47}$$

La definición de la función de riesgo en el área actuarial tiene una ligera diferencia con la definición dada en (1.7), donde se asume que el fallo incluso se puede dar en $T = t$. La definición de Bowers (1997) presume que la edad de muerte es estrictamente mayor a x , esto es la persona está viva en x :

$$h(x) = \lim_{\Delta x \rightarrow 0} \frac{1}{\Delta x} \Pr(x < X \leq x + \Delta x \mid X > x) = \frac{f(x)}{S(x)}. \tag{1.48}$$

Dado que para variables absolutamente continuas las probabilidades puntuales valen cero, entonces este cambio no afecta las valoraciones probabilísticas. Si T es discreta, entonces la definición en (1.10) adaptada a las condicionales expresadas en (1.48) será:

$$h(t_{j+1}) = \Pr(T = t_{j+1} \mid T > t_j) = \frac{S(t_j) - S(t_{j+1})}{S(t_j)} = 1 - \frac{S(t_{j+1})}{S(t_j)}, \tag{1.49}$$

que en esencia expresa lo mismo que (1.10), esto es, la probabilidad que ocurra el evento en un periodo, dado que no ha ocurrido en el anterior. Si en la ecuación anterior reemplazamos a t_j por x y a t_{j+1} por $x+1$, la definición así establecía para h cuando T es discreta, coincide con la de q_x , pero si el reemplazo se hace en (1.10) la coincidencia es con q_{x-1} . Estas observaciones son obvias pero tal vez necesarias para principiantes en el tema.

Para el cálculo de probabilidades de muerte entre las edades $x+t$ y $x+t+u$ para una persona en edad x , o probabilidades de muerte diferidas es:

$${}_t/uq_x = Pr(t < T < t+u) = \int_t^{t+u} {}_tp_x h(x+y) dy. \quad (1.50)$$

Para expresar ${}_tp_x$ en función de la fuerza de mortalidad se integra $-h(t)dt = d \ln[S(t)]$ de x hasta $x+t$:

$$-\int_x^{x+t} h(y) dy = \ln \left(\frac{S(x+t)}{S(x)} \right) = \ln({}_tp_x), \quad (1.51)$$

ahora tomando la exponencial y luego el cambio de variable $y = x+s$:

$${}_tp_x = \exp \left(-\int_x^{x+t} h(y) dy \right) = \exp \left(-\int_0^t h(x+s) ds \right). \quad (1.52)$$

La fuerza de mortalidad en términos de las probabilidades condicionales de supervivencia queda como:

$$h(x+t) = \frac{f_T(t)}{{}_tp_x} = \frac{\frac{-d}{dt} S_T(t)}{{}_tp_x} = \frac{\frac{-d}{dt} {}_tp_x}{{}_tp_x}. \quad (1.53)$$

La fuerza de mortalidad indica las variaciones instantáneas en la tasa de mortalidad a lo largo de todas las edades, y el promedio ponderado de esas tasas por $S(x)$, se denomina la tasa central de mortalidad. Si se toma el promedio en el intervalo de edad de x a $x+n$ se nota por ${}_nm_x$.

$${}_nm_x = \frac{\int_x^{x+n} S(y) h(y) dy}{\int_x^{x+n} S(y) dy}. \quad (1.54)$$

Si el promedio va de x a $x+1$ la tasa se nota por m_x . Tomando el cambio de variable $y = x+s$ y luego dividiendo numerador y denominador por $S(x)$ se obtiene:

$${}_nm_x = \frac{\int_0^n S(x+s) h(x+s) ds}{\int_0^n S(x+s) ds} = \frac{\int_0^n {}_sp_x h(x+s) ds}{\int_0^n {}_sp_x ds}. \quad (1.55)$$

La esperanza de vida para una persona en edad x es:

$$e_x^0 = E(T(x)) = \int_0^\infty t {}_tp_x h(x+t) dt = \int_0^\infty {}_tp_x dt. \quad (1.56)$$

El resultado se obtiene integrando por partes la primera integral haciendo $u = t$ y $dv = f(t)dt$, luego $du = dt$ y $v = -{}_tp_x$ (por (1.53)). De acuerdo a la definición de edad final del modelo, $\infty = w - x$. La esperanza también da como resultado el ya obtenido en (1.19) de vida residual media:

$$e_x^0 = \int_0^\infty {}_tp_x dt = \frac{\int_0^\infty S(x+t)dt}{S(x)} = \frac{\int_x^\infty S(u)du}{S(x)}.$$

TIEMPO FUTURO DE VIDA EN AÑOS ENTEROS

Muchas aplicaciones en distintos campos consideran la edad en años enteros, por tanto, es necesario contar con la siguiente variable aleatoria:

$K(x) = [T]$: Tiempo futuro de vida en años enteros.

Por simplicidad a $K(x)$ se le nota por K . De acuerdo con la definición de la función parte entera se encuentra la función de densidad de K :

$$\begin{aligned} g(k) &= Pr(K(x) = k) = Pr(k \leq T(x) < k+1) \\ &= Pr(T \geq k) - Pr(T \geq k+1) \\ &= {}_kp_x - {}_{k+1}p_x = {}_kp_x q_{x+k} = {}_k/q_x. \end{aligned} \quad (1.57)$$

La deducción anterior se obtiene debido a que T es variable aleatoria continua, y por tanto $Pr(T = k) = Pr(T = k+1) = 0$. El resultado también puede obtenerse a partir del criterio de diferencias finitas ($\Delta f(x) = f(x+1) - f(x)$):

$$g(k) = -\Delta({}_kp_x) = -({}_{k+1}p_x - {}_kp_x) = {}_kp_x - {}_{k+1}p_x = {}_kp_x q_{x+k}.$$

La función de distribución de $K(x)$ es la función escalonada:

$$G(k) = Pr(K \leq k) = \sum_{h=0}^k g(h) = -\sum_{h=0}^k ({}_{h+1}p_x - {}_hp_x) = -({}_{k+1}p_x - {}_0p_x) = {}_{k+1}q_x. \quad (1.58)$$

Lo anterior dado que ${}_0p_x = 1$ y el resultado de la propiedad telescópica de las sumas ($\sum_{i=i_0}^n a_{i+1} - a_i = a_{n+1} - a_{i_0}$). El uso de K implica un sustancial cambio en la formulación y en la notación, por ejemplo, en la esperanza de vida la notación del caso continuo e_x^0 pasa a ser en el caso discreto e_x , y la fórmula de cálculo se define por:

$$e_x = \sum_{k=0}^{\infty} k {}_k p_x q_{x+k}. \quad (1.59)$$

Aplicando la suma por partes ($\sum u(x)\Delta v(x) = u(x)v(x) - \sum v(x+1)\Delta u(x)$) también $\sum_{k=m}^n u_k \Delta v_k = (u_n v_{n+1} - v_m u_m) - \sum_{k=m}^{n-1} v_{k+1} \Delta u_k$:

$$e_x = \sum_{k=0}^{\infty} k g(k) = \sum_{k=0}^{\infty} k \Delta(-{}_k p_x) = k(-{}_k p_x) \big|_0^{\infty} + \sum_{k=0}^{\infty} {}_{k+1} p_x ((k+1) - k) = \sum_{k=1}^{\infty} {}_k p_x. \quad (1.60)$$

Se puede comprobar fácilmente que $e_x = p_x(e_{x+1} + 1)$, lo que indica que la esperanza de vida de una persona en edad x si sobrevive un año más, será igual a la esperanza de vida que tenga en la edad $x+1$ más un año, el que se ganó al sobrevivir a la edad $x+1$.

Definiendo a S como una variable que representa la fracción del tiempo de vida en el año de muerte, entonces $T = K + S$ y si asumimos una distribución uniforme para S , entonces:

$$e_x^0 = E[T] = E[k] + E[S] = e_x + \frac{1}{2}. \quad (1.61)$$

1.5.2. Truncamiento por Derecha

Tenemos un truncamiento por la derecha si solo eventos que ocurran antes de un tiempo z son observados ($X \leq z$). Un caso donde se presenta el truncamiento, es el de tiempo al incumplimiento de un crédito en un plazo determinado. Cuando el crédito llega a la maduración ya no puede presentarse el incumplimiento. Este ejemplo de terminación de un crédito, es un caso particular de riesgos en competencia, donde la terminación puede ser por prepago de la deuda, por incumplimiento o por maduración.

Debido a que $h(x)$ está condicionada a la supervivencia de x el truncamiento inferior es inocuo. No obstante el truncamiento superior si tiene un efecto en la función de riesgo, pues el tiempo restante de supervivencia después de x ha sido disminuido sin estar previamente contemplado en $h(x)$. Bajo la condición $X \leq z$ las funciones de X quedan como:

$$S(x \mid X \leq z) = \frac{S(x) - S(z)}{1 - S(z)} = \frac{S(x) - S(z)}{F(z)} \quad (1.62)$$

$$F(x \mid X \leq z) = \frac{F(x)}{F(z)} \quad (1.63)$$

$$f(x \mid X \leq z) = \frac{f(x)}{F(z)} \quad (1.64)$$

$$h(x \mid X \leq z) = \frac{f(x)}{S(x) - S(z)} = \frac{f(x)}{S(x) - 1 + F(z)} \quad (1.65)$$

1.5.3. Truncamiento por Izquierda y Derecha

Solamente se observan eventos si ocurren en un espacio de tiempo determinado. Tenemos la doble condición $y < X \leq z$ bajo la cual las funciones de X quedan como:

$$S(x \mid y < X \leq z) = \Pr(X > x \mid y < X \leq z) = \frac{\Pr(x < X \leq z)}{\Pr(y < X \leq z)} = \frac{S(x) - S(z)}{S(y) - S(z)} \quad (1.66)$$

$$F(x \mid y < X \leq z) = 1 - S(x \mid y < X \leq z) = \frac{S(y) - S(x)}{S(y) - S(z)} = \frac{F(x) - F(y)}{F(z) - F(y)} \quad (1.67)$$

$$f(x \mid y < X \leq z) = \frac{-d}{dx} S(x \mid y < X \leq z) = \frac{-d}{dx} \frac{S(x) - S(z)}{S(y) - S(z)} = \frac{f(x)}{S(y) - S(z)} \quad (1.68)$$

$$h(x \mid y < X \leq z) = \frac{f(x \mid y < X \leq z)}{S(x \mid y < X \leq z)} = \frac{f(x)}{S(x) - S(z)} \quad (1.69)$$

1.5.4. LA TABLA DE MORTALIDAD

La tabla de mortalidad tradicional es un modelo de supervivencia con truncamiento por la izquierda presentado en formato tabular, usualmente en años enteros. Su construcción fue diseñada por actuarios mucho antes del avance en la teoría estadística de los modelos de supervivencia vistos como distribuciones probabilísticas.

El modelo tabular no presenta las probabilidades de sobrevivir $S(x)$, a cambio ilustra el número esperado de sobrevivientes de un grupo inicial l_0 , que se le conoce como la raíz de la tabla y generalmente es fijada en miles de unidades, como 10.000 o 100.000. Si $S(x)$ es multiplicado por l_0 el resultado es un número esperado de sobrevivientes para la edad x

$$l_x = l_0 S(x). \quad (1.70)$$

Las funciones $S(x)$ y l_x enmarcan la misma información de la supervivencia, sus gráficas tienen la misma forma con diferente escala debido a que l_x es una expansión de $S(x)$ en la constante l_0 . Aunque la presentación usual de l_x es en forma tabular, por ser un valor esperado tiene un carácter continuo.

Ese valor esperado expresado en (1.70) planteado inicialmente de forma intuitiva, se deduce probabilísticamente a partir de la definición de la variable aleatoria:

$\mathcal{L}_x$: Número de sobrevivientes a la edad x de un grupo inicial l_0

$$\mathcal{L}_x = \sum_{j=1}^{l_0} I_j \quad I_j = 1 \text{ si la vida } j \text{ sobrevive a la edad } x, 0 \text{ en otro caso.}$$

I_j es una variable aleatoria de tipo Bernoulli, por tanto si se consideran vidas independientes, $\mathcal{L}_x$ tiene distribución binomial con parámetros $n = l_0$, o número inicial de sobrevivientes, y probabilidad de éxito (sobrevivir) $S(x)$: $\mathcal{L}_x \sim B(l_0, S(x))$. Así $E[\mathcal{L}_x] = l_x = l_0 S(x)$.

Para obtener el valor esperado de muertes entre x y $x+k$ o ${}_k d_x$, primero hay que definir la variable aleatoria

${}_k \mathcal{D}_x$: Número de muertes entre las edades x y $x+k$.

Como ${}_k \mathcal{D}_x \sim B(l_0, S(x) - S(x+k))$, entonces $E[{}_k \mathcal{D}_x] = l_0(S(x) - S(x+k))$. Otra expresión de ${}_k d_x$ junto con otras funciones de la tabla son:

$${}_k d_x = l_0(S(x) - S(x+k)) = l_x - l_{x+k} \quad (1.71)$$

$${}_k p_x = \frac{S(x+k)}{S(x)} = \frac{l_{x+k}}{l_x} \quad (1.72)$$

$${}_k q_x = \frac{S(x) - S(x+k)}{S(x)} = \frac{l_x - l_{x+k}}{l_x} \quad (1.73)$$

$$e_x = \sum_{k=1}^{\infty} {}_k p_x = \frac{1}{l_x} \sum_{k=1}^{\infty} l_{x+k}. \quad (1.74)$$

Para la función de riesgo tenemos que $h(y+t) = \frac{-d}{dt} {}_t p_y / {}_t p_y = \frac{-d}{dt} l_{y+t} / l_{y+t}$. Tomando $x = y+t$ entonces,

$$h(x) = \frac{\frac{-d}{dx} l_x}{l_x}. \quad (1.75)$$

Si en la ecuación anterior se asume T discreta y se toma la diferencia finita, entonces $h(x) = -\frac{l_{x+1} - l_x}{l_x} = q_x$, corroborando lo mencionado sobre la relación entre la función de riesgo y la función de distribución de T .

Exposición

Del grupo l_x , los sobrevivientes en $x + 1$ habrán vivido un total de l_{x+1} años, y los muertos un total de $\int_0^1 s l_{x+s} h(x+s) ds$, luego el total de años vividos por el grupo de sobrevivientes a edad x , entre x y $x + 1$ es:

$$L_x = l_{x+1} + \int_0^1 s l_{x+s} h(x+s) ds = \int_0^1 l_{x+t} dt \quad (1.76)$$

donde la última expresión es obtenida integrando por partes haciendo $u = s$ y $dv = l_{x+s} h(x+s) ds$, luego $du = ds$ y $v = -l_{x+s}$ (por (1.75)). Esta medida expresada en unidades de años vividos, indica el tiempo total que estuvo expuesta la cohorte l_x al riesgo de morir en el intervalo $(x, x + 1]$. Por extensión, ${}_n L_x$ da la exposición exacta en el intervalo $(x, x + n]$ y $T_x = {}_\infty L_x$ denota el total de años vividos por el grupo l_x más allá de la edad x .

$${}_n L_x = \int_0^n l_{x+t} dt \quad (1.77)$$

$$T_x = \int_0^\infty l_{x+t} dt. \quad (1.78)$$

Es claro entonces que la esperanza de vida para una persona de edad x es:

$$e_x^0 = T_x / l_x. \quad (1.79)$$

Para expresar m_x en función de los componentes de la tabla de mortalidad, se reemplaza (1.70) en (1.55), se toma el promedio en el intervalo de edad de x a $x + 1$ y se aplica la relación en (1.75):

$$m_x = \frac{\int_0^1 l_{x+s} h(x+s) ds}{\int_0^1 l_{x+s} ds} = \frac{-l_{x+s} \big|_0^1}{L_x} = \frac{d_x}{L_x}. \quad (1.80)$$

La tasa de mortalidad anual m_x , es entonces una relación de casos ocurridos frente a exposición. A diferencia de q_x que no excede la unidad, m_x podría excederla, lo que puede verse fácilmente si ninguna persona del grupo l_x sobrevive a la edad $x + 1$. Si se asume que los l_x sobrevivientes que mueren en $(x, x + 1]$ tienen una vida esperada de medio año (supuesto de distribución uniforme de muertes), se obtiene una aproximación que puede usarse para la estimación de los q_x :

$$q_x \approx \frac{m_x}{1 + \frac{1}{2} m_x}. \quad (1.81)$$

Probabilidades a Edades Fraccionadas

Cuando existe un modelo paramétrico para l_x se pueden calcular las probabilidades de muerte y de supervivencia en edades no enteras, pero para modelos tabulares que están determinados sobre edades enteras, es necesario calcularlas bajo supuestos. El más usado establece que el comportamiento del número esperado de sobrevivientes en el intervalo de x a $x + 1$ es lineal, $l_{x+s} = a + b \cdot s$ con $0 \leq s \leq 1$. Como $l_{x+0} = a$ y $l_{x+1} = a + b$, entonces

$$l_{x+s} = l_x - d_x \cdot s. \quad (1.82)$$

Para cada intervalo de de edad la curva de l_x es una recta, pero no necesariamente forman en conjunto una recta sobre todas las edades. Dividiendo ambos lados de la ecuación anterior por l_x se obtiene ${}_s p_x = 1 - s q_x$, luego:

$${}_s q_x = s \cdot q_x. \quad (1.83)$$

Con el resultado se puede concluir que el número de muertes es proporcional al tiempo transcurrido dentro del año, por esto la aproximación se conoce como supuesto de distribución uniforme de muertes, y es aplicable en situaciones donde el riesgo de morir es creciente en s .

Por otra parte, si sobre la probabilidad que (x) muera entre $x + k$ y $x + k + s$, $Pr[(K = k) \cup (S \leq s)] = Pr[k < T \leq k + s] = {}_k p_x {}_s q_{x+k}$, aplicamos el supuesto, entonces:

$$Pr[(K = k) \cup (S \leq s)] = [{}_k p_x] \cdot [s \cdot q_{x+k}] = {}_k p_x q_{x+k} \cdot s = Pr(K = k) Pr(S \leq s),$$

por tanto K y S son independientes y S tiene distribución uniforme. Es obvio que la uniformidad de S viene implícita en la linealidad de l_{x+s} , con ese supuesto, se obtienen fácilmente los resultados en (1.61) y (1.81).

Si se asume que $l_{x+s} = (a + b \cdot s)^{-1}$, esto es una forma hiperbólica para l_{x+s} conocida como el supuesto de Balducci, se obtiene una aproximación para ${}_s q_x$ que es aplicable en situaciones donde el riesgo de morir es decreciente en s :

$${}_s q_x = \frac{s \cdot q_x}{1 - (1 - s)q_x} \quad (1.84)$$

Si se asume que $l_{x+s} = a \cdot b^s$, esto es una forma exponencial para l_{x+s} , se obtiene para ${}_s q_x$ una aproximación conocida como el supuesto de fuerza constante de mortalidad, dado que de este también se obtiene que el riesgo de morir es constante en s :

$${}_s q_x = 1 - (1 - q_x)^s \quad (1.85)$$

2. ESTIMACIÓN DE $S(t)$

Un modelo de supervivencia puede estimarse mediante la estimación de los parámetros de un modelo paramétrico. Pero también puede hacerse en modelos tabulares, en cuyo caso se da una estimación de la supervivencia en distintos puntos donde se observan los fallos. Antes de ver los métodos, primero se introduce el concepto de censura que juega un papel importante en la estimación.

2.1. CENSURA

Cuando el evento de interés ϵ en un individuo no se presenta durante el periodo de observación de un estudio, se dice que la información está censurada y en general para el estudio se dice que la información es incompleta. La censura es no informativa si el conocimiento del tiempo de censura no proporciona más información sobre la supervivencia futura del individuo, que la que se tendría si el individuo hubiere continuado en el estudio. En el caso de retiros por pérdida de seguimiento se estaría probablemente en una situación de censura no informativa, mientras que la no observación por suspensión de un tratamiento de análisis, se trata clarísimamente de censura informativa. Podemos concluir entonces que, si el tiempo de supervivencia y el tiempo de censura son independientes, la censura es no informativa.

Si la distribución de los tiempos de censura comporta información sobre los parámetros de interés, la distribución de los estimadores podría estar influida por la distribución de la censura y debería considerarse dentro del modelo. Cuando la censura es independiente de los tiempos al evento se eliminan las complicaciones.

La muestra aleatoria estará compuesta por un par de variables aleatorias, generalmente notadas por (Y_i, δ_i) , con Y_i indicando el tiempo de observación y con δ_i indicando si se ha presentado el evento.

2.1.1. Censura por la Derecha


Ocurre cuando el evento de interés no acontece durante el transcurso del estudio. Puede suceder porque se pierde el seguimiento de algunos individuos, o porque se interrumpe la observación por suspensión de un tratamiento objeto de análisis por la no tolerancia al mismo, o porque se produce el evento por causa distinta a la de interés, como es el caso del análisis del tiempo a la muerte por cáncer pero la muerte ocurre por accidente.

Censura por la derecha no debe confundirse con truncamiento por la derecha, donde los individuos con un tiempo al evento mayor al tiempo de truncamiento C_R no son analizados. Recordemos que el truncamiento es un filtro que permite incluir los individuos dentro de los análisis solo si cumplen ciertas condiciones. Los individuos censurados sí son tenidos en cuenta para la estimación de los modelos.

Censura de Tipo I

El número observado de fallos es aleatorio en un periodo de seguimiento.

- (a) **Fija:** El evento sólo se observa si ocurre antes que un tiempo preespecificado C_R . En la Figura 2.1 se representa el tiempo de vida de 4 individuos, quienes entran simultáneamente en el estudio y son seguidos hasta el momento C_R . Los individuos 2 y 4 están censurados por la derecha. Para notar la censura se finaliza la línea de supervivencia con un '0' y para notar un fallo con 'x'. La muestra aleatoria tamaño n son los pares de



variables aleatorias $(Y_1, \delta_1), \dots, (Y_n, \delta_n)$ donde $Y_i = \min(T_i, C_R)$ y

$$\delta_i = \begin{cases} 1 & \text{si } T_i \leq C_R \\ 0 & \text{si } T_i > C_R \end{cases} \quad (2.1)$$

En general δ valdrá uno (1) si el evento se ha presentado, esto es, no hay censura, y por tanto también se le conoce como indicador de no censura.


- (b) **Progresiva:** El tiempo de censura es diferente para cada individuo o grupo de individuos. Para su manejo, se divide la muestra en m grupos ($m \leq n$), de forma que a cada grupo le corresponde una censura diferente, y para cada individuo se define la variable $Y_i = \min(T_i, C_j)$, $j = 1, \dots, m$ donde:

$$\delta_i = \begin{cases} 1 & \text{si } T_i \leq C_j : \text{ el individuo } i \text{ no está censurado} \\ 0 & \text{si } T_i > C_j : \text{ el individuo } i \text{ está censurado} \end{cases} \quad (2.2)$$

- (c) **Generalizada:** Las unidades entran en el estudio en momentos diferentes E_i hasta un tiempo C_R de cierre del estudio. Una buena manera de trabajar con estos datos, es reescalar el tiempo de inicio de estos individuos a 0 definiendo $T_i = F_i - E_i$ y $C_i = C_R - E_i$ con F_i el tiempo potencial de fallo. De esta manera se llega a la situación de censura progresiva. La figura 2.2 ilustra la supervivencia de cinco individuos incluidos en un ensayo clínico, reescalando el tiempo individual al momento 0. Los individuos 3 y 4 entran en el estudio al inicio del mismo; los individuos 1, 3 y 4 mueren durante el estudio, y los individuos 2 y 5 están vivos en el momento de analizar los datos. En este caso se observa $(Y_1, \delta_1), \dots, (Y_n, \delta_n)$ donde $Y_i = \min(T_i, C_i)$ y:

$$\delta_i = \begin{cases} 1 & \text{si } T_i \leq C_i : \text{ el individuo } i \text{ no está censurado} \\ 0 & \text{si } T_i > C_i : \text{ el individuo } i \text{ está censurado} \end{cases} \quad (2.3)$$

Figura 2.2: Censura tipo I generalizada



Censura de Tipo II

El estudio se finaliza después de haber ocurrido r fallos predeterminados. La teoría de estadísticos de orden es muy útil para el análisis de estos ensayos, que son necesarios cuando se ponen a prueba equipos costosos, para ahorrar tiempo y dinero. Sean $T_{(1)}, \dots, T_{(n)}$ los tiempos potenciales de fallo ordenados de menor a mayor. La muestra aleatoria es $(Y_1, \delta_1), \dots, (Y_n, \delta_n)$ donde $Y_i = \min(T_i, T_{(r)})$ y:


$$\delta_i = \begin{cases} 1 & \text{si } T_i \leq T_{(r)} : \text{ el individuo } i \text{ no está censurado} \\ 0 & \text{si } T_i > T_{(r)} : \text{ el individuo } i \text{ está censurado} \end{cases} \quad (2.4)$$

2.1.2. Censura por la Izquierda

Un tiempo de vida asociado a un individuo se considera censurado por la izquierda si el evento de interés ha ocurrido antes que la persona entrara al estudio. El hecho de que el fallo se ha dado es conocido, pero para el momento exacto T de falló sólo se sabe que T es menor que un tiempo C_L . Un caso típico se da con la habilidad de un niño en aprender una tarea determinada, en donde además se tiene que al momento de iniciar el estudio algunos de los niños ya saben como hacerla. Los datos pueden representarse mediante una muestra de n individuos con los pares de variables aleatorias (U_i, δ_i) , $\dots$, (U_n, δ_n) donde $U_i = \max(T_i, C_L)$ y:

$$\delta_i = \begin{cases} 1 & \text{si } U_i \geq C_L : \text{ el individuo } i \text{ no está censurado} \\ 0 & \text{si } U_i < C_L : \text{ el individuo } i \text{ está censurado} \end{cases} \quad (2.5)$$

En Figura 2.3 se representa el tiempo de vida de 4 individuos entrando en el tiempo C_L , pero donde el evento ϵ ha ocurrido para los individuos 2 y 3.




Para analizar datos censurados por la izquierda lo más sencillo es transformarlos multiplicándolos por -1 , y analizarlos como datos censurados por la derecha. Sin embargo, el modelo matemático resultante no es exactamente el mismo que para datos censurados por la derecha.

El truncamiento por la izquierda no debe confundirse con censura por la izquierda, pues en el segundo caso se conoce la existencia de los individuos y se sabe su número, a diferencia de cuando hay truncamiento por la izquierda. Además los análisis con datos censurados por la izquierda permiten la estimación de la supervivencia para todo el rango de posibles valores, mientras que si hay datos truncados, sólo pueden ser calculadas las probabilidades condicionadas a la selección.

2.1.3. Censura en un Intervalo

Para el evento de interés sólo se sabe que ha ocurrido en un intervalo aleatorio de tiempo. Es de tipo I si únicamente se sabe si el evento ha ocurrido o no, y T es mayor o menor a un cierto tiempo de control T_C . Es de tipo II cuando se conoce el intervalo dentro del cual ha ocurrido, y T cae entre dos momentos de observación aleatorios, esto es $T \in [T_L, T_R]$. En la figura 2.4 se representan 4 individuos entrando simultáneamente al estudio. Los individuos 1, 2 y 3 están censurados en el intervalo $[L_i, R_i]$ $i = 1, 2, 3$, y el individuo 4 está censurado por la derecha y por tanto $T_4 \in [L_4, \infty]$.



Los estudios longitudinales son el marco típico en el que se produce esta censura, donde el suceso de interés sólo se observa entre visitas consecutivas. El tiempo transcurrido entre dos visitas depende no solo del protocolo establecido para el paciente, sino también del no cumplimiento de las mismas por causa diversas: el paciente vive lejos del hospital y decide saltar citas establecidas, el paciente se encuentra muy mal y pide visitas extras, etc.


2.1.4. Censura Doble

- (a) En un mismo estudio se puede encontrar datos censurados por la derecha, por la izquierda y algunas observaciones exactas. Los datos pueden representarse mediante un par de variables aleatorias (V, δ) donde $V = \max[\min(T_i, C_R), C_L]$ y:

$$\delta_i = \begin{cases} 1 & \text{si } C_L \leq T_i \leq C_R : \text{ individuo } i \text{ no censurado} \\ 0 & \text{si } C_L < C_R < T_i : \text{ individuo } i \text{ censurado por la derecha} \\ -1 & \text{si } T_i < C_L < C_R : \text{ individuo } i \text{ censurado por la izquierda} \end{cases} \quad (2.6)$$

De la figura 2.5 se observa que el evento ocurre después de C_L y antes que C_R para los individuos 1 y 5 ($\delta = 1$), mientras que los individuos 2 y 4 están censurados por la izquierda ($\delta = -1$) y el individuo 3 por la derecha ($\delta = 0$). En el análisis del tiempo de infección con VIH (Virus de Inmunodeficiencia Humana), algunos individuos llegan infectados (censura por la izquierda), otros no se infectan cuando se cierra el estudio (censura por la derecha) y para algunos se conoce el tiempo de infección.

Figura 2.5: Censura doble



- (b) El origen está censurado en un intervalo y el tiempo al evento por la derecha (o en un intervalo). En los estudios sobre VIH otro objetivo reside en el análisis del tiempo transcurrido entre la infección por VIH y el diagnóstico de SIDA. Es usual no conocer con exactitud el tiempo de infección con VIH y poder determinar un intervalo de tiempo en el que ésta se produjo (censura en un intervalo), y en el momento de cerrar el estudio es muy posible que no todos los individuos hayan desarrollado el SIDA (censura por la derecha).

2.2. Estimación No-Paramétrica de $S(t)$

2.2.1. Método Actuarial

A continuación se da una forma general de estimación de $S(t)$ que reúne varios métodos de estimación que adelante se presentan. Dado que el método es actuarial, se mantiene la notación del capítulo anterior. El estimador está basado en la estimación de p_i pues surge de la ecuación $S(x) = p_0 p_1 \cdots p_{x-1}$,

$$\hat{S}(x) = \hat{p}_0 \hat{p}_1 \cdots \hat{p}_{x-1}. \quad (2.7)$$

Los p_i se estiman por separado y de forma independiente dada una muestra n_i disponible en cada intervalo. Así, se está asumiendo que el recorrido de T se ha partido en unidades de tiempo de forma preestablecida y por tanto dichos intervalos no son aleatorios como sí lo son en el estimador de Kaplan-Meier, que se describe más adelante. Si cada intervalo dispone de una muestra aleatoria para estima p_i , esto implica que tal estimador de la sobrevivencia requiera de grandes tamaños de muestra. Este método es especialmente aplicado para la estimación de tablas de mortalidad con probabilidades de muerte anual o quinquenal. De acuerdo al planteamiento, si D_i es el número observado de muertes en el intervalo analizado, un estimador de p_i puede ser determinado conforme a la proporción:

$$\hat{p}_i = 1 - \hat{q}_i = 1 - \frac{D_i}{n_i} = \frac{n_i - D_i}{n_i} \quad (2.8)$$

Condiciona a n_i los estimadores $\hat{p}_i$ son independientes con esperanza p_i y varianza $p_i(1 - p_i)/n_i$, y por tanto:

$$E[\hat{S}(x)] = E[\hat{p}_0 \hat{p}_1 \cdots \hat{p}_{x-1}] = \prod_{i=0}^{x-1} E[\hat{p}_i | n_i] = \prod_{i=0}^{x-1} p_i = S(x). \quad (2.9)$$

La varianza del estimador se hace con base en una aproximación de la varianza para transformación de variables, o método delta. Si representamos a $g(\hat{\theta})$ alrededor de θ tenemos que:

$$g(\hat{\theta}) = g(\theta) + \frac{g'(\theta)}{1!}(\hat{\theta} - \theta) + \frac{g''(\theta)}{2!}(\hat{\theta} - \theta)^2 + \cdots$$

$$g(\hat{\theta}) - g(\theta) = g'(\theta)(\hat{\theta} - \theta) + \frac{g''(\theta)}{2!}(\hat{\theta} - \theta)^2 + \cdots \approx g'(\theta)(\hat{\theta} - \theta)$$

Elevando al cuadrado y tomando esperanza en ambos lados de la aproximación:

$$\text{Var} [g(\hat{\theta})] = \text{E} \left[\left(g(\hat{\theta}) - g(\theta) \right)^2 \right] \approx (g'(\theta))^2 \text{E} \left[\left(\hat{\theta} - \theta \right)^2 \right] = (g'(\theta))^2 \text{Var} (\hat{\theta}). \quad (2.10)$$

Para aplicar el resultado al estimador de la función de supervivencia, se toma recursivamente como $\hat{S}(x) = \exp(\ln(\hat{S}(x)))$. Pensemos que en la expresión anterior, tenemos un estimador $\hat{\theta} = \ln(\hat{S}(x))$ de un parámetro $\theta = \ln(S(x))$ y se determina la varianza de la exponencial de $\hat{\theta}$, luego $\text{Var}[\hat{S}(x)] = \text{Var}[\exp(\hat{\theta})]$ y:

$$\begin{aligned} \text{Var}[\hat{S}(x)] &\approx [\exp(\theta)]^2 \text{Var}[\hat{\theta}] \\ &= [S(x)]^2 \text{Var} [\ln(\hat{S}(x))] \\ &= [S(x)]^2 \text{Var} \left[\sum_{i=0}^{x-1} \ln(\hat{p}_i) \right] \\ &= [S(x)]^2 \sum_{i=0}^{x-1} \text{Var} [\ln(\hat{p}_i)]. \end{aligned}$$

La última parte de la deducción se justifica por la independencia de los $\hat{p}_i$. Aplicando nuevamente el método delta a la varianza del estimador $\ln(\hat{p}_i)$, se tiene,

$$\text{Var} [\ln(\hat{p}_i)] \approx \left\{ \frac{\partial \ln(p_i)}{\partial p_i} \right\}^2 \text{Var} [\hat{p}_i] \approx \frac{1}{p_i^2} \frac{p_i q_i}{n_i} = \frac{q_i}{p_i n_i} \quad (2.11)$$

Por tanto la aproximación de la varianza del estimador de la función de supervivencia es:

$$\text{Var} [\hat{S}(x)] \approx [S(x)]^2 \sum_{i=0}^{x-1} \frac{q_i}{p_i n_i}. \quad (2.12)$$

Esta varianza de $\hat{S}(x)$ es conocida como la fórmula de Greenwood. Puesto que hay términos positivos ignorados que suman, la aproximación subestima el verdadero valor de la varianza. El estimador de $\text{Var} [\hat{S}(x)]$ se determina mediante la estrategia plug-in.

Si p_i se estima de forma distinta a lo establecido en (2.8), obviamente la ecuación (2.12) cambia en su último término de la sumatoria. Seguidamente se plantean otros estimadores de p_i a través de la estimación de q_i , que se notará como q_x , pensando que la estimación va dirigida a la estimación de una tabla de mortalidad. La varianza de esos estimadores debe ser considerada en la $\text{Var} \left[\hat{S}(x) \right]$.

Estimación de q_x

Para estimar q_x es necesario conocer la contribución de cada miembro del grupo de estudio en el intervalo $(x, x + 1]$. Esto es, se requiere conocer la experiencia de supervivencia de cada miembro entre las edades x y $x + 1$.

Exposición: Las edades de ingreso y terminación programada en un estudio para el individuo i se notan como y_i y z_i respectivamente. Así la exposición programada es entonces $z_i - y_i$, pero si el fallo ocurre en un tiempo t_i menor a z_i , la exposición programada no se realiza, y al tiempo $t_i - y_i$ se le conoce como exposición exacta.

En la obtención de la experiencia de supervivencia en $(x, x + 1]$, se requiere conocer cómo es la posición de y_i y z_i en relación con el intervalo. Por ejemplo, si y_i es mayor a $x + 1$ o z_i menor a x , no hay contribución del individuo i al intervalo. Por el contrario si alguno de y_i o z_i están en el intervalo, existe contribución parcial, o si $y_i < x$ y $z_i > x + 1$ como lo indica el siguiente esquema, el individuo contribuye en todo el recorrido del intervalo a la exposición total. Si y_i está en $(x, x + 1]$, el individuo i entra en el intervalo a edad $x + r_i$, y si z_i está en $(x, x + 1]$, el individuo sale del intervalo a edad $x + s_i$. Desde luego, si hay contribución total en el intervalo $r_i = 0$ y $s_i = 1$ y si hay contribución parcial, $0 < s_i - r_i < 1$.



Ejemplo 2.2: Se presentan en el siguiente cuadro las fechas de nacimiento, de ingreso y deceso de seis personas, para un estudio de mortalidad realizado del uno de enero de 1995 al 31 de diciembre de 2000, junto con los valores de y_i y z_i , y los de r_i y s_i para el intervalo (21,22]. Las fechas se dan en formato día/mes/año, y se asumen años de 365 días.

Miembro	F. Nace	F. Ingreso	F. Muerte	y_i	z_i	r_i	s_i
1	01/09/78	01/09/98		20,0	22,3	0	1
2	08/11/73	01/01/95		21,2	27,2	0,2	1
3	18/08/79	18/08/99		20,0	21,4	0	0,4
4	15/02/64	01/01/95		30,9	36,9	-	-
5	08/06/79	01/01/95	01/09/00	15,6	21,6	0	0,6
6	20/06/75	20/06/95	19/12/95	20,0	25,6	-	-

Si en un intervalo $r_i = 0$ y $s_i = 1$, el caso se denomina caso A, situación presentada en el individuo 1 del ejemplo. Si $0 < r_i < 1$ y $s_i = 1$, el caso se denomina como B (individuo 2 del ejemplo), y si $r_i = 0$ y $0 < s_i < 1$, el caso se denomina como C (individuos 3 y 5 del ejemplo). El individuo 6 estaba programado para contribuir con exposición al intervalo $(21, 22]$, pero su deceso ocurrió a los 20,5 años, por tanto la exposición no se da y (r_i, s_i) no está definido en el intervalo. La exposición programada del individuo 5 en el intervalo $(21, 22]$ es $(r_i, s_i) = (0; 0,6)$, y como muere a los 21,2 su exposición exacta en el intervalo es $(r_i; t_i) = (0; 0,2)$. $\triangle$

Se puede distinguir a s_i con diferente notación dependiendo de la salida de observación del individuo en el intervalo. Si la salida se da por una muerte se tendrá la notación t_i , pero si es por una salida aleatoria no programada la notación es w_i . En la estimación de q_x , se ha tomado la contribución del individuo en el intervalo en tres tipos especiales.

Tipo de Exposición	Cálculo de la Exposición
Exacta	$s_i - r_i$ para sobrevivientes del intervalo $t_i - r_i$ para muertes $w_i - r_i$ para retirados
Programada	$s_i - r_i$ para sobrevivientes del intervalo $s_i - r_i$ para muertes $w_i - r_i$ para retirados
Actuarial	$s_i - r_i$ para sobrevivientes del intervalo $1 - r_i$ para muertes $w_i - r_i$ para retirados

El caso donde $r_i > 0$, se da cuando la entrada al estudio de un individuo se da justo en el intervalo $(x, x + 1]$ en la edad $y_i = x + r_i$. Y aunque el estado de su sobrevivencia no se hubiera observado antes de esa edad, si ingresó al estudio es porque estaba vivo antes de la edad x y por tanto se tiene pleno conocimiento que estuvo expuesto al riesgo de morir desde la edad x y r_i debería ser 0. Caso distinto es el de la salida del estudio de un individuo en la edad $z_i = x + s_i$, por cuanto ya no se tiene conocimiento después de esa edad, de su estado de sobrevivencia. La literatura no establece ninguna ventaja en las propiedades de los estimadores ante la selección de s_i por el tipo de exposición (exacta, programada o actuarial). Pero dado que el evento se puede dar en todo el recorrido del periodo de observación, en estas notas se recomienda la exposición programada.

Método de Máxima Verosimilitud: Si δ_i toma el valor 1 cuando la muerte ocurre en el intervalo $(x, x + 1]$ y 0 en otro caso, en el ambiente de decremento simple la contribución a la función de verosimilitud del individuo i , es:

$$L_i = {}_{s_i-r_i}p_{x+r_i}(h(x+s_i))^{\delta_i}. \quad (2.13)$$

Es fácil ver que si $\delta_i = 0$ la verosimilitud es la probabilidad de sobrevivir de $x + r_i$ a $x + s_i$, y si $\delta_i = 1$ es la densidad de muerte en $x + s_i$ dado que se está vivo en $x + r_i$. La verosimilitud total, asumiendo independencia entre las vidas es:

$$L = \prod_{i=1}^{n_x} {}_{s_i-r_i}p_{x+r_i}(h(x+s_i))^{\delta_i} \quad (2.14)$$

donde n_x es el número de personas vivas a edad x . Como las probabilidades son a edades no enteras, la evaluación de (2.14) requiere hacer supuestos distribucionales para l_x en el intervalo analizado. Bajo el supuesto de fuerza constante de mortalidad en el intervalo, o de forma exponencial para l_x , se obtiene que la verosimilitud se convierte en:

$$L(q_x) = h^{D_x} \prod_{i=1}^{n_x} \exp(-(s_i-r_i)h) = (-\ln(1-q_x))^{D_x} \prod_{i=1}^{n_x} \exp[-(s_i-r_i)(-\ln(1-q_x))], \quad (2.15)$$

con D_x el número de muertes en la muestra n_x . Aunque q_x es el parámetro de interés a estimar, una forma de encontrar su estimador y su varianza, es a través de la estimación de h . El logaritmo de la verosimilitud anterior $\ell = \ln(L)$ y su derivada parcial con respecto a h son:

$$\ell = \ln L = D_x \ln h - h \sum_{i=1}^{n_x} (s_i - r_i)$$

$$\frac{\partial \ell}{\partial h} = \frac{D_x}{h} - \sum_{i=1}^{n_x} (s_i - r_i).$$

Igualando a cero la ecuación anterior, tenemos que la estimación de la fuerza de mortalidad es la tasa central de mortalidad:

$$\hat{h} = \frac{D_x}{\sum_{i=1}^{n_x} (s_i - r_i)} = \hat{m}_x \quad (2.16)$$

Los estimadores máximo verosímiles son asintóticamente insesgados con varianza $\text{Var}[\hat{\theta}] = \left\{ E \left[-\frac{\partial^2 \ln L}{\partial \theta^2} \right] \right\}^{-1} \approx \left\{ \left[-\frac{\partial^2 \ln L}{\partial \theta^2} \right] \right\}^{-1} \big|_{\theta=\hat{\theta}_{MV}}$, que aplicada al estimador resulta en:

$$E \left[-\frac{\partial^2 \ell}{\partial h^2} \right] = E \left[\frac{D_x}{h^2} \right] = \frac{n_x q_x}{h^2}$$

$$\text{Var}[\hat{h}] = \frac{h^2}{n_x q_x}$$

De acuerdo con el supuesto de fuerza constante $q_x = 1 - \exp(-h)$, luego aplicando la relación entre estimadores tenemos

$$\hat{q}_x = 1 - \exp(-\hat{h}) = 1 - \exp(-\hat{m}_x) \quad (2.17)$$

$$\text{Var}[\hat{q}_x] = \text{Var}[1 - \exp(-\hat{h})] = \text{Var}[\exp(-\hat{h})] \approx [\exp(-h)]^2 \text{Var}[\hat{h}] = [\exp(-h)]^2 \frac{h^2}{n_x q_x}.$$

La aproximación anterior se obtiene del método delta. Dado que bajo fuerza constante de mortalidad $h = -\ln(1 - q_x)$ tenemos que:

$$\text{Var}[\hat{q}_x] \approx \frac{[1 - q_x]^2 [\ln(1 - q_x)]^2}{n_x q_x}. \quad (2.18)$$

Si este estimador se está aplicando con fines de estimar la sobrevivencia mediante (2.7), entonces la varianza dada por (2.12) donde q_x se estima como D_x/n_x , cambia a:

$$\text{Var}[\hat{S}(x)] \approx [S(x)]^2 \sum_{i=0}^{x-1} \frac{(\ln(1 - q_i))^2}{n_i q_i}. \quad (2.19)$$

Por su parte, el supuesto de distribución uniforme de muertes ($s_i - r_i p_{x+r_i} = \frac{1-s_i q_x}{1-r_i q_x}$ y $h(x + s_i) = \frac{q_x}{1-s_i q_x}$), convierte la verosimilitud (2.14) en

$$L = q_x^{D_x} \prod_{i=1}^{n_x} (1 - r_i q_x)^{-1} \prod_{Viv} (1 - s_i q_x), \quad (2.20)$$

con Viv denotando que la multiplicatoria va sobre los sobrevivientes. La derivada parcial de $\ell = \ln L$ con respecto a q_x igualada a cero, produce la siguiente ecuación que debe ser solucionada para $\hat{q}_x$ por métodos numéricos

$$\frac{D_x}{\hat{q}_x} + \sum_{i=1}^{n_x} \frac{r_i}{1 - r_i \hat{q}_x} - \sum_{Viv} \frac{s_i}{1 - s_i \hat{q}_x} = 0. \quad (2.21)$$

Si $r_i = 0$ para todos los n_x en la muestra y si $s_i = 1$ para todos los $n_x - D_x$ no muertos, entonces se obtiene que:

$$\hat{q}_x = \frac{D_x}{n_x}. \quad (2.22)$$

Como el estimador es una proporción binomial, se tiene que es insesgado y de varianza:

$$\text{Var}[\hat{q}_x] = \frac{q_x(1 - q_x)}{n_x}. \quad (2.23)$$

Por otra parte, sabemos que si asumimos distribución uniforme de muertes en $(x, x + 1]$ entonces $q_x = \frac{m_x}{1+0,5m_x}$ podemos tener un estimador “plug-in” como:

$$\hat{q}_x = \frac{\hat{m}_x}{1 + 0,5\hat{m}_x}, \quad (2.24)$$

asumiendo para la tasa central de mortalidad una estimación como la dada en (2.16). Sus propiedades podríamos analizarlas con métodos de remuestreo.

Las estimaciones de q_x presentan un comportamiento irregular, la suavización de dicha tendencia puede hacerse mediante métodos de graduación como el de Whitaker Henderson, o mediante métodos de regresión por polinomios locales o splines, entre otras técnicas.

2.2.2. Estimador de Kaplan y Meier de $S(t)$


Este estimador de la función de supervivencia ha sido sugerido por varios autores, pero fue atribuido a Kaplan y Meier quienes lo publicaron en 1958. Se conoce además como estimador del límite del producto y también está basado en la descomposición de la función de supervivencia en un producto de probabilidades condicionadas. La diferencia con otros métodos radica en que los intervalos de T son aleatorios. El estimador no es un estimador máximo verosímil, pero hace uso de una secuencia de estimadores máximo verosímiles.

Sea $T_1, T_2, \dots, T_n$ una muestra de la población de interés y $C_1, C_2, \dots, C_n$ variables aleatorias independientes e idénticamente distribuidas con función de distribución G . Se supone que la censura es no informativa, esto es que las C_i son independientes de las T_i . La muestra de análisis consiste de las parejas $(Y_1, \delta_1), \dots, (Y_n, \delta_n)$ donde $Y_i = \min(T_i, C_i)$ y:

$$\delta_i = \begin{cases} 1 & \text{si } T_i \leq C_i \\ 0 & \text{si } T_i > C_i. \end{cases} \quad (2.25)$$

Las siguientes notaciones serán usadas en la definición del estimador:

$Y_{(i)}$	estadístico de orden i de Y ,
$\delta_{(i)}$	valor de δ asociado con $Y_{(i)}$,
$t_{\text{máx}} = Y_{(n)}$	máximo de las observaciones,
$t_{\text{últ}} = \text{máx}_{\delta_{(i)}=1} \{Y_i\}$	máximo de los tiempos de fallo,
$I_i = (Y_{(i-1)}, Y_{(i)}]$	intervalo aleatorio,
n_i	número de individuos vivos antes de $Y_{(i)}$ (en I_i),
D_i	número de individuos que mueren en el intervalo I_i ,
p_i	probabilidad condicional de sobrevivir al intervalo I_i dado que se está vivo al inicio del intervalo,
q_i	probabilidad condicional de morir en el intervalo I_i dado que se está vivo al inicio del intervalo,



Obsérvese que la notación adoptada para las probabilidades de supervivencia y de muerte difieren de las manejadas hasta este tema, por ejemplo en el caso de p_i , la probabilidad se calcula como la $\Pr(T > \tau_i \mid T > \tau_{i-1})$ y no como la $\Pr(T > \tau_{i+1} \mid T > \tau_i)$. La probabilidad condicional de supervivencia estimada en el intervalo I_i dado que se está vivo al inicio del intervalo es:

$$\hat{p}_i = \begin{cases} 1 - \frac{D_i}{n_i} & \text{si } \delta_{(i)} = 1 \\ 1 & \text{si } \delta_{(i)} = 0. \end{cases} \quad (2.26)$$

Si se producen empates entre observaciones censuradas y no censuradas, se considera que las no censuradas han sucedido antes que las censuradas. De acuerdo con la definición de los p_i , la función de supervivencia se descompone como $S(\tau_k) = p_1 p_2 \cdots p_k$, y se define el estimador de Kaplan-Meier para todo $t \leq t_{\text{máx}}$, es decir, para todo t en el rango en el que hay datos como:

$$\hat{S}(t) = \begin{cases} 1 & \text{si } t < Y_{(1)} \\ \prod_{Y_{(i)} \leq t} \left(1 - \frac{D_i}{n_i}\right)^{\delta_{(i)}} = \prod_{t_i \leq t} \left(1 - \frac{D_i}{n_i}\right) & \text{si } t \geq Y_{(1)}. \end{cases} \quad (2.27)$$

El estimador de Kaplan y Meier es una función escalonada con saltos en los tiempos de fallo, y está bien definido para todo punto menor a $t_{\text{máx}}$, el mayor de los tiempos observados en el estudio. Si $t_{\text{máx}}$ coincide con un tiempo de fallo, esto es si $t_{\text{máx}} = t_{\text{últ}}$, entonces el estimador de Kaplan y Meier salta hasta cero en la última observación y por tanto $\hat{S}(t) = 0$ para todo $t > t_{\text{máx}}$. Si el último valor está censurado, es decir si $t_{\text{últ}} < t_{\text{máx}}$, entonces $\hat{S}(t)$ es constante e igual a $\hat{S}(t_{\text{últ}})$ para todo $t_{\text{últ}} < t < t_{\text{máx}}$, y no está determinado después de $t_{\text{máx}}$.

Si la última observación está censurada, Efron sugiere redefinir $\hat{S}(t) = 0$ para todos los $t \geq Y_{(n)}$, y Gill sugiere considerar $\hat{S}(t) = \hat{S}(Y_{(n)})$ para todo $t > Y_{(n)}$. Aunque asintóticamente convergen a la verdadera función de supervivencia, un estudio sobre muestras pequeñas revela que la sugerencia de Gill (con sesgo positivo) tiene mejor comportamiento.

La varianza estimada del estimador de Kaplan y Meier se obtiene por la fórmula de Greenwood como sigue:

$$\hat{\text{Var}} [\hat{S}(t)] \approx [\hat{S}(t)]^2 \sum_{t_i \leq t} \frac{D_i}{n_i(n_i - D_i)}. \quad (2.28)$$


El estimador de Kaplan y Meier es consistente y bajo ciertas condiciones de regularidad converge débilmente a un proceso Gausiano.

Ejemplo 2.1: Enfermos de leucemia que después de un tratamiento con quimioterapia llegaron a un estado de remisión, se aleatorizaron en dos grupos, el primero recibió quimioterapia de mantenimiento y el segundo no recibió nada. Se desea averiguar si la quimioterapia de mantenimiento aumenta el tiempo de remisión. Los siguientes datos representan las semanas desde el inicio del estudio hasta la recaída. Los valores seguidos de un '+' indican que el paciente aún está en remisión, esto es una censura.

Grupo 1: 9, 13, 13+, 18, 23, 28+, 31, 34, 45+, 48, 161+
 Grupo 2: 5, 5, 8, 8, 12, 16+, 23, 27, 30, 33, 43, 45

En el grupo 1, $t_{\text{últ}} = 48 < t_{\text{máx}} = 161$ y la supervivencia sólo está definida hasta el valor 48, mientras que en el grupo 2, $t_{\text{últ}} = t_{\text{máx}} = 45$ y la supervivencia está perfectamente definida en toda la recta real y es cero a partir de 45. La supervivencia estimada es

Figura 2.6: Supervivencia del tiempo hasta final del estado de remisión



Grupo 1	Grupo 2
$\hat{S}(0) = 1$	$\hat{S}(0) = 1$
$\hat{S}(9) = \hat{S}(0) \frac{10}{11} = 0,91$	$\hat{S}(5) = \hat{S}(0) \frac{10}{12} = 0,83$
$\hat{S}(13) = \hat{S}(9) \frac{9}{10} = 0,82$	$\hat{S}(8) = \hat{S}(5) \frac{8}{10} = 0,67$
$\hat{S}(18) = \hat{S}(13) \frac{7}{8} = 0,72$	$\hat{S}(12) = \hat{S}(8) \frac{7}{8} = 0,58$
$\hat{S}(23) = \hat{S}(18) \frac{6}{7} = 0,61$	$\hat{S}(23) = \hat{S}(12) \frac{5}{10} = 0,49$
$\hat{S}(31) = \hat{S}(23) \frac{4}{5} = 0,49$	$\hat{S}(27) = \hat{S}(23) \frac{6}{10} = 0,39$
$\hat{S}(34) = \hat{S}(31) \frac{3}{5} = 0,37$	$\hat{S}(30) = \hat{S}(27) \frac{3}{4} = 0,29$
$\hat{S}(48) = \hat{S}(34) \frac{1}{2} = 0,18$	$\hat{S}(33) = \hat{S}(30) \frac{2}{3} = 0,19$
	$\hat{S}(43) = \hat{S}(33) \frac{1}{2} = 0,10$
	$\hat{S}(45) = \hat{S}(43) \frac{0}{1} = 0,00$

△

2.2.3. Estimador de Nelson-Aalen para $H(t)$

El estimador para la función de riesgo acumulado fue propuesto primeramente por Nelson en 1972, después Aalen en 1978 lo derivó usando teoría de procesos de conteo, y por tanto el estimador es conocido como estimador de Nelson-Aalen. De acuerdo con la relación $S(t) = \exp(-H(t))$ se obtiene una propuesta de estimación para el riesgo acumulado basada en el estimador producto límite como:

$$\hat{H}_{KM}(t) = -\ln \left[\hat{S}_{KM}(t) \right] = -\ln \left[\prod_{t_i \leq t} \left(1 - \frac{D_i}{n_i} \right) \right] = -\sum_{t_i \leq t} \ln \left(1 - \frac{D_i}{n_i} \right). \quad (2.29)$$

Como $-\ln(1 - \frac{D_i}{n_i}) = \frac{D_i}{n_i} + \frac{1}{2} \left(\frac{D_i}{n_i} \right)^2 + \dots$, entonces tomando únicamente el primer término y reemplazando en la ecuación anterior:

$$\hat{H}_{NA}(t) = \begin{cases} 0 & \text{si } t < Y_{(1)} \\ \sum_{t_i \leq t} \frac{D_i}{n_i} & \text{si } t \geq Y_{(1)}. \end{cases} \quad (2.30)$$

El estimador de Nelson-Aalen (2.30) se comporta mejor que el basado en el estimador de Kaplan-Meier (2.29) cuando las muestras son pequeñas. Los dos estimadores son asintóticamente equivalentes, siendo consistentes, eficientes e insesgados de $H(t)$ en intervalos compactos $[0, \tau]$ para los que $H(t) < \infty$, y bajo el modelo de censura aleatoria, puede probarse la convergencia débil del proceso $\sqrt{n}(\hat{H}_{NA}(t) - H(t))$ a una martingala gaussiana.

Dado su mejor desempeño en muestras pequeñas para estimar $H(t)$ que el estimador basado en el estimador de Kaplan-Meier, el estimador de Nelson-Aalen es ampliamente usado para estimar la función de riesgo. El estimador de la función de riesgo basado en $\hat{H}_{NA}(t)$ es:

$$\hat{h}_{NA}(t) = \begin{cases} 0 & \text{si } t \neq Y_{(i)} \\ \frac{D_i}{n_i} & \text{si } t = Y_{(i)}. \end{cases} \quad (2.31)$$

El estimador sólo pone masa positiva en los tiempos en que se ha producido un evento. Condicional a n_i , D_i es binomial con parámetros n_i y p_i , y por tanto $\text{Var} \left[\frac{D_i}{n_i} \right] = (p_i q_i)/n_i$, y si se estima q_i por D_i/n_i entonces:

$$\hat{\sigma}_{\hat{h}_{NA}}^2 = \hat{\text{Var}} \left[\hat{h}_{NA}(t) \right] = \frac{D_i}{n_i^2} \left(1 - \frac{D_i}{n_i} \right) \approx \frac{D_i}{n_i^2}. \quad (2.32)$$

Suponiendo que condicionalmente al número de individuos a riesgo, los términos D_i/n_i y D_j/n_j no están correlacionados, se sigue que la varianza del estimador de Nelson-Aalen de la función de riesgo acumulado:

$$\hat{\sigma}_{\hat{H}_{NA}(t)}^2 \approx \sum_{t_i \leq t} \frac{D_i}{n_i^2}. \quad (2.33)$$

Si en la varianza del estimador de Nelson-Aalen para el riesgo no se hace la aproximación en (2.32), entonces se tendría la siguiente expresión para la varianza del riesgo acumulado:

$$\hat{\sigma}_{\hat{H}(t)}^2 = \sum_{t_i \leq t} \frac{D_i}{n_i^2} \left(1 - \frac{D_i}{n_i}\right) = \sum_{t_i \leq t} \frac{D_i}{n_i(n_i - D_i)} \left(1 - \frac{D_i}{n_i}\right)^2,$$

que bajo el mismo criterio de aproximación usado para obtener (2.32), se llegaría al factor que multiplica a $(\hat{S}(t))^2$ para obtener la varianza estimada del estimador de Kaplan-Meier. Por tanto tendríamos una aproximación para la varianza del estimador del riesgo acumulado y del estimador de Kaplan-Meier para la sobrevivencia en términos de este como:

$$\hat{\sigma}_{\hat{H}_{KM}(t)}^2 \approx \sum_{t_i \leq t} \frac{D_i}{n_i(n_i - D_i)} \quad (2.34)$$

$$\hat{\text{Var}}(\hat{S}_{KM}(t)) \approx \left(\hat{S}_{KM}(t)\right)^2 \hat{\sigma}_{\hat{H}_{KM}(t)}^2.$$

A partir del estimador de Nelson-Aalen de $H(t)$ se obtiene un estimador de $S(t)$, que el software R lo llama estimador de Fleming-Harrington:

$$\hat{S}_{NA}(t) = \exp\left(-\hat{H}_{NA}(t)\right) = \exp\left(-\sum_{t_i \leq t} \frac{D_i}{n_i}\right) \quad (2.35)$$

$$\hat{\text{Var}}(\hat{S}_{NA}(t)) \approx \left(\hat{S}_{NA}(t)\right)^2 \hat{\sigma}_{\hat{H}_{NA}(t)}^2. \quad (2.36)$$

Normalidad Asintótica del Estimador de Nelson-Aalen

Teorema: La estandarización $\sqrt{n} \left(\hat{H}_{NA} - H(t) \right)$, cuando $n \rightarrow \infty$ converge a un proceso gaussiano de media cero.

Demostración. El estimador de Nelson-Aalen puede escribirse como:

$$\hat{H}_{NA}(t) = \int_0^t \frac{d\hat{F}_U(u)}{1 - \hat{F}(u^-)}, \quad (2.37)$$

con $d\hat{F}_U(u) = \frac{\delta_{(i)}}{n}$ (riesgo sin empates) y $1 - \hat{F}(t) = \frac{1}{n} \sum_{i=1}^n 1(Y_i > t)$ la supervivencia empírica de la variable Y . Si no hay empates $1 - \hat{F}(y_{(i)}) = 1 - i/n$ y $1 - \hat{F}(y_{(i)}^-) = 1 - (i-1)/n$. Nótese que en (2.37) se suma el riesgo estimado o cociente entre densidad y sobrevivencia estimadas.

Tomando el desarrollo en serie de Taylor de $(1 - \hat{F}(u^-))^{-1}$ alrededor de $F(u^-)$, y luego integrando tenemos que (para $g(x) = g(a) + g'(a)(x-a) + \dots$ tomar $g(u) = (1-u)^{-1}$ con $x = \hat{F}(u^-)$ y $a = F(u^-)$),

$$\frac{1}{1 - \hat{F}(u^-)} = \frac{1}{1 - F(u^-)} + \frac{\hat{F}(u^-) - F(u^-)}{(1 - F(u^-))^2} + \dots$$

$$\int_0^t \frac{d\hat{F}_U(u)}{1 - \hat{F}(u^-)} = \int_0^t \frac{d\hat{F}_U(u)}{1 - F(u^-)} + \int_0^t \frac{\hat{F}(u^-) - F(u^-)}{(1 - F(u^-))^2} d\hat{F}_U(u) + \dots,$$

si $d\hat{F}_U(u) = dF_U(u) + d(\hat{F}_U(u) - F_U(u))$ y por (2.37) entonces:

$$\begin{aligned} \hat{H}_{NA}(t) &= \int_0^t \frac{dF_U(u)}{1 - F(u^-)} + \int_0^t \frac{d(\hat{F}_U(u) - F_U(u))}{1 - F(u^-)} + \\ &\quad \int_0^t \frac{\hat{F}(u^-) - F(u^-)}{(1 - F(u^-))^2} dF_U(u) + \int_0^t \frac{\hat{F}(u^-) - F(u^-)}{(1 - F(u^-))^2} d(\hat{F}_U(u) - F_U(u)) + \dots, \end{aligned}$$

integrando por partes la segunda expresión de la ecuación anterior, sean:

$$w = \frac{1}{1 - F(u^-)} \quad dw = \frac{1}{(1 - F(u^-))^2} dF(u)$$

$$dv = d(\hat{F}_U(u) - F_U(u)) \quad v = \hat{F}_U(u) - F_U(u)$$

$$\int_0^t \frac{d(\hat{F}_U(u) - F_U(u))}{1 - F(u^-)} = \frac{\hat{F}_U(u) - F_U(u)}{1 - F(u^-)} \Big|_0^t - \int_0^t \frac{\hat{F}_U(u) - F_U(u)}{(1 - F(u^-))^2} dF(u),$$

por tanto,

$$\begin{aligned}\hat{H}_{NA}(t) = H_{NA}(t) + \frac{\hat{F}_U(t) - F_U(t)}{1 - F(t)} - \int_0^t \frac{\hat{F}_U(u) - F_U(u)}{(1 - F(u^-))^2} dF(u) + \\ \int_0^t \frac{\hat{F}(u^-) - F(u^-)}{(1 - F(u^-))^2} dF_U(u) + \int_0^t \frac{\hat{F}(u^-) - F(u^-)}{(1 - F(u^-))^2} d(\hat{F}_U(u) - F_U(u)) + \dots\end{aligned}$$

$$\begin{aligned}\sqrt{n} \left(\hat{H}_{NA}(t) - H_{NA}(t) \right) \approx \frac{\sqrt{n} \left(\hat{F}_U(t) - F_U(t) \right)}{1 - F(t)} - \int_0^t \frac{\sqrt{n} \left(\hat{F}_U(u) - F_U(u) \right)}{(1 - F(u^-))^2} dF(u) + \\ \int_0^t \frac{\sqrt{n} \left(\hat{F}(u^-) - F(u^-) \right)}{(1 - F(u^-))^2} dF_U(u) + \int_0^t \frac{\sqrt{n} \left(\hat{F}(u^-) - F(u^-) \right)}{(1 - F(u^-))^2} d(\hat{F}_U(u) - F_U(u)).\end{aligned}\tag{2.38}$$

Puesto que los estimadores $\hat{F}$ y $\hat{F}_U$ son sumas de variables aleatorias independientes divididas por n , entonces por el teorema central del límite, los siguientes procesos convergen débilmente a un proceso gaussiano Z cuando $n \rightarrow \infty$.

$$\sqrt{n} \left(\hat{F}_U(t) - F_U(t) \right) \rightarrow Z_{F_U}(t) \quad \sqrt{n} \left(\hat{F}_U(t) - F(t) \right) \rightarrow Z_F(t).$$

Según la primera expresión anterior, el último término de (2.38) converge en probabilidad a cero, luego el proceso $\sqrt{n} \left(\hat{H}_{NA}(t) - H_{NA}(t) \right)$ converge débilmente a la siguiente suma de tres procesos gaussianos y por tanto, a un proceso gaussiano Z_H de $E[Z_H] = 0$.

$$\frac{Z_{F_U}(t)}{1 - F(t)} - \int_0^t \frac{Z_{F_U}(u)}{(1 - F(u^-))^2} dF(u) + \int_0^t \frac{Z_F(u^-)}{(1 - F(u^-))^2} dF_U(u).$$

Teorema: La estandarización $\sqrt{n} \left(\hat{S} - S(t) \right)$, cuando $n \rightarrow \infty$ converge a un proceso gaussiano de media cero.

Demostración. En serie de Taylor sea $g(x) = \exp(-x)$, $x = \hat{H}_{NA}(t)$ y $a = H_{NA}(t)$, entonces:

$$\exp(-\hat{H}_{NA}(t)) = \exp(-H_{NA}(t)) - \exp(-H_{NA}(t)) \left(\hat{H}_{NA}(t) - H_{NA}(t) \right) + \dots$$

$$\hat{S}_{NA}(t) = S_{NA}(t) - S_{NA}(t) \left(\hat{H}_{NA}(t) - H_{NA}(t) \right) + \dots$$

$$\sqrt{n} \left(\hat{S}_{NA}(t) - S_{NA}(t) \right) \approx -\sqrt{n} \left(\hat{H}_{NA}(t) - H_{NA}(t) \right) S_{NA}(t).$$

La convergencia débil de $\sqrt{n} \left(\hat{H}_{NA}(t) - H_{NA}(t) \right)$ a un proceso gaussiano cuando $n \rightarrow \infty$ implica la convergencia débil de $\sqrt{n} \left(\hat{S} - S(t) \right)$ a un proceso gaussiano $Z(t)$ de media cero.

2.2.4. Intervalos de Confianza para la Supervivencia y la Función de Riesgo Acumulada

Con base en la estandarización de $\hat{S}(t)$ como pivote, se obtiene un intervalo de confianza para la supervivencia denominado intervalo lineal.

$$\Pr \left(-z_{\alpha/2} \leq \frac{\hat{S} - S(t)}{\sigma_{\hat{S}(t)}} \leq z_{\alpha/2} \right) \simeq 1 - \alpha$$

$$\Pr \left(\hat{S}(t) - z_{\alpha/2} \sigma_{\hat{S}(t)} < S(t) < \hat{S}(t) + z_{\alpha/2} \sigma_{\hat{S}(t)} \right) \simeq 1 - \alpha$$

$$\Pr \left(\hat{S}(t) - z_{\alpha/2} S(t) \sigma_{\hat{H}(t)} < S(t) < \hat{S}(t) + z_{\alpha/2} S(t) \sigma_{\hat{H}(t)} \right) \simeq 1 - \alpha$$

En la estandarización $(\hat{S} - S)/\sigma_{\hat{S}}$ se reemplaza $\sigma_{\hat{S}}$ por su estimador $\hat{\sigma}_{\hat{S}}$ y se sigue asumiendo normalidad. Así, el estimador por intervalo lineal para $S(t_0)$ con t_0 un valor observado de T es entonces:

$$\hat{S}(t_0) - z_{\alpha/2} \hat{S}(t_0) \hat{\sigma}_{\hat{H}(t_0)}, \quad \hat{S}(t_0) + z_{\alpha/2} \hat{S}(t_0) \hat{\sigma}_{\hat{H}(t_0)}, \quad (2.39)$$

Se puede obtener otro estimador por intervalo para la supervivencia con base en un estimador para la función de riesgo acumulado. Con base en la estandarización de $\hat{H}$ como cantidad pivotal se obtiene:

$$\hat{H}(t_0) - z_{\alpha/2} \hat{\sigma}_{\hat{H}(t_0)} \leq H(t_0) \leq \hat{H}(t_0) + z_{\alpha/2} \hat{\sigma}_{\hat{H}(t_0)} \quad (2.40)$$

Tomando la exponencial en el negativo de la relación anterior, se obtiene un estimador por intervalo denominado estimador *log*, dado que está basado en $H = -\ln S$.

$$\hat{S}(t_0) \exp \left(-z_{\alpha/2} \hat{\sigma}_{\hat{H}(t_0)} \right) \leq S(t_0) \leq \hat{S}(t_0) \exp \left(z_{\alpha/2} \hat{\sigma}_{\hat{H}(t_0)} \right)$$

$$\hat{S}(t_0) \exp \left(-z_{\alpha/2} \frac{\hat{\sigma}_{\hat{S}(t_0)}}{\hat{S}(t_0)} \right) \leq S(t_0) \leq \hat{S}(t_0) \exp \left(z_{\alpha/2} \frac{\hat{\sigma}_{\hat{S}(t_0)}}{\hat{S}(t_0)} \right). \quad (2.41)$$

El anterior intervalo se puede obtener con base en la convergencia débil a la normal del estimador $\ln(\hat{S})$ de $\ln(S)$. Del concepto de diferencial $\Delta f = f(x+\Delta x) - f(x) \approx f'(x)\Delta x$, si tomamos f como la función logaritmo natural y asumimos una distancia pequeña entre $S(t)$ y $\hat{S}(t)$ bajo $n \rightarrow \infty$, podemos obtener la siguiente aproximación:

$$\begin{aligned} \ln \hat{S} - \ln S &\approx \frac{\hat{S} - S}{S} \\ S (\ln \hat{S} - \ln S) &\approx \hat{S} - S \\ \frac{(\ln \hat{S} - \ln S)}{\sigma_{\hat{S}}/S} &\approx \frac{(\hat{S} - S)}{\sigma_{\hat{S}}} \rightarrow N(0, 1). \end{aligned}$$

Como $\text{Var}[\ln(\hat{S}(t))] \approx \left(\frac{1}{S(t)}\right)^2 \text{Var}[\hat{S}(t)]$, la siguiente es una probabilidad definida sobre la cantidad pivotal basada en la estandarización de $\ln(\hat{S})$, de donde se obtiene el intervalo en (2.41):

$$\begin{aligned} \Pr \left(-z_{\alpha/2} \leq \frac{S(t)}{\sigma_{\hat{S}(t)}} [\ln(\hat{S}(t)) - \ln(S(t))] \leq z_{\alpha/2} \right) &\simeq 1 - \alpha \\ \Pr \left(\hat{S}(t) \exp \left(-z_{\alpha/2} \frac{\sigma_{\hat{S}(t)}}{S(t)} \right) \leq S(t) \leq \hat{S}(t) \exp \left(z_{\alpha/2} \frac{\sigma_{\hat{S}(t)}}{S(t)} \right) \right) &\simeq 1 - \alpha \end{aligned}$$

Aquí también con el reemplazo de $\sigma_{\ln \hat{S}} = \sigma_{\hat{S}}/S$ por el estimador $\hat{\sigma}_{\hat{S}}/\hat{S}$, se sigue asumiendo convergencia de la estandarización de $\ln \hat{S}$ a la normal estándar.

Borgan y Liestol en 1990 proponen un intervalo basado en la convergencia débil a la normal del estimador $\ln(\hat{H})$ de $\ln H$. Dicha convergencia se deduce de forma similar a como se obtuvo anteriormente la convergencia a la normal estándar, de la estandarización de $\ln \hat{S}$. Si asumimos una distancia pequeña entre $H(t)$ y $\hat{H}(t)$ bajo $n \rightarrow \infty$, podemos obtener la siguiente aproximación:

$$\ln \hat{H} - \ln H \approx \frac{\hat{H} - H}{H}$$

$$H \left(\ln \hat{H} - \ln H \right) \approx \hat{H} - H$$

$$\frac{\left(\ln \hat{H} - \ln H \right)}{\sigma_{\hat{H}}/H} \approx \frac{\left(\hat{H} - H \right)}{\sigma_{\hat{H}}} \rightarrow N(0, 1).$$

En la estandarización de $\ln \hat{H}$, la varianza del estimador $\ln(\hat{H}(t))$ se detrmina según el método delta así:

$$\text{Var}[\ln \hat{H}(t)] \approx \left(\frac{1}{H(t)} \right)^2 \text{Var}[-\ln \hat{S}(t)] \approx \left(\frac{1}{H(t)} \right)^2 \left(\frac{1}{S(t)} \right)^2 \text{Var}[\hat{S}(t)] = \frac{\sigma_{\hat{H}(t)}^2}{(H(t))^2}.$$

Por tanto, la estandarización de $\ln(\hat{H})$, o $[\ln(\hat{H}(t)) - \ln(H(t))]/(\sigma_{\hat{H}(t)}/H(t))$, es cercana a una normal estandar, y la tomamos como cantidad pivotal para determinar un intervalo para $H(t)$. Con algunos pasos algebraicos se despeja la función de riesgo:

$$\Pr \left(-z_{\alpha/2} \leq \frac{H(t)}{\sigma_{\hat{H}(t)}} [\ln(\hat{H}(t)) - \ln(H(t))] \leq z_{\alpha/2} \right) \simeq 1 - \alpha.$$

$$\Pr \left(\hat{H}(t) \exp \left(-z_{\alpha/2} \frac{\sigma_{\hat{H}(t)}}{H(t)} \right) \leq H(t) \leq \hat{H}(t) \exp \left(z_{\alpha/2} \frac{\sigma_{\hat{H}(t)}}{H(t)} \right) \right) \simeq 1 - \alpha.$$

Reemplazando $\sigma_{\ln \hat{H}} = \sigma_{\hat{H}}/H$ por el estimador $\hat{\sigma}_{\hat{H}}/\hat{H}$, se sigue asumiendo convergencia de la estandarización de $\ln \hat{H}$ a la normal estándar. Así, un intervalo de confianza para la función de riesgo en un punto particular t_0 es:

$$\hat{H}(t_0) \exp \left(-z_{\alpha/2} \frac{\hat{\sigma}_{\hat{H}(t_0)}}{\hat{H}(t_0)} \right) \leq H(t_0) \leq \hat{H}(t_0) \exp \left(z_{\alpha/2} \frac{\hat{\sigma}_{\hat{H}(t_0)}}{\hat{H}(t_0)} \right). \quad (2.42)$$

Tomando la exponencial en el negativo de la relación anterior, se obtiene un estimador por intervalo denominado estimador *log - log*, dado que está basado en la transformación $\ln(\hat{H}(t)) = \ln(-\ln(\hat{S}(t)))$:

$$\hat{S}(t_0)^{\exp \left(z_{\alpha/2} \frac{\hat{\sigma}_{\hat{H}(t_0)}}{\hat{H}(t_0)} \right)} \leq S(t_0) \leq \hat{S}(t_0)^{\exp \left(-z_{\alpha/2} \frac{\hat{\sigma}_{\hat{H}(t_0)}}{\hat{H}(t_0)} \right)}. \quad (2.43)$$

Aunque los intervalos de Borgan no son simétricos, tiene mejor desempeño que el lineal, garantizando unos límites entre 0 y 1 para la supervivencia, y un nivel $1-\alpha$ incluso con tamaños de muestra tan pequeños como 25 y una

censura del 50 % excepto en el extremo de la derecha donde habrá pocos datos.

Los intervalos construidos en esta sección son válidos únicamente en el punto t_0 , y son muy angostos como para garantizar que toda la supervivencia esté contenido en ellos. Unas bandas de confianza que garanticen esto, se definen a continuación.

2.2.5. Bandas de Confianza para la Supervivencia

Proporcionan unos límites que garantizan que la supervivencia se encuentre en ellas en un cierto grado de confiabilidad. Los límites $L(t)$ y $U(t)$ son una banda de confianza de nivel $(1 - \alpha)100\%$ para $S(t)$ si:

$$\Pr(L(t) \leq S(t) \leq U(t), \text{ para todo } t_L \leq t \leq t_U) = 1 - \alpha.$$

Hall y Wellner en 1980, propusieron unas bandas que no son proporcionales a los intervalos de confianza dados en (2.39) y (2.43). La estimación sigue los siguientes pasos para una muestra tamaño n :

- (a) Escoger $t_L \geq 0$ y $t_U \leq y_{(n)}$.
- (b) Calcular valores a_L y a_U como sigue, verificando que $0 < a_L < a_U < 1$.

$$a_L = \frac{n\hat{\sigma}_{\hat{H}(t_L)}^2}{1 + n\hat{\sigma}_{\hat{H}(t_L)}^2} \quad ; \quad a_U = \frac{n\hat{\sigma}_{\hat{H}(t_U)}^2}{1 + n\hat{\sigma}_{\hat{H}(t_U)}^2}. \quad (2.44)$$

- (c) Buscar un coeficiente $k_\alpha(a_L, a_U)$ de la tabla C.4 del apéndice del libro de Klein y Moeschberger.
- (d) Las bandas de confianza lineales se definen como:

$$\hat{S}(t) - k_\alpha(a_L, a_U)\hat{S}(t)\frac{(1 + n\hat{\sigma}_{\hat{H}(t)}^2)}{\sqrt{n}}, \quad \hat{S}(t) + k_\alpha(a_L, a_U)\hat{S}(t)\frac{(1 + n\hat{\sigma}_{\hat{H}(t)}^2)}{\sqrt{n}}. \quad (2.45)$$

- (e) Con $\theta = \exp\left(\frac{k_\alpha(a_L, a_U)(1 + n\hat{\sigma}_{\hat{H}(t)}^2)}{\sqrt{n}\ln(\hat{S}(t))}\right)$, las bandas de confianza basadas en la transformación $\ln(-\ln(\hat{S}))$ se definen como:

$$\hat{S}(t)^{1/\theta}, \quad \hat{S}(t)^\theta. \quad (2.46)$$

Las bandas de igual probabilidad o bandas IP, propuestas por Nair en 1984, son tales que los límites de las bandas son proporcionales a los intervalos de confianza dados en (2.39) y (2.43). El proceso es similar al anterior pero cambia el percentil y el estimador de $\sigma_{\hat{H}}$, los pasos son los siguientes:

- (a) Escoger $t_L \geq y_{(1)}$ y $t_U \leq y_{(n)}$.
- (b) Calcular valores a_L y a_U definidos en (2.44).
- (c) Buscar un coeficiente $c_\alpha(a_L, a_U)$ de la tabla C.3 del apéndice del libro de Klein y Moeschberger.
- (d) Las bandas de confianza lineales se definen como:

$$\hat{S}(t) - c_\alpha(a_L, a_U)\hat{S}(t)\hat{\sigma}_{\hat{H}(t)}, \quad \hat{S}(t) + c_\alpha(a_L, a_U)\hat{S}(t)\hat{\sigma}_{\hat{H}(t)}. \quad (2.47)$$

- (e) Con $\theta = \exp\left(\frac{c_\alpha(a_L, a_U)\hat{\sigma}_{\hat{H}(t)}}{\ln(\hat{S}(t))}\right)$, las bandas de confianza basadas en la transformación $\ln(-\ln(\hat{S}))$ se definen como:

$$\hat{S}(t)^{1/\theta}, \quad \hat{S}(t)^\theta. \quad (2.48)$$

Borgan y Liestol demuestran en 1990 que las bandas de confianza IP basadas en el método lineal se comporta bastante mal para muestras de tamaño inferior a 200. Estos autores también demuestran que el método propuesto por Hall y Wellner proporciona bandas de confianza, tanto en su versión lineal como en la logarítmica, con una probabilidad de cobertura cercana al objetivo para muestras con tan solo 20 eventos observados.

2.2.6. Intervalo de Confianza para la Media y Percentiles

Un estimador para la media $\hat{\mu} = \int_0^\infty \hat{S}(t)dt$ no es apropiado si el mayor tiempo observado está censurado. De forma general se puede establecer:

$$\hat{\mu} = \int_0^\tau \hat{S}(t)dt, \quad (2.49)$$

donde τ será t_{max} si la mayor observación no está censurada, pero si lo está, será t_{ult} como lo sugiere Efron, o será asumido como el mayor valor posible de fallo que se podría presentar. La varianza viene dada por:

$$\hat{\text{Var}}(\hat{\mu}) = \sum_{i=1}^D \left[\int_{y_{(i)}}^{\tau} \hat{S}(t) dt \right]^2 \frac{D_i}{n_i(n_i - D_i)} \quad (2.50)$$

con D el número total de eventos. Un intervalo de confianza para la media es:

$$\hat{\mu} - z_{\alpha/2} \sqrt{\hat{\text{Var}}(\hat{\mu})} \quad , \quad \hat{\mu} + z_{\alpha/2} \sqrt{\hat{\text{Var}}(\hat{\mu})}. \quad (2.51)$$

Un intervalo de confianza del nivel $100(1 - \alpha)\%$ para t_p basado en el intervalo lineal para la supervivencia, está formado por los puntos t que satisfacen:

$$-z_{\alpha/2} \leq \frac{\hat{S}(t) - (1 - p)}{\sqrt{\hat{\text{Var}}(\hat{S}(t))}} \leq z_{\alpha/2}. \quad (2.52)$$

2.2.7. Estimador Kernell de la Función de Riesgo

El estimador kernel de $h(t)$ es un promedio ponderado de las estimacones puntuales de los tiempos a evento cercanos a t . El aquí presentado y su varianza, se obtienen a partir del estimador de la función de riesgo acumulado de Nelson-Aalen. Recordemos que $\hat{H}$ es una función con saltos en los r tiempos a evento, $0 = t_0 < t_1 < t_2 < \dots < t_r$. Sean $\Delta\hat{H}(t_i) = \hat{H}(t_i) - \hat{H}(t_{i-1})$ y $\Delta\hat{V}[\hat{H}(t_i)] = \hat{V}[\hat{H}(t_i)] - \hat{V}[\hat{H}(t_{i-1})]$, la magnitud del salto de $\hat{H}(t_{i-1})$ y $\hat{V}[\hat{H}(t_i)]$ en t_i respectivamente, y donde $\Delta\hat{H}(t_i)$ es un estimador de h en los tiempos t_i . El estimador kernel y su varianza para los puntos t tales que $h \leq t \leq t_r - h$ están dados por:

$$\hat{h}(t) = h^{-1} \sum_{i=1}^r k\left(\frac{t - t_i}{h}\right) \Delta\hat{H}(t_i) \quad (2.53)$$

$$\hat{V}[\hat{h}(t)] = h^{-2} \sum_{i=1}^r k\left(\frac{t - t_i}{h}\right)^2 \Delta\hat{V}[\hat{H}(t_i)], \quad (2.54)$$

donde h es el ancho de banda y no se debe confundir con la función de riesgo $h(t)$. La función ponderadora $K(x)$ es una función núcleo que puede tomar formas como:

Uniforme	$K(x) = 1/2,$	$-1 \leq x \leq 1$
Epanechnikov	$K(x) = 0,75(1 - x^2),$	$-1 \leq x \leq 1$
biweight	$K(x) = 15/16(1 - x^2)^2,$	$-1 \leq x \leq 1.$

Si $t < h$, las funciones kernel anteriores que son simétricas no son apropiadas, debido a que no hay tiempos a evento observables menores que cero. Por tanto es recomendable tomar un kernel asimétrico, pero sin modificar el estimador y su varianza. Si $q = t/h$

Uniforme	$K_q(x) = \frac{4(1+q^3)}{(1+q)^4} + \frac{6(1-q)}{(1+q)^3}x,$	$-1 \leq x \leq q$
Epanechnikov	$K_q(x) = K(x)(\alpha_E + \beta_E x),$	$-1 \leq x \leq 1$
	$\alpha_E = \frac{64(2-4q+6q^2-3q^3)}{(1+q)^4(19-18q+3q^2)}$	
	$\beta_E = \frac{240(1-q)^2}{(1+q)^4(19-18q+3q^2)}$	
biweight	$K_q(x) = K(x)(\alpha_{BW} + \beta_{BW}x),$	$-1 \leq x \leq 1$
	$\alpha_{BW} = \frac{64(8-24q+48q^2-45q^3+15q^4)}{(1+q)^5(81-168q+126q^2-40q^3+5q^4)}$	
	$\beta_{BW} = \frac{1120(1-q)^3}{(1+q)^5(81-168q+126q^2-40q^3+5q^4)}.$	

Para los puntos t tales que $t_r - h < t < t_r$ se toma $q = (t_r - t)/h$ y los kernel asimétricos K_q anteriores se usan pero reemplazando x por $-x$.


Un intervalo de confianza para el riesgo basado en la transformación $\ln(-\ln(\hat{S}))$ es

$$\hat{h}(t) \exp \left[\pm \frac{z_{\alpha/2} \hat{\sigma}_{\hat{h}(t)}}{\hat{h}(t)} \right]. \quad (2.55)$$

Ejemplo 2.3: Con la información del ejemplo 2.1 de los tiempos a evento (quimioterapia) bajo ambos tratamientos, se estimó la función de riesgo. La primera conclusión de la estimación, es la diferencia evidente entre el riesgo Nelson-Aalen y el kernel (ver Gráfico 2.7). Esto debido a que en esencia el método de estimación kernel, distribuye las probabilidades en los tiempos a evento observados entre sus vecindades. Es más probable una diferencia grande cuanto más pequeña sea la muestra, debido a que al no observar eventos en un espectro amplio del recorrido de la variable, sólo habrá unas

pocas estimaciones diferentes a cero para redistribuir. Si la muestra es muy grande, habrá tiempos a evento en un espectro amplio del recorrido de T y prácticamente la tendencia del riesgo estará determinada por las estimaciones crudas que da el estimador de Nelson-aalen, así, el estimador kernel del riesgo se convierte en una especie de suavizador de dicha tendencia.

Figura 2.7: Riesgo Kernel y Nelson-Aalen del tiempo hasta final del estado de remisión, por tipo de terapia



Anchos de banda pequeños dan estimaciones más apegadas a la tendencia de las estimaciones crudas, debido al mayor peso que tienen los tiempos a evento observados contiguos a los puntos de estimación, mientras que un ancho de banda grande, proporciona una tendencia global más general, pues otorga pesos a una amplia cantidad de tiempos observados. Es así como con $h = 20$ se estima una tendencia creciente en el riesgo kernel, manteniendo la mostrada por el riesgo Nelson-Aalen, mientras que con $h = 50$, la tendencia cambia a riesgo en forma de joroba. Si es verificable clínicamente, que tiempos grandes en estado de remisión indican la eliminación de la enfermedad, entonces la tendencia apropiada del riesgo sería la forma de joroba. $\triangle$

2.3. Estimación Máximo Verosímil de Modelos Paramétricos

Si no hay datos censurados, la estimación de un modelo paramétrico se realiza acorde al procedimiento usual máximo verosímil. Por ejemplo si T sigue una distribución exponencial, la verosimilitud total asumiendo independencia entre las unidades de estudio está dada por $L = \prod_{i=1}^n h \exp(-\rho t_i)$, y de aquí se deduce fácilmente que $d \ln(L)/d\rho = 0$ da como resultado el estimador $\hat{\rho} = \frac{1}{\bar{t}}$ con $\bar{t}$ el promedio muestral de todos los fallos. Si hay datos censurados hay que tener en cuenta varias consideraciones para usar toda la información en el proceso de estimación.

Cuando se construye la función de verosimilitud se ha de tener en cuenta en particular el tipo de censura y truncamiento que acompaña los datos. También se ha de tener en cuenta si hay independencia entre el tiempo de fallo y el tiempo de censura, lo cual, en general se supone. Si esta hipótesis no se cumple, se necesita mucha más información sobre el comportamiento de los tiempos de censura y deben usarse entonces técnicas especiales para construir la función de verosimilitud.

2.3.1. Función de verosimilitud para un individuo censurado por la derecha

En la deducción de la verosimilitud se supondrá por simplicidad que la variable aleatoria Y es discreta, aunque el mismo razonamiento y conclusión se aplica al caso continuo. La contribución de un individuo a la función de verosimilitud con censura por la derecha es:

(a) Individuo no censurado, $(Y, \delta) = (y, 1)$:

$$\Pr(Y = y, \delta = 1) = \Pr(Y = y, T \leq C) = \Pr(T = y, y \leq C) = \Pr(T = y) \Pr(C \geq y).$$

(b) Individuo censurado, $(Y, \delta) = (y, 0)$:

$$\Pr(Y = y, \delta = 0) = \Pr(Y = y, T > C) = \Pr(C = y, T > y) = \Pr(C = y) \Pr(T > y).$$

La última igualdad en los dos casos analizados, asume independencia entre T y C . La contribución de un individuo con datos observados (y, δ) es:

$$\Pr(y, \delta) = [\Pr(T = y) \Pr(C \geq y)]^\delta [\Pr(C = y) \Pr(T > y)]^{1-\delta}.$$

Asumiendo que T y C son continuas, la contribución de un individuo a la verosimilitud y la verosimilitud total quedan como:

$$f(y, \delta) = [f_T(y)S_C(y)]^\delta [f_C(y)S_T(y)]^{1-\delta} \quad (2.56)$$

$$L(\theta_T, \theta_C \mid Y, \delta) = \prod_{i=1}^n f_T(y_i; \theta_T)^{\delta_i} S_T(y_i; \theta_T)^{1-\delta_i} \prod_{i=1}^n f_C(y_i; \theta_C)^{1-\delta_i} S_C(y_i; \theta_C)^{\delta_i}. \quad (2.57)$$

Si se supone que C censura no informativamente a T , y que el soporte en el que T se mueve es disjunto con el soporte en que se mueve C , entonces la estimación de la distribución de T vía la función de verosimilitud no dependerá de la ley de C y se podrá trabajar equivalentemente con una de las dos siguientes expresiones para L :

$$L(\theta_T \mid Y, \delta) = \prod_{i=1}^n f_T(y_i; \theta_T)^{\delta_i} S_T(y_i; \theta_T)^{1-\delta_i} \quad (2.58)$$

$$L(\theta_T \mid Y, \delta) = \prod_{i=1}^n h_T(y_i; \theta_T)^{\delta_i} S_T(y_i; \theta_T). \quad (2.59)$$

2.3.2. Contribución a la Verosimilitud Según el Tipo de Censura

En la siguiente lista se indica la contribución de un individuo según haya fallado, o haya sido censurado por la derecha, por la izquierda o en un intervalo. Indicando por D el conjunto de tiempos de fallo, por R el conjunto

Clase de Censura	Contribución
Ninguna, tiempo de fallo exacto	$f(y)$
Por la derecha	$S(C_R)$
Por la izquierda	$1 - S(C_L)$
En un intervalo	$S(C_L) - S(C_R)$, si $C_L < C_R$

de observaciones censuradas por la derecha, por L el conjunto censurado por la izquierda y por I el conjunto censurado en un intervalo, la función de verosimilitud se construye poniendo juntas las componentes:

$$L = \prod_{i \in D} f(y_i) \prod_{i \in R} S(C_R) \prod_{i \in L} (1 - S(C_L)) \prod_{i \in I} (S(C_L) - S(C_R)). \quad (2.60)$$

Si hay datos truncados por la izquierda en τ_i , y el truncamiento es independiente del tiempo de muerte, cada contribución queda dividida por $S(\tau_i)$, por ejemplo se reemplaza $f(y_i)$ por $f(y_i)/S(\tau_i)$ y $S(C_R)$ por $S(C_R)/S(\tau_i)$. Si hubiere datos truncados por la derecha, se deben tener en cuenta en la verosimilitud las funciones condicionales descritas en (1.62) - (1.65), igual a como se procede con el truncamiento por la izquierda.

Ejemplo 2.4: Para estimar la distribución de la edad a la cual las mujeres postmenopáusicas desarrollan cáncer de pecho, se observaron 8 mujeres de 50 años durante un periodo de 10 años, examinándolos cada año respecto al desarrollo de este cáncer. Los datos resultantes de este ensayo son los siguientes (edad en la cual se desarrolló el cáncer): (55,56], (58,59], (52,53], (59,60], ≥ 60 , ≥ 60 , ≥ 60 , ≥ 60 . Se supone que la edad en la cual se desarrolla el cáncer sigue una Weibull con parámetro ρ y k . La función de verosimilitud tiene la siguiente forma:

$$L = \prod_{i=1}^4 (S(L_i) - S(R_i)) \prod_{i=5}^8 S(C_i)$$

$$L = \prod_{i=1}^4 (\exp(-(\rho l_i)^k) - \exp(-(\rho r_i)^k)) \prod_{i=5}^8 \exp(-(\rho c_i)^k)$$

en donde C_i es el tiempo de censura por derecha, (L_i, R_i) es el intervalo en caso de censura en un intervalo, y c_i , l_i y r_i son los valores observados de C_i , L_i y R_i respectivamente. El logaritmo de L y las ecuaciones de verosimilitud son:

$$\ln(L) = \ell(\rho, k) = \sum_{i=1}^4 \ln(\exp(-(\rho l_i)^k) - \exp(-(\rho r_i)^k)) - \sum_{i=5}^8 (\rho c_i)^k$$


$$\frac{\partial}{\partial \rho} \ell(\rho, k) = \sum_{i=1}^4 k \rho^{k-1} \frac{r_i^k \exp(-(\rho r_i)^k) - l_i^k \exp(-(\rho l_i)^k)}{\exp(-(\rho l_i)^k) - \exp(-(\rho r_i)^k)} - \sum_{i=5}^8 k c_i (\rho c_i)^{k-1} = 0$$

$$\frac{\partial}{\partial k} \ell(\rho, k) = \sum_{i=1}^4 \rho^k \frac{r_i^k \exp(-(\rho r_i)^k) \ln(\rho r_i) - l_i^k \exp(-(\rho l_i)^k) \ln(\rho l_i)}{\exp(-(\rho l_i)^k) - \exp(-(\rho r_i)^k)} - \sum_{i=5}^8 (\rho c_i)^k \ln(\rho c_i) = 0.$$

Solucionando las ecuaciones por métodos numéricos para ρ y k , se obtiene que: $\hat{\rho} \approx 0,01635$ y $\hat{k} \approx 19,11$. $\triangle$

Ejemplo 2.5: La información del ejemplo 2.1 se reunió en una sola muestra con la información de los tiempos a evento (quimioterapia) bajo ambos tratamientos, para estimar la función de riesgo. La figura 2.8 muestra los ajustes para varias distribuciones paramétricas junto con la estimación kernel ($h = 50$). Como se puede observar, la distribución log-logística parece ajustarse más al estimador no paramétrico kernel del riesgo.

Figura 2.8: Riesgo del tiempo hasta final del estado de remisión, según tipo de distribución



△

2.4. Diagnóstico Gráfico de Modelos Paramétricos

Los gráficos de probabilidad constituyen un instrumento útil para obtener información sobre la población a partir de los datos y deducir la idoneidad del modelo escogido. Los gráficos de probabilidad sirven para rechazar modelos que son claramente no válidos aunque eso no implique ni pruebe que el modelo escogido sea el correcto. De hecho en muchas situaciones más de un modelo puede ser apropiado y proporcionar estimaciones similares para las cantidades de interés. También hay que tener en cuenta que no siempre se tienen suficientes datos para validar la ley que se escoja.

El riesgo kernel (estimado) es una buena alternativa en la selección de una distribución apropiada con datos específicos, mediante su comparación frente al riesgo paramétrico evaluado. El criterio gráfico es un buen complemento en la búsqueda del mejor ajuste. Otro criterio importante son las pruebas de bondad de ajuste presentados en la siguiente sección, aunque estos métodos tienen en su contra las bajas potencias para muestras pequeñas y moderadas, y que tienden a rechazar cualquier modelo cuando el tamaño de la muestra es grande.

El fundamento de los gráficos de probabilidad reside en encontrar una transformación de la función de riesgo acumulada, $g(H(t))$, que sea lineal en alguna función del tiempo $r(t)$. Una vez conocida esta expresión el gráfico de probabilidad se construye estimando la función de riesgo acumulada mediante el estimador de Nelson-Aalen (ver sección 2.2.3) y dibujando los puntos $(r(t), g(H(t)))$ para cada tiempo de fallo t_j .

En un modelo exponencial la relación entre $H(t) = -\ln S(t)$ y t es lineal ($-\ln S(t) = \rho t$), entonces un gráfico de $\hat{H}$ versus t , indicará la plausibilidad del modelo exponencial. Por otra parte, en un modelo de Weibull se tiene la siguiente relación

$$\ln[-\ln S(t)] = \ln[H(t)] = \ln \rho + \alpha \ln t$$

Luego una validación del modelo Weibull, puede conseguirse si la representación del $\ln[\hat{H}(t)]$ respecto a $\ln t$ se aproxima a una recta. También se puede comprobar tal validez con el estimador de Kaplan-Meier, si existe ajuste lineal entre $\ln[-\ln \hat{S}(t)]$ y $\ln t$. La siguiente tabla indica el gráfico que se debe hacer para establecer la bondad de ajuste de varias distribuciones.

Modelo	$H(t)$	Gráfico
Exponencial	ρt	$\hat{H}(t)$ vs. t
Weibull	ρt^α	$\ln(\hat{H}(t))$ vs. $\ln(t)$
Log-Normal	$-\ln \left(1 - \Phi \left(\frac{\ln(t) - \mu}{\sigma} \right) \right)$	$\Phi^{-1} \left(1 - \exp(-\hat{H}(t)) \right)$ vs. $\ln(t)$
Log-Logística	$\ln(1 + \rho t^\alpha)$	$\ln \left(\exp(\hat{H}(t)) - 1 \right)$ vs. $\ln(t)$

3. PRUEBAS DE HIPÓTESIS

Cuando en la muestra no hay censura se pueden usar métodos paramétricos y no paramétricos clásicos para analizar la procedencia de una muestra o para comparar dos o más muestra en relación a su distribución. En presencia de censura, la estrategia de análisis es la comparación de riesgos observados y esperados, mediante estadísticas que ponen pesos en tales comparaciones de riesgos, para detectar diferencias en la supervivencia sobre distintas partes del recorrido de T .

3.1. Pruebas de Hipótesis para una Muestra

Para una muestra tamaño n sean $t_1 < t_2 < \dots < t_r$ los diferentes r tiempos de fallo. La hipótesis que se pone a prueba es:

$$H_0 : h(t) = h_0(t) \text{ para todo } t, \text{ versus, } H_1 : h(t) \neq h_0(t) \text{ para algún } t$$

con $h_0(t)$ una función de riesgo completamente especificada en $[0, \tau]$, usualmente tomando para τ el mayor tiempo observado. Para evaluar la hipótesis se cuenta con la estadística global:

$$Z(\tau) = O(\tau) - E(\tau) = \sum_{i=1}^r W(t_i) \frac{D_i}{n(t_i)} - \int_0^\tau W(s) h_0(s) ds \quad (3.1)$$

con $n(t_i)$ el número de individuos a riesgo en t_i , D_i el número de fallos y W una función positiva que puede ser aleatoria. Si $n(t_i)$ es cero entonces se tiene que $W(t_i)$ también es cero. La estimación del riesgo en t_i , es adoptado del principio de estimación de Nelson y Aalen, y deberá ser cercano al esperado $O(t_i)$ si la hipótesis nula es cierta.

La estadística es la diferencia entre riesgos observados y esperados, pero ponderada por una función $W(t)$ con el propósito de detectar diferencias en el riesgo sobre partes especiales del recorrido de T . Si $W(t) = n(t)$ la prueba pone énfasis en tiempos menores, aunque también se puede ver como una diferencia entre eventos observados y esperados de los individuos en riesgo, sin énfasis en ninguna parte del recorrido en estas diferencias de eventos. La prueba de Wilcoxon toma $W(t) = n(t)S_0(t)$, con S_0 la sobrevivencia hipotética, y pone énfasis en tiempos menores para detectar diferencias entre riesgos observados y esperados. Con $W(t) = n(t)S_0(t)^p(1 - S_0(t))^q$, $p \geq 0$ y $q \geq 0$, se tiene la prueba de Fleming y Harrington. Si p es más grande que q , se pone más peso en tiempos cortos, si es más pequeño, el peso mayor recae en tiempos grandes, y si $p = q > 0$ se pone más énfasis a la mitad del recorrido de los tiempos. Para $p = q = 0$ se obtiene la prueba de log-rank.

Cuando H_0 es cierta, la varianza de Z y un estimador consistente de ella son:

$$\text{Var}(Z(\tau)) = \int_0^\tau W^2(s) \frac{h_0(s)}{n(s)} ds \quad (3.2)$$

$$\hat{\text{Var}}(Z(\tau)) = \sum_{i=1}^r W^2(t_i) \frac{D_i}{n^2(t_i)} \quad (3.3)$$

Para muestras grandes $[Z(\tau)]^2/V[Z(\tau)]$ se distribuye como una χ^2 con un grado de libertad.

Ejemplo 3.1: La información del ejemplo 2.1 se reunió en una sola muestra con la información de los tiempos a evento (quimioterapia) bajo ambos tratamientos, para probar su procedencia frente a una distribución paramétrica en particular. Fijando $\tau = 161$, la hipótesis nula no fue rechazada al 5% para ninguna distribución de las analizadas, como son la log-logística ($p - \text{valor} = 0,304$), Weibul ($p - \text{valor} = 0,257$), exponencial ($p - \text{valor} = 0,099$) y log-normal ($p - \text{valor} = 0,088$). De escoger una distribución paramétrica para modelar el tiempo al evento la opción es la log-logística dado que presentó el mayor $p - \text{valor}$ en la prueba. Esto concuerda con el criterio gráfico que compara ajustes paramétricos con el riesgo kernel ilustrado en el ejemplo 2.4. $\triangle$

3.2. Pruebas de Hipótesis para dos Muestras

Se somete a prueba si es razonable creer que dos muestras provengan de una población con la misma función de riesgo o supervivencia. Si S_1 y S_2 representan las funciones de supervivencia de cada una de las dos poblaciones completamente especificadas en el intervalo $[0, \tau]$, entonces la hipótesis de interés pueden expresarse de la siguiente forma:

$H_0 : S_1(t) = S_2(t)$ para todo t , versus, $H_1 : S_1(t) \neq S_2(t)$ para algún $t \leq \tau$.

$H_0 : h_1(t) = h_2(t)$ para todo t , versus, $H_1 : h_1(t) \neq h_2(t)$ para algún $t \leq \tau$.

Diferentes estrategias se han diseñado para probar la hipótesis nula de igualdad de modelos de supervivencia, concluyendo en el uso de estadísticas que pueden ser resumidas en una forma general, cuya estructura tiene forma similar a (3.1), pero en este caso se compara mediante dos estadísticas, la intensidad de fallo estimada de cada una de las muestras en t_i , frente a la de fallo global estimada en t_i bajo la hipótesis nula.

$$Z_j(\tau) = \sum_{i=1}^r W_j(t_i) \left\{ \frac{D_{ij}}{n_{ij}} - \frac{D_i}{n_i} \right\} \quad (3.4)$$

con $t_1 < t_2 < \dots < t_r$ los diferentes tiempos de fallo en las muestras combinadas, D_{ij} y n_{ij} el número de eventos e individuos a riesgo en el tiempo t_i de la muestra $j = 1 ; 2$, y $D_i = D_{i1} + D_{i2}$ el número total de eventos en t_i y $n_i = n_{i1} + n_{i2}$ el número de individuos a riesgo justo antes de t_i . Luego la intensidad de fallo global es estimada por D_i/n_i y las de cada muestra por D_{ij}/n_{ij} , $j = 1, 2$.

Igual que para el caso de una muestra los $W_j(t)$ son funciones de peso positivas convenientemente escogidas dependiendo del propósito de la prueba que en particular se someta, y también bajo la condición que $W_j(t) = 0$ siempre que el número de individuos a riesgo n_{i1} o n_{i2} sea cero. La función de peso se suele definir como $W_j(t_i) = n_{ij} \cdot W(t_i)$ donde W es un peso común compartido por los dos grupos, así la estadística de prueba se convierte en:

$$Z_j(\tau) = \sum_{i=1}^r W(t_i) \left\{ D_{ij} - \frac{n_{ij}}{n_i} D_i \right\}, \quad j = 1, 2 \quad (3.5)$$

La estadística así planteada, ahora es la suma ponderada de las diferencias entre D_{ij} , o número observado de muertes en t_i y el número esperado de muertes bajo H_0 en t_i de la muestra j .

Si cada tiempo $t_i, i = 1, \dots, r$, es visto de forma independiente, cada vector aleatorio (D_{i1}, D_{i2}) condicionado a D_i y n_{i1} y n_{i2} , sigue una ley hipergeométrica de parámetros $(D_i, p_j = n_{ij}/n_i)$. Por tanto un estimador consistente de la varianza del estadístico en (3.5) y de la covarianza entre $Z_1(\tau)$ y $Z_2(\tau)$ están dados respectivamente por:

$$\hat{\text{Var}}[Z_j(\tau)] = \sum_{i=1}^r W^2(t_i) \left[D_i \frac{n_{ij}}{n_i} \left(1 - \frac{n_{ij}}{n_i} \right) \right] \frac{n_i - D_i}{n_i - 1} \quad (3.6)$$

$$\hat{\text{Cov}}[Z_1(\tau), Z_2(\tau)] = - \sum_{i=1}^r W^2(t_i) \left[D_i \frac{n_{i1}}{n_i} \frac{n_{i2}}{n_i} \right] \frac{n_i - D_i}{n_i - 1} \quad (3.7)$$

El factor de corrección por finitud $(n_i - D_i)/(n_i - 1)$ es visto como una corrección por empates, que tiene el valor uno si no hay individuos con tiempos a evento comunes.

La prueba cuenta con dos estadísticas $Z_1(\tau)$ y $Z_2(\tau)$, de tal forma que existe evidencia para el rechazo de la hipótesis nula si algún valor observado de ellas es lejano a cero, pues bajo H_0 la esperanza de $Z_j(\tau)$ es cero. Como $Z_1(\tau) + Z_2(\tau) = 0$, las componentes del vector $(Z_1(\tau), Z_2(\tau))$ son linealmente dependientes, y la prueba estadística puede reducirse a un sólo estadístico con la estandarización entre $Z_1(\tau)$ y $Z_2(\tau)$ notado como $Z_W(\tau)$.

$$Z_W(\tau) = \frac{\sum_{i=1}^r W(t_i) \left\{ D_{i1} - \frac{n_{i1}}{n_i} D_i \right\}}{\sqrt{\sum_{i=1}^r W^2(t_i) \frac{n_{i1}}{n_i} \left(1 - \frac{n_{i1}}{n_i} \right) \frac{n_i - D_i}{n_i - 1} D_i}} \quad (3.8)$$

La evidencia contra H_0 se resume mediante $Z_W(\tau)$, que se distribuye como una normal estándar para n suficientemente grande. Propuestas de W que proporcionan pruebas estadísticas diferentes, se citan a continuación.

3.2.1. Prueba del Log-Rank o de Cox y Mantel

Para entender esta prueba es necesario traer a colación los resultados de la distribución hipergeométrica. Si una población tamaño N se compone de N_1 elementos de una clase 1 y N_2 de la clase 2, entonces la variable X que cuenta el número de elementos que pertenece a la clase 1 en una muestra aleatoria tamaño n sin reemplazo, tiene distribución hipergeométrica con parámetros $(n, p_1 = N_1/N)$. X puede tomar valores en el rango $\max(0, n - N_2) \leq x \leq \min(n, N_1)$ y tiene $E[X] = np_1$ y $\text{Var}[X] = np_1(1 - p_1) \frac{N-n}{N-1}$.

En el caso de la sobrevivencia de dos grupos, justo antes del primer tiempo al evento t_1 , se tienen n_{11} individuos a riesgo en el grupo 1 y n_{12} en el grupo 2, con $n_1 = n_{11} + n_{12}$. Si se asumen estos valores como poblacionales, entonces condicional a n_1 y D_1 , la variable aleatoria D_{11} que cuenta el número de eventos en el grupo 1 de una muestra tamaño D_1 , tiene distribución hipergeométrica de parámetros $(D_1, p_1 = n_{11}/n_1)$ y con esperanza y varianza:

$$E[D_{11}] = D_1 \cdot p_1 = D_1 \frac{n_{11}}{n_1}$$

$$\text{Var}[D_{11}] = D_1 \frac{n_{11}}{n_1} \left(1 - \frac{n_{11}}{n_1}\right) \frac{n_1 - D_1}{n_1 - 1}.$$

De la misma forma tenemos resultados similares para los restantes tiempos a evento t_i . Para el último tiempo al evento t_r , se tienen n_{r1} individuos a riesgo en el grupo 1 y n_{r2} en el grupo 2, con $n_r = n_{r1} + n_{r2}$. Condicional a n_r y D_r , D_{r1} tiene distribución hipergeométrica de parámetros $(D_r, p_r = n_{r1}/n_r)$ y con esperanza y varianza:

$$E[D_{r1}] = D_r \cdot p_r = D_r \frac{n_{r1}}{n_r}$$

$$\text{Var}[D_{r1}] = D_r \frac{n_{r1}}{n_r} \left(1 - \frac{n_{r1}}{n_r}\right) \frac{n_r - D_r}{n_r - 1}.$$

La variable centrada $Z_{11} = D_{11} - E[D_{11}] = D_{11} - D_1 \frac{n_{11}}{n_1}$ tendrá entonces esperanza 0 y varianza $\text{Var}[Z_{11}] = \text{Var}[D_{11}]$. Así mismo tenemos esta centralización para los demás tiempos a evento, en particular en t_r , la variable centrada $Z_{r1} = D_{r1} - D_r \frac{n_{r1}}{n_r}$ tendrá esperanza 0 y varianza $\text{Var}[Z_{r1}] = \text{Var}[D_{r1}]$.

Si se mira de forma independiente los individuos a riesgo y los eventos que hay justo antes de cada tiempo a evento $t_1 < t_2 < \dots < t_r$, entonces las variables aleatorias $D_{i1}, i = 1, \dots, r$, son independientes y por tanto tenemos para el agregado de sus centralizaciones:

$$Z_1 = \sum_{i=1}^r Z_{i1} = \sum_{i=1}^r \left(D_{i1} - D_i \frac{n_{i1}}{n_i} \right)$$

$$E[Z_1] = 0 \quad ; \quad \text{Var}[Z_1] = \sum_{i=1}^r \text{Var}[Z_{i1}] = \sum_{i=1}^r D_i \frac{n_{i1}}{n_i} \left(1 - \frac{n_{i1}}{n_i}\right) \frac{n_i - D_i}{n_i - 1}.$$

La estandarización de Z_1 tendrá asintóticamente distribución normal estándar, esto es:

$$\frac{\sum_{i=1}^r \left(D_{i1} - D_i \frac{n_{i1}}{n_i} \right)}{\sqrt{\sum_{i=1}^r D_i \frac{n_{i1}}{n_i} \left(1 - \frac{n_{i1}}{n_i} \right) \frac{n_i - D_i}{n_i - 1}}} \sim N(0, 1).$$

Por procedimiento similar para el grupo 2 se tiene:

$$Z_2 = \sum_{i=1}^r Z_{i2} = \sum_{i=1}^r \left(D_{i2} - D_i \frac{n_{i2}}{n_i} \right)$$

$$E[Z_2] = 0 \quad ; \quad \text{Var}[Z_2] = \sum_{i=1}^r \text{Var}[Z_{i2}] = \sum_{i=1}^r D_i \frac{n_{i2}}{n_i} \left(1 - \frac{n_{i2}}{n_i} \right) \frac{n_i - D_i}{n_i - 1}.$$

Los anteriores resultados se utilizan para la prueba de dos muestras con censura. El principio sale de la siguiente deducción. Sea p_{ij} la probabilidad de fallo en el momento t_i , $i = 1, 2, \dots, r$, para el grupo $j = 1, 2$. Si únicamente interesa la diferencia de mortalidad en un momento dado t_i , la hipótesis bilateral sobre la supervivencia es:

$$H_0 : p_{i1} = p_{i2}, \text{ versus, } H_1 : p_{i1} \neq p_{i2}$$

Como un estimador natural de p_{ij} es n_{ij}/n_i , entonces la distribución bajo H_0 de D_{ij} , el número de fallos en t_i para el grupo j , condicionada a n_i y D_i , converge a una hipergeométrica con esperanza y varianza:

$$E[D_{ij} \mid n_i, D_i] = D_i(n_{ij}/n_i)$$

$$\text{Var}[D_{ij} \mid n_i, D_i] = [D_i(n_{i1}/n_i)(n_{i2}/n_i)] [(n_i - D_i)/(n_i - 1)]$$

Como estadística de prueba de la anterior hipótesis, puede usarse una estandarización de Z_1 , que bajo H_0 converge asintóticamente a una normal estándar. Si interesa la diferencia de mortalidad en todos los tiempos t_i , la hipótesis se plantea como:

$$H_0 : p_{11} = p_{12}, p_{21} = p_{22}, \dots, p_{r1} = p_{r2}$$

$$H_1 : p_{i1} \neq p_{i2} \text{ para algún } i = 1, 2, \dots, r$$

La estadística de prueba podría usar la información comportada en Z_1 y Z_2 , pero dado que:

$$\begin{aligned}
Z_1 + Z_2 &= \sum_{i=1}^r \left(D_{i1} - D_i \frac{n_{i1}}{n_i} \right) + \sum_{i=1}^r \left(D_{i2} - D_i \frac{n_{i2}}{n_i} \right) \\
&= \sum_{i=1}^r \left(D_{i1} + D_{i2} - D_i \left[\frac{n_{i1}}{n_i} + \frac{n_{i2}}{n_i} \right] \right) \\
&= \sum_{i=1}^r (D_i - D_i * 1) \\
&= 0,
\end{aligned}$$

entonces como estadística de prueba puede ser usada Z_1 o Z_2 . Si se selecciona Z_1 , la distribución asintótica de su estandarización al cuadrado bajo H_0 tiene distribución $\chi^2(1)$, aunque las D_{ij} no sean independientes. La estadística de prueba es entonces:

$$LR = \frac{\left(\sum_{i=1}^r \left(D_{i1} - \frac{n_{i1}}{n_i} D_i \right) \right)^2}{\sum_{i=1}^r \frac{n_{i1} n_{i2} (n_i - D_i) D_i}{n_i^2 (n_i - 1)}} \quad (3.9)$$

Como se ve, la estadística es igual al cuadrado de (3.8) cuando $W(t_i)$ es igual a uno, y por tanto la estadística de base es la dada en (3.5) con $W(t_i) = 1$.

Si los p_{ij} pertenecen a grupos independientes, la prueba de log-rank se corresponde con la conocida prueba de Mantel y Haenszel. La prueba de log-rank da igual peso a cada observación y tiene una potencia óptima para detectar diferencias en la supervivencia de dos poblaciones cuando las funciones de riesgo son proporcionales. Los distintos mecanismos de censura que pueden actuar en uno u otro tratamiento no tienen efecto en el estadístico log-rank.

3.2.2. Prueba de Gehan

Es una generalización de la prueba de Mann, Whitney y Wilcoxon para muestras censuradas propuesta por Gehan en 1.965. Se compara cada tiempo de la muestra 1 con cada tiempo de la muestra 2 mediante una función score definida por:

$$\Phi((Y_{i1}, \delta_{i1}), (Y_{j2}, \delta_{j2})) = \begin{cases} +1 & \text{si } Y_{i1} \leq Y_{j2} \text{ y } \delta_{i1} = 1 \text{ y } \delta_{j2} = 0, \\ +1 & \text{si } Y_{i1} < Y_{j2} \text{ y } \delta_{i1} = 1 \text{ y } \delta_{j2} = 1, \\ -1 & \text{si } Y_{i1} \geq Y_{j2} \text{ y } \delta_{i1} = 0 \text{ y } \delta_{j2} = 1, \\ -1 & \text{si } Y_{i1} > Y_{j2} \text{ y } \delta_{i1} = 1 \text{ y } \delta_{j2} = 1, \\ 0 & \text{en otros casos.} \end{cases}$$

En la comparación se asigna 1 siempre que el tiempo de una unidad sea inferior a la de otro, y se asigna -1 siempre que sea superior. El estadístico se define como:

$$\begin{aligned} U &= \sum_{i=1}^n \sum_{j=1}^n \Phi((Y_{i1}, \delta_{i1}), (Y_{j2}, \delta_{j2})) \\ &= \sum_{i=1}^n \sum_{j=1}^n \mathbf{1}(Y_{i1} \leq Y_{j2}) \delta_{i1} (1 - \delta_{j2}) + \mathbf{1}(Y_{i1} < Y_{j2}) \delta_{i1} \delta_{j2} \\ &\quad - \mathbf{1}(Y_{i1} \geq Y_{j2}) (1 - \delta_{i1}) \delta_{j2} - \mathbf{1}(Y_{i1} > Y_{j2}) \delta_{i1} \delta_{j2} \end{aligned}$$

Con la siguiente variable se expresa la estadística en términos de la muestra combinada y su procedencia.

$$Z_i^* = \begin{cases} 1 & \text{si } i \text{ es de la muestra 1 ,} \\ 0 & \text{si } i \text{ es de la muestra 2 .} \end{cases}$$

$$\begin{aligned} U &= \sum_{i=1}^n \sum_{j=1}^n Z_i^* (1 - Z_j^*) (\delta_i \mathbf{1}(Y_j \geq Y_i) - \delta_j \mathbf{1}(Y_j \leq Y_i)) \\ &= \sum_{i=1}^n \delta_i Z_i^* \sum_{j=1}^n (1 - Z_j^*) \mathbf{1}(Y_j \geq Y_i) - \sum_{j=1}^n \delta_j (1 - Z_j^*) \sum_{i=1}^n Z_i^* \mathbf{1}(Y_j \leq Y_i) \\ &= \sum_{i=1}^n \delta_i Z_i^* n_{i2} - \sum_{j=1}^n \delta_j (1 - Z_j^*) n_{j1} \\ &= \sum_{i=1}^n (\delta_i Z_i^* n_{i2} - \delta_i n_{i1} + \delta_i Z_i^* n_{i1}) \\ &= \sum_{i=1}^n \delta_i (Z_i^* [n_{i2} + n_{i1}] - n_{i1}) \\ &= \sum_{i=1}^n \delta_i n_i \left(Z_i^* - \frac{n_{i1}}{n_i} \right), \end{aligned}$$

con $n_i = n_{i1} + n_{i2}$ y n_{i1} el número de individuos a riesgo de la muestra 1 justo antes que Y_i y n_{i2} el número de individuos a riesgo de la muestra 2 justo antes que Y_i . El resultado corresponde a un caso particular de la familia de estadísticos $Z_j(\tau)$ definidos en (3.5) cuando $W(t_i) = n_i$ y el número de eventos es como máximo uno. En esas condiciones la varianza en (3.6) para U queda como: $\text{Var}(U) = \sum_{i=1}^r n_{i1} \cdot n_{i2}$.

Para esta prueba los pesos al principio son grandes y a medida que transcurre el tiempo disminuyen, por tanto los valores del estadístico dan más peso a las observaciones tempranas, y desde luego, es más potente para detectar diferencias a corto término. Considera pesos que dependen fuertemente del momento en que ocurre un evento y de la distribución de la censura, y por consiguiente puede conducir a resultados falsos si los patrones de censura de cada población son muy diferentes.

3.2.3. Prueba de Tarone y Ware

Considera los pesos como $W(t_i) = \sqrt{n_i}$. Es como un compromiso entre las dos pruebas anteriores, pues asigna más peso a la diferencia entre el número de muertes observadas y esperadas en aquellos puntos donde hay más datos. Al igual que la prueba de Gehan por considerar pesos que dependen fuertemente del momento en que ocurre un evento y de la distribución de la censura, puede conducir a resultados falsos si los patrones de censura de cada población son muy diferentes.

3.2.4. Prueba de Peto

Toma como estimador de la función de supervivencia para las dos muestras combinadas, una función muy cercana al estimador de Kaplan y Meier:

$$\tilde{S}(t) = \prod_{t_i \leq t} \left(1 - \frac{D_i}{n_i + 1}\right) \quad (3.10)$$

La prueba fija los pesos en la anterior función de supervivencia estimada: $W(t_i) = \tilde{S}(t_i)$. La prueba no está afectada por posibles patrones de censura distintos.

3.2.5. Familia de Pruebas de Fleming y Harrington

Fleming y Harrington proponen una familia de pruebas basándose en una familia de pesos $\hat{S}(t_{i-1})^p(1 - \hat{S}(t_{i-1}))^q$ con $p \geq 0$ y $q \geq 0$. El uso de la función de supervivencia combinada asegura que los pesos sean conocidos justo antes del momento en que se hacen las comparaciones. Reiterando, si $p > 0$ y $q = 0$ se concluye en una prueba que detecta diferencias tempranas, y contrariamente si $p = 0$ y $q > 0$ las pruebas obtenidas dan más peso a las observaciones más grandes y pueden detectar diferencias a largo término.

Ejemplo 3.2: Para la información del ejemplo 2.1 tenemos que con la prueba de Peto no podemos rechazar al 5% la hipótesis nula $H_0 : S_1(t) = S_2(t)$ frente a una alternativa bilateral ($p - valor = 0,096$), ni con la de Gehan ($p - valor = 0,099$). Tampoco se puede rechazar con la prueba de log-rank (Fleming y Harrington con $p = 0$ y $q = 0$) pero da un estadístico de prueba calculado más cerca a la región de rechazo ($p - valor = 0,065$). $\triangle$

3.2.6. Pruebas para Funciones de Supervivencia que se Cruzan

Cuando las funciones de riesgo se cruzan, las diferencias tempranas a favor de un grupo se cancelan con las diferencias tardías a favor del otro, y por tanto las pruebas basadas en $Z_j(\tau)$ resultan muy poco potentes. La prueba propuesta por Levene en 1.969 tiene los siguientes pasos:

- (a) Combinar los datos y ordenarlos de menor a mayor, con la condición que un tiempo t no censurado preceda a un tiempo t censurado.
- (b) Para cada t_i calcular: $s_i = \prod_{j=1}^i \frac{n_j}{n_j+1}$, con n_j el número de individuos a riesgo en la muestra combinada en el tiempo j .
- (c) Asignar un rango c_k , al k -ésimo individuo $k = 1, 2, \dots, n$, así:
$$c_k = 1 - 2s_i, \text{ si no hay censura y el tiempo de fallo } T_k \text{ es igual a } t_i.$$
$$c_k = 1 - s_i, \text{ si hay censura y } C_k \text{ está entre los tiempos de fallo } t_i \text{ y } t_{i+1}.$$
- (d) Para cada individuo calcular $d_k = |c_k - \bar{c}_j|$ con $\bar{c}_j$ la media de los c_k en el grupo $j = 1, 2$.
- (e) Aplicar la prueba de los rangos signados de Wilcoxon a estos d_k .

3.3. Pruebas para K Muestras

La hipótesis sometida a prueba para comparar los patrones de supervivencia de K poblaciones es la siguiente:

$$H_0 : S_1(t) = S_2(t) = \dots = S_k(t) \text{ para todo } t$$

$$H_1 : S_i(t) \neq S_j(t) \text{ para algún } t$$

La información se resume en la terna (Y_i, δ_i, Z_i) $i = 1, 2, \dots, n$ en donde como antes $Y_i = \min\{T_i, C_i\}$, $\delta_i = 1$ si $T_i \leq C_i$ y $\delta_i = 0$ si $T_i > C_i$, y por su parte $Z_i = j$ si el dato i proviene de la muestra $j = 1, 2, \dots, K$. Se nota por $t_1 < t_2 < \dots < t_r$ los diferentes tiempos de fallo en las muestras combinadas. También, $D_i = \sum_{j=1}^k D_{ij}$ define el número total de eventos en t_i , y $n_i = \sum_{j=1}^k n_{ij}$ el número de individuos a riesgo justo antes de t_i . Si la hipótesis nula es cierta un estimador de la tasa de fallo esperada es D_i/n_i .

La estadística de prueba se basa en los estadísticos definidos por (3.4), pero con j variando de 1 a k , y también para ella se define $W_j(\tau) = n_{ij} \cdot W(t_i)$. Las estimaciones de la varianza de $Z_j(\tau)$ y de la covarianza entre $Z_j(\tau)$ y $Z_g(\tau)$ bajo H_0 , también son como se definió en la sección anterior.

$$\hat{\sigma}_{jj} = \sum_{i=1}^r W^2(t_i) \frac{n_{ij}}{n_i} \left(1 - \frac{n_{ij}}{n_i}\right) \frac{n_i - D_i}{n_i - 1} D_i \quad (3.11)$$

$$\hat{\sigma}_{jg} = - \sum_{i=1}^r W^2(t_i) \frac{n_{ij}}{n_i} \frac{n_{ig}}{n_i} \frac{n_i - D_i}{n_i - 1} D_i \quad j \neq g \quad (3.12)$$

Como $\sum_{j=1}^K Z_j(\tau) = 0$, las componentes del vector $(Z_1(\tau), Z_2(\tau), \dots, Z_K(\tau))$ son linealmente dependientes y la prueba estadística puede construirse eligiendo $K - 1$ de los $Z_j(\tau)$. La estadística de prueba final es entonces:

$$Q^2 = (Z_1(\tau), Z_2(\tau), \dots, Z_{K-1}(\tau)) \hat{\Sigma}^{-1} (Z_1(\tau), Z_2(\tau), \dots, Z_{K-1}(\tau))^T, \quad (3.13)$$

donde $\hat{\Sigma} = (\hat{\sigma}_{jg})$ es una matriz de orden $(K - 1) \times (K - 1)$ conformada por las $\hat{\sigma}_{jg}$ correspondientes a las $(K - 1)$ componentes elegidas. Cuando la hipótesis nula es cierta el estadístico Q^2 sigue una ley χ^2 con $K - 1$ grados de libertad si n es grande. Igual que en la sección anterior diversas elecciones de la función de peso W proporcionan pruebas estadísticas diferentes, y $W_j(t) = 0$ siempre que el número de individuos a riesgo sea cero.

Si se rechaza la hipótesis nula, se procede a realizar comparaciones múltiples por pares controlando el nivel de significancia, similar a como se hace en diseño experimental. Bonferroni propone establecer un $\alpha' = \alpha/m$ con m el total de comparaciones. Šidák propone $\alpha' = 1 - (1 - \alpha)^{1/m}$. Si $\alpha = 0,05$, $K = 3$ y por tanto $m = 6$, según Bonferroni $\alpha' = 0,0083$ y según Šidák $\alpha' = 0,0085$.

3.3.1. Prueba de Tendencia

Algunas veces las poblaciones siguen un cierto orden de tal manera que se puede esperar que la supervivencia en la población uno sea mejor que en la población dos, la supervivencia de la población dos sea mejor que en la población tres, y así sucesivamente. La hipótesis en consideración es:

$$H_0 : S_1(t) = S_2(t) = \dots = S_k(t) \text{ para todo } t$$

$$H_1 : S_1(t) \geq S_2(t) \geq \dots \geq S_k(t) \text{ con alguna desigualdad estricta, y } t \leq \tau.$$

$$H_0 : h_1(t) = h_2(t) = \dots = h_k(t) \text{ para todo } t$$

$$H_1 : h_1(t) \leq h_2(t) \leq \dots \leq h_k(t) \text{ con alguna desigualdad estricta, y } t \leq \tau.$$

La estadística de prueba también se basa en los estadísticos definidos por (3.5), con j variando de 1 a k , y teniéndose la alternativa de considerar cualquier peso de los mencionados. Sea $\hat{\Sigma} = (\hat{\sigma}_{jg})$ la matriz de covarianzas definidas en las ecuaciones (3.11) y (3.12), correspondientes a las K componentes del vector $(Z_1(\tau), Z_2(\tau), \dots, Z_K(\tau))$. Dada una secuencia de puntuaciones (scores) $a_1 < a_2 < \dots < a_K$, usualmente asignando $a_j = j$, el estadístico de prueba se toma como:

$$Z = \frac{\sum_{j=1}^K a_j \cdot Z_j(\tau)}{\sqrt{\sum_{j=1}^K \sum_{g=1}^K a_j a_g \sigma_{jg}}} \quad (3.14)$$

Cuando H_0 es cierta y las muestras son grandes, la distribución del estadístico sigue una ley normal estándar. Así mismo, las estadísticas Z_i , $i = 1, 2, \dots, K$, tienen tendencia decreciente.

3.3.2. Prueba Estratificada

Se compara la supervivencia de poblaciones ajustando por los niveles de otra covariante. El ajuste es recomendable cuando los niveles de la covariante de ajuste no son muchos, si la covariante es continua, su discretización debe procurar tener un número de niveles reducido. Si hay M niveles la hipótesis planteada es:

$$H_0 : S_{1s}(t) = S_{2s}(t) = \cdots = S_{ks}(t) \text{ para } s = 1, \dots, M \text{ y todo } t < \tau$$

$$H_1 : S_{is}(t) \neq S_{js}(t) \text{ para algún } t$$

La estadística de prueba se toma de los estadísticos definidos por (3.5), con j variando de 1 a K , pero tomadas en cada estrato s y son notadas por $Z_{js}(\tau)$. Las varianzas y covarianzas se calculan también a partir de (3.11) y (3.12).

$$Q^2 = (Z_1(\tau), Z_2(\tau), \dots, Z_{k-1}(\tau)) \hat{\Sigma}^{-1} (Z_1(\tau), Z_2(\tau), \dots, Z_{k-1}(\tau))^T, \quad (3.15)$$

con $Z_j(\tau) = \sum_{s=1}^M Z_{js}(\tau)$ y $\hat{\sigma}_{jg} = \sum_{s=1}^M \hat{\sigma}_{jgs}$. Bajo la hipótesis nula y n suficientemente grande, el estadístico de prueba sigue una ley χ^2 con $K - 1$ grados de libertad.

4. MODELOS DE REGRESIÓN PARAMÉTRICOS

El modelo log-lineal totalmente paramétrico se define con base en: un vector de p covariantes Z , un vector de coeficientes de regresión γ , una distribución para los errores W y unos parámetros $\mu(-\infty < \mu < \infty)$ de localización y $\sigma > 0$ de escala.

$$Y = \ln T = \mu + \gamma^T Z + \sigma W. \quad (4.1)$$

El modelo para $S(t | Z)$ puede expresarse en términos de una función de sobrevivencia subyacente (basal) $S_0(t)$ o correspondiente a un individuo con $Z = 0$:

$$\begin{aligned} S(t | Z) &= \Pr(T > t | Z) \\ &= \Pr(\ln T > \ln t | Z) \\ &= \Pr(\mu + \gamma^T Z + \sigma W > \ln t) \\ &= \Pr(\mu + \sigma W > \ln t + \theta^T Z) \quad \text{con } \theta = -\gamma \\ &= \Pr(e^{\mu + \sigma W} > te^{\theta^T Z}). \end{aligned}$$

Por otra parte si $Z = 0$ entonces (4.1) queda como $\ln T = \mu + \sigma W$ y su función de sobrevivencia se nota como $S(t | Z = 0) = S_0(t)$, que difiere paramétricamente de $S(t | Z)$. Como $T = e^{\mu + \sigma W}$, vemos que la anterior probabilidad quedó referida sobre “ $T | Z = 0$ ” pero evaluada en el punto $te^{\theta^T Z}$, luego:

$$S(t | Z) = S_0(te^{\theta^T Z}). \quad (4.2)$$

Esta expresión en (4.2) sobre la función de supervivencia, se conoce como modelo de vida acelerada. Al factor $e^{\theta^T Z}$ se le llama factor de aceleración e indica el cambio de escala de tiempo producido por las covariantes. Puede verse fácilmente que:

$$f(t | Z) = \frac{-d}{dt} S(t | Z) = f_0(t e^{\theta^T Z}) e^{\theta^T Z}$$

$$h(t | Z) = \frac{f(t | Z)}{S(t | Z)} = h_0(t e^{\theta^T Z}) e^{\theta^T Z}.$$

Ejemplo 4.1: Sea la covariante Z tomando el valor 1 para tratamiento alternativo y 0 para tratamiento estándar.

- Si $\theta = 0,7$ entonces $e^{0,7*1} = 2$ y si:
 - $t = 3$: $S(3 | Z = 1) = S_0(3e^{0,7*1}) = S_0(3 * 2) = S_0(6)$
 La supervivencia para un individuo con tratamiento alternativo después de 3 años es la misma que tendría un individuo con tratamiento estándar después de 6 años. Luego el tratamiento alternativo disminuye la supervivencia.
 - $t = M_1$: $S(M_1 | Z = 1) = S_0(M_1 * 2) = 0,5 = S_0(M_0)$, con M_1 la mediana del tratamiento alternativo y M_0 la mediana del tratamiento estándar, luego:
 $2M_1 = M_0$ y por tanto "la supervivencia mediana del tratamiento estándar es dos veces la del tratamiento alternativo".
- Si $\theta = -0,7$ entonces $e^{-0,7*1} = 0,5$ y si:
 - $t = 3$: $S(3 | Z = 1) = S_0(3e^{-0,7*1}) = S_0(3 * 0,5) = S_0(1,5)$
 La supervivencia para un individuo con tratamiento alternativo después de 3 años es la misma que tendría un individuo con tratamiento estándar después de 1,5 años. Luego el tratamiento alternativo alarga la supervivencia.
 - $t = M_1$: $S(M_1 | Z = 1) = S_0(M_1 * 0,5) = 0,5 = S_0(M_0)$, luego:
 $M_1/2 = M_0$ y por tanto "la mediana del tratamiento estándar es la mitad de la mediana del tratamiento alternativo". $\triangle$

4.1. Estimación del Modelo Log-Lineal

La ilustración general se hace omitiendo las covariantes en (4.1). Si se desea incluir en el proceso de estimación las covariantes, se reemplaza en las deducciones a μ por $\mu + \gamma^T Z$. Con la omisión, entonces Y como función de W queda como $y = h(w) = \mu + \sigma w$, y $w = h^{-1}(y) = (y - \mu)/\sigma$ y $J = \frac{d h^{-1}(y)}{dy} = 1/\sigma$. Luego las funciones de densidad y supervivencia de Y son:

$$f_Y(y) = f_W(h^{-1}(y)) |J| = \frac{1}{\sigma} f_W\left(\frac{y - \mu}{\sigma}\right) \quad (4.3)$$

$$S_Y(y) = \Pr(Y > y) = \Pr(\mu + \sigma W > y) = \Pr\left(W > \frac{y - \mu}{\sigma}\right) = S_W\left(\frac{y - \mu}{\sigma}\right). \quad (4.4)$$

Ahora, si $t = h(y) = e^y$ entonces $y = h^{-1}(t) = \ln t$ y $J = \frac{d h^{-1}(t)}{dt} = 1/t$, luego las funciones de densidad y supervivencia de T quedan como:

$$f_T(t) = f_Y(h^{-1}(t)) |J| = \frac{1}{t} f_Y(\ln t) = \frac{1}{t\sigma} f_W\left(\frac{\ln t - \mu}{\sigma}\right) \quad (4.5)$$

$$S_T(t) = \Pr(T > t) = \Pr(\ln T > \ln t) = \Pr(Y > \ln t) = S_Y(\ln t) = S_W\left(\frac{\ln t - \mu}{\sigma}\right). \quad (4.6)$$

Distribuciones con función de sobrevivencia de la forma $S_Y(y) = S_W\left(\frac{y - \mu}{\sigma}\right)$, se conocen como distribuciones de localización-escala. Como $Y = \ln T$ entonces se dice que T tiene una distribución de log-localización-escala. Asumiendo censura por la derecha, las funciones de verosimilitud y de log-verosimilitud para la estimación de los parámetros del modelo (4.1), quedan así:

$$L(\mu, \sigma | y'_i, \delta_i) = \prod_{i=1}^n f_Y(y'_i)^{\delta_i} S_Y(y'_i)^{1-\delta_i} = \prod_{i=1}^n \left[\frac{1}{\sigma} f_W\left(\frac{y'_i - \mu}{\sigma}\right) \right]^{\delta_i} \left[S_W\left(\frac{y'_i - \mu}{\sigma}\right) \right]^{1-\delta_i}$$

$$\ell(\mu, \sigma | y'_i, \delta_i) = \sum_{i=1}^n [-\delta_i \ln \sigma + \delta_i \ln f_W(w_i) + (1 - \delta_i)(\ln S_W(w_i))], \quad (4.7)$$

con $w_i = \frac{y'_i - \mu}{\sigma}$, y'_i un valor particular de $Y'_i = \min(\ln T_i, \ln C_i)$ y $\delta_i = I(T_i \leq C_i)$. La estimación puede hacerse maximizando ℓ o solucionando las ecuaciones de verosimilitud: $\frac{\partial \ell}{\partial \mu} = 0$ y $\frac{\partial \ell}{\partial \sigma} = 0$, con base en métodos numéricos.

Obsérvese que si la log-verosimilitud se plantea con las distribuciones de T , entonces el primer término en (4.7) quedaría como $-\delta_i \ln(t'_i \sigma)$ con t'_i un valor particular de $T'_i = \min(T_i, C_i)$. La log-verosimilitud resultante es proporcional a (4.7), pues $\ln(t'_i \sigma) = \ln t'_i + \ln \sigma$ y $\ln t'_i$ es constante en ℓ .

Las varianzas estimadas de los estimadores se toman de la matriz de información observada, para la cual se requieren las siguientes primeras y segundas derivadas de $\ell(\mu, \sigma | y'_i, \delta_i)$ con respecto a μ y σ . Tomando a $D = \sum_{i=1}^n \delta_i$ y dado que $\frac{\partial w}{\partial \mu} = -\frac{1}{\sigma}$ y $\frac{\partial w}{\partial \sigma} = -\frac{y'_i - \mu}{\sigma^2} = -\frac{w}{\sigma}$, entonces:

$$\begin{aligned} \frac{\partial \ell}{\partial \mu} &= -\frac{1}{\sigma} \sum_{i=1}^n \left[\delta_i \frac{\partial}{\partial w_i} \ln f_W(w_i) + (1 - \delta_i) \frac{\partial}{\partial w_i} \ln S_W(w_i) \right] \\ \frac{\partial \ell}{\partial \sigma} &= -\frac{D}{\sigma} - \frac{1}{\sigma} \sum_{i=1}^n \left[\delta_i w_i \frac{\partial}{\partial w_i} \ln f_W(w_i) + (1 - \delta_i) w_i \frac{\partial}{\partial w_i} \ln S_W(w_i) \right] \\ \frac{\partial^2 \ell}{\partial \mu^2} &= \frac{1}{\sigma^2} \sum_{i=1}^n \left[\delta_i \frac{\partial^2}{\partial w_i^2} \ln f_W(w_i) + (1 - \delta_i) \frac{\partial^2}{\partial w_i^2} \ln S_W(w_i) \right] \\ \frac{\partial^2 \ell}{\partial \sigma^2} &= \frac{D}{\sigma^2} + \frac{2}{\sigma^2} \left[\sum_{i=1}^n \delta_i w_i \frac{\partial}{\partial w_i} \ln f_W(w_i) + (1 - \delta_i) w_i \frac{\partial}{\partial w_i} \ln S_W(w_i) \right] \\ &\quad + \frac{1}{\sigma^2} \left[\sum_{i=1}^n \delta_i w_i^2 \frac{\partial^2}{\partial w_i^2} \ln f_W(w_i) + (1 - \delta_i) w_i^2 \frac{\partial^2}{\partial w_i^2} \ln S_W(w_i) \right] \\ \frac{\partial^2 \ell}{\partial \mu \partial \sigma} &= \frac{1}{\sigma^2} \left[\sum_{i=1}^n \delta_i \frac{\partial}{\partial w_i} \ln f_W(w_i) + (1 - \delta_i) \frac{\partial}{\partial w_i} \ln S_W(w_i) \right] \\ &\quad + \frac{1}{\sigma^2} \left[\sum_{i=1}^n \delta_i w_i \frac{\partial^2}{\partial w_i^2} \ln f_W(w_i) + (1 - \delta_i) w_i \frac{\partial^2}{\partial w_i^2} \ln S_W(w_i) \right]. \end{aligned}$$

Dado que $\hat{\mu}$ y $\hat{\sigma}$ satisfacen las ecuaciones $\frac{\partial \ell}{\partial \mu} = 0$ y $\frac{\partial \ell}{\partial \sigma} = 0$, el primer término de $\frac{\partial^2 \ell}{\partial \mu \partial \sigma}$ es igual a 0 en $(\hat{\mu}, \hat{\sigma})$, y el segundo término en $\frac{\partial^2 \ell}{\partial \sigma^2}$ es igual a $-2D/\hat{\sigma}^2$.

Bajo n grande la distribución conjunta de $(\hat{\mu}, \hat{\sigma})$ es aproximadamente normal con media (μ, σ) y matriz de varianzas y covarianzas $\Sigma = \mathcal{I}^{-1}(\theta)$ con $\mathcal{I}_{ij}(\theta) = -E \left[\frac{\partial^2 \ell(\theta)}{\partial \theta_i \partial \theta_j} \right]$, $j = 1, 2$ siendo $\theta_1 = \mu$ y $\theta_2 = \sigma$. La estimación de la matriz de varianzas y covarianzas viene dada por $\hat{\Sigma} = I^{-1}(\hat{\mu}, \hat{\sigma})$, donde I es la matriz de información observada

$$I(\mu, \sigma) = \begin{bmatrix} -\frac{\partial^2 \ell}{\partial \mu^2} & -\frac{\partial^2 \ell}{\partial \mu \partial \sigma} \\ -\frac{\partial^2 \ell}{\partial \sigma \partial \mu} & -\frac{\partial^2 \ell}{\partial \sigma^2} \end{bmatrix}.$$

Por tanto $ee(\hat{\mu}) = \hat{\Sigma}_{11}^{1/2}$ y $ee(\hat{\sigma}) = \hat{\Sigma}_{22}^{1/2}$. Para probar $H_0 : \mu = 0$ ante la alternativa de interés, se usa el estadístico $T = \hat{\mu}/\hat{ee}(\hat{\mu})$ que se aproxima a una normal estándar cuando n es grande. Por otra parte, un intervalo de confianza al $100(1 - \alpha) \%$ para μ viene dado por:

$$\hat{\mu} - z_{\alpha/2} ee(\hat{\mu}) < \mu < \hat{\mu} + z_{\alpha/2} ee(\hat{\mu}).$$

Un intervalo para σ que se mueva en un soporte positivo puede obtenerse de la cantidad pivotal:

$$\frac{\ln \hat{\sigma} - \ln \sigma}{ee(\ln \hat{\sigma})},$$

que es aproximadamente normal estándar cuando n grande, y donde por (2.10) $\text{Var}(\ln \hat{\sigma}) = \frac{1}{\sigma^2} \text{Var}(\hat{\sigma})$, y $ee(\ln \hat{\sigma}) = ee(\hat{\sigma})/\sigma$. De la cantidad pivotal se obtiene un intervalo para $\ln \sigma$ y de aquí uno para σ :

$$\begin{aligned} \ln \hat{\sigma} - z_{\alpha/2} ee(\ln \hat{\sigma}) &< \ln \sigma < \ln \hat{\sigma} + z_{\alpha/2} ee(\ln \hat{\sigma}) \\ \hat{\sigma} e^{-z_{\alpha/2} ee(\ln \hat{\sigma})} &< \sigma < \hat{\sigma} e^{z_{\alpha/2} ee(\ln \hat{\sigma})}. \end{aligned}$$

4.2. Modelo de Regresión de Weibull

Omitiendo covariantes en (4.1) tenemos que $Y = \ln T = \mu + \sigma W$ y si W tiene distribución valor extremo estándar, entonces $f(w) = \exp(w - \exp(w))$ y $S(w) = \exp(-\exp(w))$, y por tanto de (4.3) y (4.4):

$$\begin{aligned} f_Y(y) &= \frac{1}{\sigma} f_W\left(\frac{y - \mu}{\sigma}\right) = \frac{1}{\sigma} \exp^{\frac{y - \mu}{\sigma} - \exp^{\frac{y - \mu}{\sigma}}} \\ S_Y(y) &= S_W\left(\frac{y - \mu}{\sigma}\right) = \exp^{-\exp^{\frac{y - \mu}{\sigma}}}. \end{aligned}$$

La verosimilitud y la matriz de información en $(\hat{\mu}, \hat{\sigma})$ quedan de la forma:

$$L(\mu, \sigma | y'_i, \delta_i) = \prod_{i=1}^n \left[\frac{1}{\sigma} \exp^{\frac{y'_i - \mu}{\sigma} - \exp^{\frac{y'_i - \mu}{\sigma}}} \right]^{\delta_i} \left[\exp^{-\exp^{\frac{y'_i - \mu}{\sigma}}} \right]^{1 - \delta_i} \quad (4.8)$$

$$I(\hat{\mu}, \hat{\sigma}) = \frac{1}{\sigma^2} \begin{bmatrix} D & \sum_{i=1}^n w_i e^{w_i} \\ \sum_{i=1}^n w_i e^{w_i} & D + \sum_{i=1}^n w_i^2 e^{w_i} \end{bmatrix}.$$

Maximizando $\ell = \ln L$ e invirtiendo $I(\hat{\mu}, \hat{\sigma})$ obtenemos estimaciones de μ y σ con sus varianzas. Para incluir covariantes en el modelo, reemplazamos μ por $\mu + \gamma^T Z$, así μ pasaría de jugar el papel de media de Y al rol de intercepto en el modelo de $Y | Z$. La dimensionalidad de la verosimilitud y de la matriz de información aumentan. En el caso de la verosimilitud se tiene que:

$$L(\mu, \sigma, \gamma | y'_i, \delta_i, z_i) = \prod_{i=1}^n \left[\frac{1}{\sigma} \exp \frac{y'_i - \mu - \gamma^T z_i}{\sigma} - \exp \frac{y'_i - \mu - \gamma^T z_i}{\sigma} \right]^{\delta_i} \left[\exp - \exp \frac{y'_i - \mu - \gamma^T z_i}{\sigma} \right]^{1 - \delta_i}. \quad (4.9)$$

Como el objetivo de la regresión es estimar el modelo de sobrevivencia de T , una vez estimados los parámetros del modelo log-lineal, son incluidos en (4.6). La representación de la sobrevivencia en este paso, no permite identificar con claridad el tipo de distribución que representa, lo que se consigue con unas transformaciones en los parámetros, así:

$$S_T(t | Z) = e^{-e^{\frac{\ln t - \mu - \gamma^T Z}{\sigma}}} = e^{-t^{1/\sigma} e^{-\mu/\sigma} e^{\frac{-\gamma^T Z}{\sigma}}} = e^{-\rho t^\alpha e^{\beta^T Z}}, \quad (4.10)$$

con $\alpha = 1/\sigma$, $\rho = e^{-\mu/\sigma}$ y $\beta = -\gamma^T/\sigma$. Si $Z = 0$ y de acuerdo con (1.26), se ve claramente que la supervivencia anterior corresponde a la de una Weibull(α, ρ), con α un parámetro de forma y ρ un parámetro de escala. Para la función de riesgo tenemos la siguiente representación

$$h_T(t | Z) = \frac{d}{dt} - \ln S_T(t | Z) = \frac{d}{dt} \rho t^\alpha e^{\beta^T Z} = \rho \alpha t^{\alpha-1} e^{\beta^T Z}. \quad (4.11)$$

Nótese que en la última parte de (4.11), si $Z = 0$ entonces $e^{\beta^T Z} = 1$ y $h_T(t | Z)$ queda expresada en términos del riesgo de una Weibull. Por tanto en (4.11) se tiene el riesgo de una Weibull expandido por el factor de covariantes $e^{\beta^T Z}$. Si notamos por $h_0(t) = \rho \alpha t^{\alpha-1}$, entonces

$$h(t | Z) = h_0(t) e^{\beta^T Z}. \quad (4.12)$$

Si solo hay una covariante binaria en el modelo y tomamos el riesgo relativo del evento con respecto a ambos valores de la variable, esto es,

$$\frac{h(t \mid Z = 1)}{h(t \mid Z = 0)} = e^\beta,$$

entonces como el resultado no depende de t , se dice que los riesgos son proporcionales en el tiempo, por lo que el modelo se conoce como modelo de riesgos proporcionales. De forma general el factor $e^{\beta^T Z}$ permite obtener el riesgo relativo del evento frente a distintas alternativas que tome una covariante Z .

En conclusión, si W sigue una distribución valor extremo estándar, entonces T sigue una distribución Weibull y el modelo (4.1) se puede representar como un modelo riesgos proporcionales, siendo el único modelo totalmente paramétrico que admite esta representación.

Si h_0 se modela de forma no paramétrica, se tiene entonces un modelo semiparamétrico conocido como el modelo de Cox de riesgos proporcionales. Por la flexibilidad que da al modelo la estimación no paramétrica de h_0 , el modelo se ha convertido en objeto de investigación en las últimas décadas. Una presentación más detallada se hace en el siguiente capítulo.

Para determinar las varianzas de los estimadores transformados α , ρ y β , recurrimos al método delta como se ilustra en la siguiente sección. No obstante, las estimaciones y sus varianzas se pueden obtener estableciendo directamente los estimadores en la verosimilitud. Así, (4.9) puesta en términos del riesgo y la sobrevivencia de T y de los parámetros α , ρ y β queda así:

$$L(\alpha, \rho, \beta | y_i, \delta_i, z_i) = \prod_{i=1}^n h(y_i)^{\delta_i} S(y_i) = \prod_{i=1}^n \left[\rho \alpha y_i^{\alpha-1} e^{\beta^T Z} \right]^{\delta_i} \left[e^{-\rho y_i^\alpha e^{\beta^T Z}} \right], \quad (4.13)$$

donde $Y_i = \min(T_i, C_i)$ y $\delta_i = I(T_i \leq C_i)$. La maximización de $\ell = \ln L$ basada en formas del método de Newton-Rhapson como el Fisher's Scoring, arroja una aproximación de la matriz hessiana, y de aquí se obtiene la matriz de varianzas y covarianzas.

4.2.1. Varianza de los Estimadores Weibull

Del método delta tenemos que si abreviadamente representamos a $g(\hat{\theta})$ alrededor de θ tenemos que $g(\hat{\theta}) = g(\theta) + g'(\theta)(\hat{\theta} - \theta) + \dots$, y por tanto $\text{Var} [g(\hat{\theta})] = \text{E} \left[(g(\hat{\theta}) - g(\theta))^2 \right] \approx (g'(\theta))^2 \text{E} \left[(\hat{\theta} - \theta)^2 \right] = (g'(\theta))^2 \text{Var} (\hat{\theta})$.

El resultado aplica a distribuciones de T que tienen un solo parámetro, como en el caso de la exponencial, donde $\sigma = 1$ y la distribución de Y depende solo de μ , y T de $\rho = g(\mu) = \exp(-\mu)$, así,

$$\text{Var}(\hat{\rho}) \approx \left\{ \frac{\partial g}{\partial \mu} \right\}^2 \text{Var}[\hat{\mu}] = \exp(-2\mu) \text{Var}(\hat{\mu}).$$

En el caso de distribuciones de Y con dos parámetros entonces la distribución de W tendrá así mismo dos parámetros. Si la regresión es sin covariantes, con $Y = \mu + \sigma W$, entonces dado que $\alpha = 1/\sigma$:

$$\text{Var}(\hat{\alpha}) = \text{Var}(1/\hat{\sigma}) = \left(\frac{-1}{\sigma^2} \right)^2 \text{Var}(\hat{\sigma}) = \frac{1}{\sigma^4} \text{Var}(\hat{\sigma}). \quad (4.14)$$

El resultado no puede ser aplicado para la varianza de $\hat{\rho} = e^{-\hat{\mu}/\hat{\sigma}}$ pues es una transformación de dos estimadores. Debemos entonces extender el método para que se tenga en consideración la variación de los dos estimadores y la covariación con $\hat{\alpha}$. El método delta para dos transformaciones está basado en la siguiente expansión

$$g_k(\hat{\theta}_1, \hat{\theta}_2) = g_k(\theta_1, \theta_2) + (\hat{\theta}_1 - \theta_1) \frac{\partial g_k(\theta_1, \theta_2)}{\partial \theta_1} + (\hat{\theta}_2 - \theta_2) \frac{\partial g_k(\theta_1, \theta_2)}{\partial \theta_2} + \dots$$

Las funciones g_1 y g_2 definen las transformaciones de los nuevos estimadores basados en $\hat{\theta}_1$ y $\hat{\theta}_2$. Las varianzas de cada transformación ($k = 1; 2$) y su covarianza son

$$\begin{aligned} \text{Var} \left[g_k(\hat{\theta}_1, \hat{\theta}_2) \right] &= \text{E} \left[g_k(\hat{\theta}_1, \hat{\theta}_2) - g_k(\theta_1, \theta_2) \right]^2 \\ &\approx \left[\frac{\partial g_k(\theta_1, \theta_2)}{\partial \theta_1} \right]^2 \text{Var}(\hat{\theta}_1) + \left[\frac{\partial g_k(\theta_1, \theta_2)}{\partial \theta_2} \right]^2 \text{Var}(\hat{\theta}_2) \\ &\quad + 2 \frac{\partial g_k(\theta_1, \theta_2)}{\partial \theta_1} \frac{\partial g_k(\theta_1, \theta_2)}{\partial \theta_2} \text{Cov}(\hat{\theta}_1, \hat{\theta}_2). \end{aligned} \quad (4.15)$$

$$\text{Cov}(g_1(\hat{\theta}_1, \hat{\theta}_2), g_2(\hat{\theta}_1, \hat{\theta}_2)) = \text{E} \left[\left(g_1(\hat{\theta}_1, \hat{\theta}_2) - g_1(\theta_1, \theta_2) \right) \left(g_2(\hat{\theta}_1, \hat{\theta}_2) - g_2(\theta_1, \theta_2) \right) \right],$$

$$\text{pero } g_k(\hat{\theta}_1, \hat{\theta}_2) - g_k(\theta_1, \theta_2) \approx (\hat{\theta}_1 - \theta_1) \frac{\partial g_k}{\partial \theta_1} + (\hat{\theta}_2 - \theta_2) \frac{\partial g_k}{\partial \theta_2}, \quad \text{luego}$$

$$\begin{aligned}
\text{Cov}(g_1(\hat{\theta}_1, \hat{\theta}_2), g_2(\hat{\theta}_1, \hat{\theta}_2)) &= E \left[\left((\hat{\theta}_1 - \theta_1) \frac{\partial g_1}{\partial \theta_1} + (\hat{\theta}_2 - \theta_2) \frac{\partial g_1}{\partial \theta_2} \right) \left((\hat{\theta}_1 - \theta_1) \frac{\partial g_2}{\partial \theta_1} + (\hat{\theta}_2 - \theta_2) \frac{\partial g_2}{\partial \theta_2} \right) \right] \\
&= \frac{\partial g_1}{\partial \theta_1} \frac{\partial g_2}{\partial \theta_1} \text{Var}(\hat{\theta}_1) + \frac{\partial g_1}{\partial \theta_1} \frac{\partial g_2}{\partial \theta_2} \text{Cov}(\hat{\theta}_1, \hat{\theta}_2) \\
&\quad + \frac{\partial g_1}{\partial \theta_2} \frac{\partial g_2}{\partial \theta_1} \text{Cov}(\hat{\theta}_1, \hat{\theta}_2) + \frac{\partial g_1}{\partial \theta_2} \frac{\partial g_2}{\partial \theta_2} \text{Var}(\hat{\theta}_2) \\
&= \frac{\partial g_1}{\partial \theta_1} \frac{\partial g_2}{\partial \theta_1} \text{Var}(\hat{\theta}_1) + \frac{\partial g_1}{\partial \theta_2} \frac{\partial g_2}{\partial \theta_2} \text{Var}(\hat{\theta}_2) \\
&\quad + \left(\frac{\partial g_1}{\partial \theta_1} \frac{\partial g_2}{\partial \theta_2} + \frac{\partial g_1}{\partial \theta_2} \frac{\partial g_2}{\partial \theta_1} \right) \text{Cov}(\hat{\theta}_1, \hat{\theta}_2).
\end{aligned} \tag{4.16}$$

El resultado aplicado sobre $\hat{\alpha} = g_1(\hat{\mu}, \hat{\sigma}) = 1/\hat{\sigma}$ y $\hat{\rho} = g_2(\hat{\mu}, \hat{\sigma}) = \exp(-\frac{\hat{\mu}}{\hat{\sigma}})$, con $\hat{\theta}_1 = \hat{\mu}$ y $\hat{\theta}_2 = \hat{\sigma}$ y donde $\hat{\rho}$ es una transformación bivariada y $\hat{\alpha}$ no, queda así

$$\text{Var}(\hat{\alpha}) = \text{Var}[g_1(\hat{\mu}, \hat{\sigma})] \approx (1/\sigma^2)^2 \text{Var}(\hat{\sigma}). \tag{4.17}$$

Como $\hat{\alpha}$ solo es transformación de $\hat{\sigma}$, su resultado es simple debido a que $\frac{\partial g_1}{\partial \mu} = 0$. Como es obvio, el resultado es el mismo a (4.14) donde se aplicó el método delta univariado.

$$\begin{aligned}
\text{Var}(\hat{\rho}) &\approx \left\{ \frac{\partial g_2}{\partial \mu} \right\}^2 \text{Var}[\hat{\mu}] + \left\{ \frac{\partial g_2}{\partial \sigma} \right\}^2 \text{Var}[\hat{\sigma}] + 2 \left\{ \frac{\partial g_2}{\partial \mu} \right\} \left\{ \frac{\partial g_2}{\partial \sigma} \right\} \text{Cov}[\hat{\mu}, \hat{\sigma}] \\
&= \left\{ \exp\left(\frac{-\mu}{\sigma}\right) \left(\frac{-1}{\sigma}\right) \right\}^2 \text{Var}[\hat{\mu}] + \left\{ \exp\left(\frac{-\mu}{\sigma}\right) \left(\frac{\mu}{\sigma^2}\right) \right\}^2 \text{Var}[\hat{\sigma}] \\
&\quad + 2 \left\{ \exp\left(\frac{-\mu}{\sigma}\right) \left(\frac{-1}{\sigma}\right) \right\} \left\{ \exp\left(\frac{-\mu}{\sigma}\right) \left(\frac{\mu}{\sigma^2}\right) \right\} \text{Cov}[\hat{\mu}, \hat{\sigma}] \\
&= \exp\left(\frac{-2\mu}{\sigma}\right) \left\{ \left(\frac{1}{\sigma^2}\right) \text{Var}[\hat{\mu}] + \left(\frac{\mu^2}{\sigma^4}\right) \text{Var}[\hat{\sigma}] - 2 \left(\frac{\mu}{\sigma^3}\right) \text{Cov}[\hat{\mu}, \hat{\sigma}] \right\}.
\end{aligned} \tag{4.18}$$

$$\begin{aligned}
\text{Cov}(\hat{\alpha}, \hat{\rho}) &\approx 0 + \left(\frac{-1}{\sigma^2}\right) \exp\left(\frac{-\mu}{\sigma}\right) \left(\frac{\mu}{\sigma^2}\right) \text{Var}[\hat{\sigma}] + \left[0 + \left(\frac{-1}{\sigma^2}\right) \exp\left(\frac{-\mu}{\sigma}\right) \left(\frac{-1}{\sigma}\right) \right] \text{Cov}(\hat{\mu}, \hat{\sigma}) \\
&= \frac{\exp\left(\frac{-\mu}{\sigma}\right)}{\sigma^4} \{-\mu \text{Var}[\hat{\sigma}] + \sigma \text{Cov}[\hat{\mu}, \hat{\sigma}]\}.
\end{aligned} \tag{4.19}$$

Si el modelo tiene covariantes, las varianzas de los estimadores $\hat{\alpha}$ y $\hat{\rho}$ y su covarianza por el método delta quedan de la misma forma como en (4.17)-(4.19) respectivamente, y las varianzas de $\hat{\beta}_k = -\hat{\gamma}_k/\hat{\sigma}$ y las covarianzas de

esos estimadores con los otros quedan así:

$$\text{Cov}(\hat{\beta}_j, \hat{\beta}_k) \approx \frac{\text{Cov}(\hat{\gamma}_j, \hat{\gamma}_k)}{\sigma^2} - \frac{\gamma_j \text{Cov}(\hat{\gamma}_j, \hat{\sigma})}{\sigma^3} - \frac{\gamma_k \text{Cov}(\hat{\gamma}_k, \hat{\sigma})}{\sigma^3} + \frac{\gamma_j \gamma_k \text{Var}(\hat{\sigma})}{\sigma^4}, \quad j, k = 1, \dots, p \quad (4.20)$$

$$\text{Cov}(\hat{\beta}_j, \hat{\alpha}) \approx \frac{\text{Cov}(\hat{\gamma}_j, \hat{\sigma})}{\sigma^3} - \frac{\gamma_j \text{Var}(\hat{\sigma})}{\sigma^4} \quad j = 1, \dots, p \quad (4.21)$$

$$\text{Cov}(\hat{\beta}_j, \hat{\rho}) \approx \exp\left(-\frac{\hat{\mu}}{\hat{\sigma}}\right) \left[\frac{\text{Cov}(\hat{\gamma}_j, \hat{\mu})}{\sigma^2} - \frac{\gamma_j \text{Cov}(\hat{\gamma}_j, \hat{\sigma})}{\sigma^3} - \frac{\mu \text{Cov}(\hat{\mu}, \hat{\sigma})}{\sigma^3} + \frac{\gamma_j \mu \text{Var}(\hat{\sigma})}{\sigma^4} \right] \quad j = 1, \dots, p \quad (4.22)$$

Ejemplo 4.2: Para la información del ejemplo 2.1 tenemos que el modelo $Y = \mu + \sigma W$, tiene las estimaciones $\hat{\mu} = 3,641$ y $\hat{\sigma} = 0,912$, y la matriz de información observada

$$I(\hat{\mu}, \hat{\sigma}) = \begin{bmatrix} 21,7 & 4,4 \\ 4,4 & 42,8 \end{bmatrix}.$$

Con base en la inversa de I se obtiene $\hat{\text{Var}}(\hat{\mu}) = 0,0471$, $\hat{\text{Var}}(\hat{\sigma}) = 0,0239$ y $\hat{\text{Cov}}(\hat{\mu}, \hat{\sigma}) = -0,0048$. El cociente $\hat{\mu}/\hat{e}e(\hat{\mu}) = 16,8$ indica el rechazo de la prueba $H_0 : \mu = 0$.

La hipótesis $H_0 : \sigma = 0$ no es procedente pues indirectamente afirma que la información es constante. Probar $H_0 : \ln \sigma = 0$ equivale a probar $H_0 : \sigma = 1$. En la Weibull si $\sigma = 1$ se obtiene una distribución exponencial, no obstante, al aceptar $H_0 : \sigma = 1$ no se está probando que los datos provienen de una exponencial, eso depende de la capacidad de la exponencial de interpretar el comportamiento de los datos, cosa que la prueba no analiza. Hay que tener en cuenta que las pruebas de bondad de ajuste evalúan una distribución en el conjunto de sus parámetros. Con base en los resultados tenemos que $\hat{\text{Var}}(\ln \hat{\sigma}) = \hat{\text{Var}}(\hat{\sigma})/\hat{\sigma}^2 = 0,0239/0,912^2 = 0,0287$ y por tanto $\hat{e}e(\ln \hat{\sigma}) = 0,169$ y $\ln \hat{\sigma}/\hat{e}e(\ln \hat{\sigma}) = -0,092/0,169 = -0,54$, con lo que se concluye que $H_0 : \sigma = 1$ no puede ser rechazada. Hay que tener en cuenta que dado lo pequeño de la muestra, los resultados asintóticos de la estimación máximo verosímil no están garantizados. La estimación de los parámetros de la Weibull, sus varianzas estimadas y su covarianza son:

$$\hat{\alpha} = 1/\hat{\sigma} = 1/0,9119 = 1,097$$

$$\hat{\text{Var}}(\hat{\alpha}) = 1/\hat{\sigma}^4 * \hat{\text{Var}}(\hat{\sigma}) = 1/(0,912^4) * 0,0239 = 0,0345$$

$$\begin{aligned}
\hat{\rho} &= \exp(-\hat{\mu}/\hat{\sigma}) = \exp(-3,642/0,9119) = 0,0184 \\
\hat{V}\text{ar}(\hat{\rho}) &\approx \exp\left(\frac{-2\hat{\mu}}{\hat{\sigma}}\right) \left\{ \left(\frac{1}{\hat{\sigma}^2}\right) \hat{V}\text{ar}[\hat{\mu}] + \left(\frac{\hat{\mu}^2}{\hat{\sigma}^4}\right) \hat{V}\text{ar}[\hat{\sigma}] - 2\left(\frac{\hat{\mu}}{\hat{\sigma}^3}\right) \hat{C}\text{ov}[\hat{\mu}, \hat{\sigma}] \right\} \\
&= \exp\left(\frac{-2 * 3,641}{0,912}\right) \left\{ \left(\frac{1}{0,912^2}\right) 0,0471 + \left(\frac{3,641^2}{0,912^4}\right) 0,0239 - 2\left(\frac{3,641}{0,912^3}\right) (-0,0048) \right\} \\
&= 0,00019 \\
\hat{C}\text{ov}(\hat{\alpha}, \hat{\rho}) &\approx \frac{\exp\left(\frac{-\hat{\mu}}{\hat{\sigma}}\right)}{\hat{\sigma}^4} \left\{ -\hat{\mu} \hat{V}\text{ar}[\hat{\sigma}] + \hat{\sigma} \hat{C}\text{ov}[\hat{\mu}, \hat{\sigma}] \right\} \\
&= \frac{\exp\left(\frac{-3,641}{0,912}\right)}{0,912^4} \{-3,6410,0239 + 0,912(-0,0048)\} \\
&= -0,00243. \quad \triangle
\end{aligned}$$

Ejemplo 4.3: Con la información del ejemplo 2.1 tenemos el siguiente modelo Weibull estimado, donde la covariante Z toma los valores 1 para el grupo de terapia de mantenimiento y 0 para el grupo control.

$$\hat{y}_i = \hat{\mu} + \hat{\gamma} z_i = 3,180 + 0,929 z_i, \quad \text{con} \quad \hat{\sigma} = 0,791$$

Dado que $\hat{e}e(\hat{\gamma}) = 0,383$ la hipótesis $H_0 : \gamma = 0$ frente a una alternativa bilateral, se rechaza al 5 % ($p - \text{valor} = 0,00151$).

Factor de aceleración: $e^{-\hat{\gamma}} * M_1 = e^{-0,929} * M_1 = 0,395 * M_1 = M_0$ con M_1 la mediana del grupo terapia de mantenimiento y $e^{-\hat{\gamma}} = 0,395$ el factor de aceleración. También tenemos que: $M_1 = 2,53 * M_0$, esto es, el tiempo mediano a la quimioterapia de pacientes con terapia de mantenimiento es 2,53 veces el tiempo mediano del grupo control (sin terapia de mantenimiento).

Riesgo relativo: $e^{\hat{\beta}} = e^{-\hat{\gamma}/\hat{\sigma}} = e^{-0,929/0,791} = 0,309$. El riesgo de quimioterapia del grupo terapia de mantenimiento es 0,309 veces el riesgo del grupo control. También podemos decir que el riesgo de quimioterapia del grupo control es 3,24 ($1/0,309$) veces el riesgo del grupo terapia de mantenimiento.

Parámetro del modelo loglineal: $\hat{\gamma} = 0,929$. Al pasar de no tener terapia de mantenimiento a tenerla, el tiempo a quimio aumenta en 92,9 %.

Los parámetros del riesgo Weibull $h(t | Z)$: $\hat{\alpha} = 1/\hat{\sigma} = 1,2643$, $\hat{\rho} = e^{-\hat{\mu}/\hat{\sigma}} = 0,018$ y $\hat{\beta} = -\hat{\gamma}/\hat{\sigma} = -1,175$, por sí mismos no se interpretan. Sus errores estándar obtenidos con base en el método de fisher-scoring son 0,160, 0,0037 y 0,462 respectivamente. $\triangle$

4.3. Modelo de Regresión Log-Logístico

Si W tiene distribución logística estándar entonces $S(w) = (1 + e^w)^{-1}$ y $f(w) = e^w * (1 + e^w)^{-2}$ y por tanto si Y se define como en (4.1), entonces las funciones de densidad y supervivencia de Y , y la función de verosimilitud basada en ellas son

$$f_Y(y | Z) = \frac{1}{\sigma} f_W \left(\frac{y - \mu - \gamma^T Z}{\sigma} \right) = \frac{1}{\sigma} \frac{\exp \left(\frac{y - \mu - \gamma^T Z}{\sigma} \right)}{\left(1 + \exp \left(\frac{y - \mu - \gamma^T Z}{\sigma} \right) \right)^2}$$

$$S_Y(y | Z) = S_W \left(\frac{y - \mu - \gamma^T Z}{\sigma} \right) = \frac{1}{1 + \exp \left(\frac{y - \mu - \gamma^T Z}{\sigma} \right)}$$

$$L(\mu, \sigma, \gamma | y'_i, \delta_i, z_i) = \prod_{i=1}^n \left[\frac{1}{\sigma} \frac{\exp \left(\frac{y'_i - \mu - \gamma^T z_i}{\sigma} \right)}{\left(1 + \exp \left(\frac{y'_i - \mu - \gamma^T z_i}{\sigma} \right) \right)^2} \right]^{\delta_i} \left[\frac{1}{1 + \exp \left(\frac{y'_i - \mu - \gamma^T z_i}{\sigma} \right)} \right]^{1 - \delta_i}.$$

Tenemos dos expresiones de las funciones de T , una con los parámetros μ , σ y γ y otra a partir de la reparametrización $\alpha = 1/\sigma$, $\rho = e^{-\frac{\mu}{\sigma}}$ y $\beta = -\gamma/\sigma$.

$$\exp \left(\frac{\ln t - \mu - \gamma^T z}{\sigma} \right) = t^{1/\sigma} e^{-\frac{\mu}{\sigma}} e^{-\frac{\gamma^T z}{\sigma}} = t^\alpha \rho e^{\beta^T z}$$

$$f_T(t | Z) = \frac{1}{t\sigma} f_W \left(\frac{\ln t - \mu - \gamma^T Z}{\sigma} \right) = \frac{\rho \alpha t^{\alpha-1} e^{\beta^T Z}}{(1 + \rho t^\alpha e^{\beta^T Z})^2}$$

$$S_T(t | Z) = S_W \left(\frac{\ln t - \mu - \gamma^T Z}{\sigma} \right) = \frac{1}{1 + \rho t^\alpha e^{\beta^T Z}}$$

El modelo de regresión log-logístico admite una representación de odds proporcionales, donde se establece una relación de proporcionalidad entre las odds del evento bajo unas covariantes Z y las odds cuando las covariantes valen cero. La odds en referencia es:

$$\frac{\text{Probabilidad de No Evento Antes de } t}{\text{Probabilidad del Evento Antes de } t} = \frac{S(t | Z)}{1 - S(t | Z)} = e^{-\beta Z} \frac{1}{\rho t^\alpha} = e^{-\beta Z} \frac{S(t | Z = 0)}{1 - S(t | Z = 0)}$$

Por tanto $\exp(-\beta Z)$ expresado en la siguiente ecuación, permite obtener una estimación de cuánto la odds basal de sobrevivencia cambia cuando un individuo tiene un valor de covariante $Z \neq 0$, esto es

$$e^{-\beta Z} = \frac{\frac{S(t|Z)}{1-S(t|Z)}}{\frac{S(t|Z=0)}{1-S(t|Z=0)}}$$

Ejemplo 4.4: Con la información del ejemplo 2.1 tenemos el siguiente modelo log-logístico estimado, donde la covariante Z toma los valores 1 para el grupo de terapia de mantenimiento y 0 para el grupo control.

$$\hat{y}_i = \hat{\mu} + \hat{\gamma} z_i = 2,9 + 0,6 z_i, \quad \text{con} \quad \hat{\sigma} = 0,513$$

Debido a que el modelo log-logístico resulta ser el modelo más apropiado para modelar T según valoraciones de bondad de ajuste realizadas anteriormente, los resultados e interpretaciones obtenidos con base en este son los que deben ser adoptados, antes que el del modelo Weibull u otros de los analizados hasta este punto.

Factor de aceleración: $e^{-\hat{\gamma}} * M_1 = e^{-0,6} * M_1 = 0,54 * M_1 = M_0$ con M_1 la mediana del grupo terapia de mantenimiento y $e^{-\hat{\gamma}} = 0,54$ el factor de aceleración. También tenemos que: $M_1 = 1,8 * M_0$, esto es, el tiempo mediano a la quimioterapia de pacientes con terapia de mantenimiento es 1,8 veces el tiempo mediano del grupo control (sin terapia de mantenimiento).


Odds proporcionales: $e^{-\hat{\beta}*(Z=1)} = e^{\hat{\gamma}/\hat{\sigma}} = e^{0,6/0,51} = 3,2$. Como la odds es el cociente $\text{Pr}(\text{No Recaer}) / \text{Pr}(\text{Recaer})$, entonces el chance (la odds) de no recaer del grupo terapia alternativa es 3,2 veces el de la terapia estándar.

Parámetro del modelo loglineal: $\hat{\gamma} = 0,6$. Al pasar de no tener terapia de mantenimiento a tenerla, el tiempo a quimio aumenta en 60 %. El error estándar de estimación de la estimación es 0,393, por tanto la hipótesis $H_0 : \gamma = 0$ no puede ser rechazada frente a una alternativa bilateral ($p\text{-valor} = 0,124$). Por tanto, concluimos que la diferencia del tiempo a quimioterapia entre los dos grupos, quimioterapia de mantenimiento y grupo control, no es significativa.

Los parámetros del riesgo log-logístico $h(t | Z)$ son: $\hat{\alpha} = 1/\hat{\sigma} = 1,949$, $\hat{\rho} = e^{-\hat{\mu}/\hat{\sigma}} = 0,0035$ y $\hat{\beta} = -\hat{\gamma}/\hat{\sigma} = -1,177$, y sus errores estándar obtenidos con base en el método de fisher-scoring son 0,231, 0,002 y 0,768 respectivamente.

En la figura 4.1 se muestra la estimación kernel del riesgo global junto al riesgo por tipo de terapia. Es clara la característica de riesgos monótonos y proporcionales para el modelo Weibull. El modelo log-logístico sigue de cerca la tendencia en forma de joroba del riesgo kernel. A pesar que se aprecia una diferencia marcada en el riesgo al evento por tipo de terapia en tiempos menores, debemos tener en cuenta que con el tamaño de muestra analizado, dicha diferencia no resultó significativa ($p\text{-valor} = 0,124$). De todas formas de optarse por una medición paramétrica del riesgo, la opción log-logística es la recomendada.

Figura 4.1: Modelos de Riesgo para el Tiempo Hasta Final del Estado de Remisión: No Paramétrico Kernel ($h=50$) y de Regresión Weibull y Loglogístico, por Tipo de Terapia.



△

4.4. Modelo de Regresión Log-Normal

Se asume para W una distribución normal estándar, por tanto Y tendrá una distribución normal de media μ y varianza σ^2 , y T tendrá una distribución log-normal. La distribución de T no se reparametriza y queda también en términos de μ , σ y γ . Como la estimación de los parámetros del modelo puede hacerse indistintamente con base en las funciones de Y o T , entonces seguidamente se presentan dichas funciones para T con la verosimilitud basada en ellas.

$$f(t) = \frac{1}{t\sigma} f_W\left(\frac{\ln t - \mu - \gamma^T Z}{\sigma}\right) = \frac{1}{t\sigma} \Phi\left(\frac{\ln t - \mu - \gamma^T Z}{\sigma}\right) = \frac{1}{\sigma t \sqrt{2\pi}} \exp\left(-0,5 \left(\frac{\ln t - \mu - \gamma^T Z}{\sigma}\right)^2\right) \quad (4.23)$$

$$S(t) = S_W\left(\frac{\ln t - \mu - \gamma^T Z}{\sigma}\right) = 1 - \Phi\left(\frac{\ln t - \mu - \gamma^T Z}{\sigma}\right) \quad (4.24)$$

$$L(\mu, \sigma, \gamma | y'_i, \delta_i, z_i) = \prod_{i=1}^n \left[\frac{1}{\sigma t \sqrt{2\pi}} \exp\left(-0,5 \left(\frac{\ln y'_i - \mu - \gamma^T Z}{\sigma}\right)^2\right) \right]^{\delta_i} \left[1 - \Phi\left(\frac{\ln y'_i - \mu - \gamma^T Z}{\sigma}\right) \right]^{1-\delta_i},$$

con $Y'_i = \min(T_i, C_i)$ y siendo Φ la distribución normal estándar acumulada. A diferencia de los modelos Weibull y log-logístico donde hay una interpretación adicional sobre la estimación del factor e^β o $e^{-\beta}$, en este caso no la hay. La interpretación de los parámetros quedan sólo en términos del factor de aceleración $e^{-\gamma}$, y de γ dentro del contexto general de los modelos “log-lin”.

5. EL MODELO DE COX DE RIESGOS PROPORCIONALES

El modelo de Cox modela la función de riesgo condicional en unas covariantes. Los trabajos de Cox en general, y en particular el trabajo *Regression Models and Life Tables* publicado en el año 1972 en el *Journal of the Royal Statistical Society (Serie B)*, son los pioneros de esta metodología.

Al conjunto de covariantes o factores pronóstico del riesgo se denota por $Z = (Z_1, \dots, Z_p)$ y se refiere a este como el perfil del individuo. Se define la función de riesgo basal o subyacente, $h_0(t)$, como la función de riesgo correspondiente a un individuo cuyos valores en las covariantes son iguales a cero, es decir con perfil $Z = 0$. El modelo general de Cox relaciona la función de riesgo $h(t | Z)$ en el momento t de un individuo con perfil Z con la función de riesgo en el mismo momento de un individuo con perfil $Z=0$ mediante la expresión:

$$h(t | Z) = h_0(t)\psi(Z; \beta), \quad (5.1)$$

con β un vector de parámetros. La parametrización log-lineal $\psi(Z; \beta) = \exp(\beta^T Z)$ es la más popular, pues asegura que $h(t | Z)$ es no negativo sin necesidad de añadir restricciones a los parámetros. El modelo es entonces:

$$h(t | Z) = h_0(t) \exp(\beta^T Z). \quad (5.2)$$

La función de riesgo subyacente o basal $h_0(t)$, puede tomar cualquier forma, por este motivo se dice que el modelo de Cox es de naturaleza semiparamétrica. De acuerdo con (1.9), el modelo en términos de la función de supervivencia es:

$$S(t | Z) = [S_0(t)]^{\exp(\beta^T Z)} \quad (5.3)$$

La mención de modelo de riesgos proporcionales como se indicó previamente, se debe al hecho que para dos individuos con covariantes Z_1 y Z_2 , la razón de sus riesgos es una contante que no depende del tiempo:

$$\frac{h(t | Z_1)}{h(t | Z_2)} = \frac{h_0(t) \exp(\beta_1^T Z_1)}{h_0(t) \exp(\beta_2^T Z_2)} = \exp(\beta_1^T Z_1 - \beta_2^T Z_2)$$

En este modelo la distribución del error no está especificada y permite que los datos hablen por ellos mismos. El factor $\exp(\beta_1 Z_1 + \beta_2 Z_2 + \cdots + \beta_p Z_p)$ corresponde al riesgo relativo de un individuo con perfil Z respecto de un individuo con perfil $Z = 0$, y expresa cuántas veces es mayor la probabilidad de padecer un evento con un perfil Z que con un perfil $Z = 0$. Una forma equivalente de plantear el modelo es mediante la transformación logarítmica sobre la razón de riesgos:

$$\log \left(\frac{h(t | Z)}{h_0(t)} \right) = \beta_1 Z_1 + \beta_2 Z_2 + \cdots + \beta_p Z_p \quad (5.4)$$

La cantidad $\eta = \beta_1 Z_1 + \beta_2 Z_2 + \cdots + \beta_p Z_p$ se conoce como el índice pronóstico o risk score. Nótese que no hay término constante ya que este lo absorbe $h_0(t)$. El logaritmo del cociente de las funciones de riesgo se relaciona linealmente con los factores pronóstico, mientras que en una regresión lineal es la media de la variable respuesta la que se relaciona linealmente con los factores pronóstico.

Si intuitivamente se entiende que $p = h(t | Z)$ representa la probabilidad de morir en el intervalo $(t, t + \Delta t)$ dado que se está vivo en t , y si se supone que p es muy pequeño, entonces $p/(1 - p) = p = h(t | Z)$, y el modelo de Cox podría interpretarse como un modelo de regresión logística:

$$\log \left(\frac{p}{1 - p} \right) = \alpha + \beta_1 Z_1 + \beta_2 Z_2 + \cdots + \beta_p Z_p \quad (5.5)$$

Si se cuenta con una covariante Z y dos individuos con valores respectivos z_1 y z_2 , el cociente de los riesgos en el tiempo t es $h(t | z_1)/h(t | z_2) = \exp(\beta(z_1 - z_2))$. Si la covariante es 1 cuando el individuo ha recibido el tratamiento A y es 0 cuando el individuo ha recibido el tratamiento B , y si se comparan dos individuos uno de cada tratamiento, se tiene que $h(t | Z = 1)/h(t | Z = 0) = e^{\beta(1-0)} = e^\beta$. Por consiguiente si $e^\beta > 1$ ($\beta > 0$),

el riesgo de evento es más alto para $Z = 1$, es decir bajo el tratamiento A . Análogamente, si $e^\beta < 1$ ($\beta < 0$), el riesgo de evento es más alto para $Z = 0$, es decir bajo el tratamiento B , y por tanto indica que el tratamiento A es superior. Si $e^\beta = 1$ ($\beta = 0$) indica que no hay diferencia entre los tratamientos.

En caso que existan más variables, la comparación de los riesgos por los niveles de una covariante, asume que las demás son iguales entre los grupos. Por ejemplo si existen 3 covariantes, y la primera es el género que se desea comparar en términos del evento de muerte, la razón de riesgos codificando con 1 a la mujer y con 0 al hombre, es:

$$\frac{h(t \mid \text{mujer})}{h(t \mid \text{hombre})} = \frac{h_0(t) \exp(\beta_1 + \beta_2 Z_2 + \beta_3 Z_3)}{h_0(t) \exp(\beta_2 Z_2 + \beta_3 Z_3)} = e^{\beta_1}$$

si $\beta_1 = 1,5$, el riesgo de muerte de una mujer con características particulares z_2 y z_3 , es $e^{1,5} = 4,5$ veces mayor que el de un hombre de las mismas características.

La función de riesgo puede depender de variables y de factores. Las variables toman valores numéricos y se incorporan en el modelo asignando a cada una de ellas un coeficiente β . En este caso la función basal $h_0(t)$ se refiere a un individuo con valores de las covariables iguales a cero. Los factores toman un número limitado de a niveles y se incorporan en el modelo con $a - 1$ coeficientes α_j , que se conocen como los efectos principales del factor A . La función de riesgo para un individuo con el factor A en el nivel j es $e^{\alpha_j} h_0(t)$ y por tanto e^{α_j} es el riesgo de tener el factor A en el nivel j respecto del riesgo de tenerlo en el nivel 1.

Cuando el riesgo de un evento por los niveles de un factor es diferente en los niveles de otro, se dice que hay interacción entre estos dos factores y la función de riesgo depende de la combinación de los niveles de los dos factores. Por ejemplo, si un factor es el género (Z_1) y si la presencia o ausencia de una proteína (Z_2) sobre el riesgo de muerte fuese diferente en pacientes de cada sexo, entonces se incorpora en el modelo el término $\gamma_{12} z_1 z_2$. En general, a las llamadas interacciones de segundo orden para dos factores A y B con a y b niveles de factor respectivamente, les corresponde $(a - 1)(b - 1)$ parámetros γ . En general, un término de interacción sólo se incluye si se han incluido previamente los efectos principales.

5.1. Estimación de Parámetros para Muestras con Censura por la Derecha

En el modelo de Cox para muestras censuradas por la derecha se supone que los tiempos T_i se relacionan con las covariantes Z_i mediante los riesgos proporcionales. Las variables censura C_i pueden estar relacionadas con las covariantes Z_i de cualquier forma, sin embargo se supone que las variables aleatorias T_i y C_i son condicionalmente independientes dado Z_i (condición de no informatividad).

La estimación completa del modelo de riesgos proporcionales a partir de la observación de las ternas (Y_i, δ_i, Z_i) , $i = 1, \dots, n$, donde Y_i es el mínimo entre el tiempo hasta el evento y el valor censurado, δ_i es el indicador de censura y Z_i el vector de covariantes, requiere los siguientes dos pasos:

- La estimación de los parámetros β_j .
- La estimación de la función de riesgo basal $h_0(t)$ mediante la función de verosimilitud condicionada a los valores estimados $\hat{\beta}_j$.

La estimación de los parámetros β_j , se hace mediante la llamada función de verosimilitud parcial $L(\beta)$, que genera estimadores que cumplen, en general, las buenas propiedades características del método de máxima verosimilitud. En la década de los 70 se dio lugar a una controversia en la aplicación de esta metodología debido a la definición de la función de verosimilitud parcial, surgida de la naturaleza semiparamétrica del problema. Asumiendo que no hay empates la función de verosimilitud parcial en la cual h_0 no aparece es:

$$L(\beta) = \prod_{i=1}^n \left(\frac{\exp(\beta^T Z_i)}{\sum_{j \in R(t_i)} \exp(\beta^T Z_j)} \right)^{\delta_i}, \quad (5.6)$$

donde $R(t_i)$ es el grupo de individuos en riesgo justo antes de t_i . La deducción de dicha verosimilitud se puede deducir de la función de verosimilitud total bajo censura no informativa de h_0 y β :

$$L(\beta, h_0(\cdot)) = \prod_{i=1}^n h(t_i)^{\delta_i} S(t_i) = \prod_{i=1}^n (h_0(t_i) \exp(\beta^T Z_i))^{\delta_i} \exp(-H_0(t_i) \exp(\beta^T Z_i)). \quad (5.7)$$

El logaritmo de la verosimilitud es:

$$l(\beta, h_0(\cdot)) = \sum_{i=1}^n [\delta_i (\ln(h_0(t_i)) + \beta^T Z_i) - H_0(t_i) \exp(\beta^T Z_i)], \quad (5.8)$$

Derivando el logaritmo de la verosimilitud con respecto a $h_0(t_i)$ se obtiene:

$$\frac{\partial}{\partial h_0(t_i)} l(\beta, h_0(\cdot)) = \frac{\delta_i}{h_0(t_i)} - \sum_{j:t_j \geq t_i} \exp(\beta^T Z_j). \quad (5.9)$$

Así, la verosimilitud es maximizada por:

$$\hat{h}_0(t_i) = \frac{\delta_i}{\sum_{j:t_j \geq t_i} \exp(\beta^T Z_j)}, \quad i = 1, 2, \dots, n \quad (5.10)$$

El estimador es conocido como estimador de Breslow. Nótese que $\hat{h}_0(t) = 0$ si $\delta = 0$ así como para cualquier $t \notin \{t_1, \dots, t_n\}$. Reemplazando (5.10) en (5.7) se obtiene:

$$\begin{aligned} L(\beta) &= \prod_{i=1}^n (\hat{h}_0(t_i) \exp(\beta^T Z_i))^{\delta_i} \exp \left(- \exp(\beta^T Z_i) \sum_{j:t_j \leq t_i} \hat{h}_0(t_j) \right) \\ &= \prod_{i=1}^n \left(\frac{\exp(\beta^T Z_i)}{\sum_{j:t_j \geq t_i} \exp(\beta^T Z_j)} \right)^{\delta_i} \exp \left(- \exp(\beta^T Z_i) \sum_{j:t_j \leq t_i} \frac{\delta_j}{\sum_{l:t_l \geq t_j} \exp(\beta^T Z_l)} \right) \\ &= \exp \left(- \sum_{i=1}^n \exp(\beta^T Z_i) \sum_{j:t_j \leq t_i} \frac{\delta_j}{\sum_{l:t_l \geq t_j} \exp(\beta^T Z_l)} \right) \prod_{i=1}^n \left(\frac{\exp(\beta^T Z_i)}{\sum_{j \in R(t_i)} \exp(\beta^T Z_j)} \right)^{\delta_i} \\ &= \exp \left(- \sum_{j=1}^n \sum_{i:t_j \leq t_i} \frac{\delta_j \exp(\beta^T Z_i)}{\sum_{l:t_l \geq t_j} \exp(\beta^T Z_l)} \right) \prod_{i=1}^n \left(\frac{\exp(\beta^T Z_i)}{\sum_{j \in R(t_i)} \exp(\beta^T Z_j)} \right)^{\delta_i} \\ &= \exp \left(- \sum_{j=1}^n \delta_j \frac{\sum_{i:t_i \geq t_j} \exp(\beta^T Z_i)}{\sum_{l:t_l \geq t_j} \exp(\beta^T Z_l)} \right) \prod_{i=1}^n \left(\frac{\exp(\beta^T Z_i)}{\sum_{j \in R(t_i)} \exp(\beta^T Z_j)} \right)^{\delta_i} \\ &= \prod_{i=1}^n \left(\frac{\exp(\beta^T Z_i)}{\sum_{j \in R(t_i)} \exp(\beta^T Z_j)} \right)^{\delta_i} \exp(-\delta_i) \\ &\propto \prod_{i=1}^n \left(\frac{\exp(\beta^T Z_i)}{\sum_{j \in R(t_i)} \exp(\beta^T Z_j)} \right)^{\delta_i} \end{aligned}$$

5.2. Inferencia sobre los parámetros β

El estimador de β obtenido por maximización de (5.6) es asintóticamente normal e insesgado. La matriz de varianzas y covarianzas se estima por $\hat{\Sigma} = I^{-1}(\hat{\beta})$, con $I(\beta)$ la matriz información observada, o negativo de las segundas derivadas del logaritmo de la verosimilitud:

$$I_{ij} = -\frac{\partial^2 \ln L}{\partial \beta_i \partial \beta_j}.$$

La prueba global $H_0 : \beta = \beta_0$ versus $H_1 : \beta \neq \beta_0$ puede hacerse mediante:

- Prueba de Wald: $X_W^2 = (\hat{\beta} - \beta_0)^T I(\hat{\beta})(\hat{\beta} - \beta_0)$, bajo H_0 se distribuye $\chi^2(p)$.
- Prueba de la razón de verosimilitud: $X_{RV}^2 = 2(\ln L(\hat{\beta}) - \ln L(\beta_0))$, bajo H_0 se distribuye $\chi^2(p)$
- Prueba del score: El vector score S de primeras derivadas de $\ln L$, bajo H_0 se distribuye $N(0, I(\hat{\beta}))$.

Si H_0 con $\beta_0 = 0$ es rechazada, se procede a realizar pruebas particulares para determinar cuál de los $\beta_j \neq 0$. La prueba particular $H_0 : \beta_j = 0$ versus $H_1 : \beta_j \neq 0$ puede hacerse mediante el estadístico $\hat{\beta}_j / \sqrt{\hat{Var}(\hat{\beta}_j)}$, que bajo H_0 se distribuye asintóticamente como una normal estándar.


Ejemplo 5.1: Con la información del ejemplo 2.1 tenemos el siguiente modelo estimado de Cox, donde la covariante Z toma los valores 1 para el grupo de terapia de mantenimiento y 0 para el grupo control.

$$\hat{h}(t) = \hat{h}_0(t) \exp(-0,916 * Z)$$

Dado que $\exp(-0,916) = 0,4$ podemos decir que el riesgo de quimioterapia del grupo de terapia de mantenimiento es 0,4 veces el riesgo del grupo control. No obstante, ha de tenerse precaución con esta interpretación, debido a que el error estándar estimado de $\hat{\beta}$ es 0,512 y por tanto la hipótesis de no diferencia en el tiempo a reinicio de quimioterapia por tipo de tratamiento, no puede ser rechazada ($p - valor = 0,074$).


En la Figura 5.1 se muestra la estimación del riesgo con dos criterios: a) el estimador de Nelson-Aalen y el modelo de Cox con el estimador de Breslow para el riesgo basal, ambas estimaciones en los tiempos observados del evento (color negro). Estas estimaciones puntuales se unen de forma incorrecta en la figura, pues donde no hay eventos el estimador vale cero. Esto se hace solo para efectos de facilitar la visualización de la tendencia. b) El estimador kernel con base en los dos criterios anteriores y un ancho de banda $h=50$ (color rojo). La Figura reseña que el modelo de Cox por ser no paramétrico en el riesgo basal, puede ser estimado únicamente en los tiempos a evento, o puede estimarse de forma continua con base en dicha estimación puntual, por medio de mecanismos como la estimación kernel, quien devela la verdadera tendencia del riesgo.

Figura 5.1: Estimador de Nelson-Aalen y Modelo de Cox para el Tiempo al Final del Estado de Remisión por Tipo de Terapia



Un criterio general de bondad de ajuste, mira cómo es un modelo teórico en relación con estimadores empíricos. En un mismo sentido, podemos comparar cómo quedan los modelos de regresión totalmente paramétricos frente al semi-paramétrico, tomando como referencia el estimador kernel. En la Figura 5.2 se compara el modelo paramétrico seleccionado, el log-logístico, frente al modelo de Cox. Dado que el criterio del estimador de Breslow es algo similar al estimador de Nelson-Aalen, el modelo de Cox continuo se muestra más cercano al estimador kernel. La desventaja que tiene el modelo de Cox, es que está limitado a rangos cercanos a los tiempos a evento. En la Figura se observa, cómo las estimaciones del riesgo no van mas allá de 48, mientras que el riesgo estimado por el modelo log-logístico, no presenta tal limitación.

Figura 5.2: Modelos de Cox para el Tiempo Hasta Final del Estado de Remisión,
por Tipo de Terapia



△

5.3. Comparación de Modelos Anidados

Dadas $p + q$ covariables $Z_1, Z_2, \dots, Z_p, Z_{p+1}, \dots, Z_{p+q}$ con ellas se pueden plantear los modelos:

$$M1 : h_1(t | Z_i) = h_0(t) e^{\beta_1 Z_{1i} + \dots + \beta_p Z_{pi}}$$

$$M2 : h_2(t | Z_i) = h_0(t) e^{\beta_1 Z_{1i} + \dots + \beta_p Z_{pi} + \beta_{p+1} Z_{p+1,i} + \dots + \beta_{p+q} Z_{p+q,i}}$$

La hipótesis y su estadístico de prueba para decidir si las q variables adicionales en el segundo modelo mejoran significativamente el poder explicativo del modelo uno con p variables, son:

$$H_0 : \beta_{p+1} = \beta_{p+2} = \dots = \beta_{p+q} = 0$$

$$H_1 : \text{algún } \beta_k \neq 0 \quad ; \quad k = p+1, p+2, \dots, p+q$$

$$D = -2 \ln \left(\frac{L_1(\hat{\beta})}{L_2(\hat{\beta})} \right) \quad \text{bajo } H_0 \sim \chi^2(q)$$

La decisión se puede complementar con el criterio: $AIC = -2 \ln L + kp$ (usualmente $k = 2$). El valor de AIC decrece a medida que se agregan variables al modelo hasta un unto donde sube, indicando que no se necesitan más variables.

5.4. Modelo Estratificado

Si se viola el supuesto de proporcionalidad para una covariable, se estratifica por ella y se plantean s modelos, uno por cada estrato, que se tendrán en cuenta en una verosimilitud total para estimar los parámetros β

$$h_j(t | Z) = h_{0,j}(t)e^{\beta^T Z} \quad , \quad j = 1, \dots, s$$

$$L(\beta) = L_1(\beta) * L_2(\beta) * \dots * L_s(\beta)$$

$$\ell = \ln L(\beta) = \ln L_1(\beta) + \ln L_2(\beta) + \dots + \ln L_s(\beta)$$

5.5. Análisis de Residuos

5.5.1. Residuos de Cox y Snell

Proporcionan un criterio de ajuste global del modelo. El residuo para la observación i -ésima ($i = 1, \dots, n$) se define como $r_{csi} = \hat{H}(t_i | Z_i) = \hat{H}_0(t_i) \exp(\hat{\beta}^T Z_i)$ con $\hat{H}$ la función de riesgo acumulado del modelo estimado y con $\hat{H}_0$ determinado por el estimador de breslow. El uso de los errores se basa en el principio de ley exponencial de parámetro uno para la función de riesgo acumulado. Veamos, si $V = H(t | Z)$:

$$\Pr(V \leq v) = \Pr(H(T | Z) \leq v) = \Pr(T \leq H^{-1}(v | Z)) = F(H^{-1}(v | Z))$$

Como $H(t | Z) = -\ln(1 - F(t | Z))$, entonces $F(t | Z) = 1 - \exp(-H(t | Z))$, luego:

$$F(v) = \Pr(V \leq v) = 1 - \exp(-H(H^{-1}(v | Z) | Z)) = 1 - \exp(-v),$$

función de distribución que corresponde a la de una exponencial de parámetro uno. Si el modelo es correcto los residuos deberían asemejarse a una muestra censurada de una exponencial de parámetro uno. Para verificarlo, se calcula

el estimador de Nelson-Aalen del riesgo acumulado de los r_{cs_i} , y se grafica dicho riesgo versus r_{cs_i} . El modelo es correcto si la nube de puntos se asemeja a una recta de pendiente uno que pasa por el origen. Therneau y Grambsch (2000) no los recomiendan pues estos son exponenciales independiente de la validez del modelo.

5.5.2. Residuos Martingala

Se definen como $r_{M_i} = \delta_i - r_{cs_i}$ con r_{cs_i} el residuo de Cox y Snell. Si se determinan con los valores poblacionales β y H_0 entonces deberían ser martingalas. Algunas características importantes son:

- Son no simétricos alrededor de cero y la suma de todos es cero.
- $E(r_{M_i}) = 0$
- Son una estimación de la diferencia: número de eventos observados y el esperado bajo el modelo de Cox. Estiman el exceso de eventos en los datos pero no predichos por el modelo.
- Detectan bien individuos que viven más de lo esperado por el modelo, aunque no tan bien los que viven menos.
- Pueden usarse para determinar la mejor transformación de las covariantes para ser incluidas en el modelo, siguiendo el siguiente método: Ajustar el modelo con $p - 1$ covariables dejando por fuera a $Z^{(j)}$ y graficar los residuos bajo éste modelo reducido versus $Z^{(j)}$. Si la nube es lineal, no se necesita ninguna transformación para $Z^{(j)}$, en caso contrario, la nube indicará el tipo de transformación.

5.5.3. Residuos Basados en la Deviance

Son una transformación de los residuos martingala. En su definición siguiente, el logaritmo infla el valor del residuo r_{M_i} para valores cercanos a uno y encoge los negativos grandes.

$$r_{D_i} = \text{Signo}(r_{M_i}) [-2(\delta_i \ln(\delta_i - r_{M_i}) + r_{M_i})]^{1/2}$$

Son simétricos alrededor de cero si el modelo es correcto. Se usan para detectar valores atípicos y de la validez del modelo para pronóstico. Para ello se plantea un gráfico de r_{D_i} versus los índices pronóstico o risk-score $\eta_i = \beta_1 Z_{1i} + \dots + \beta_p Z_{pi}$.

5.5.4. Residuos de Schoenfeld

Cada residuo establece la diferencia entre el valor observado de la covariante en el k -ésimo tiempo de fallo y el valor esperado de la covariante en ese momento. Para el k -ésimo evento y el i -ésimo individuo se define como:

$$r_{sc_{ik}}(t) = \delta_i J_i(t) [Z_{ik} - \bar{Z}_k(t_i)]$$

donde $J_i(t) = 1$ si el individuo i está a riesgo antes de t y:

$$\bar{Z}_k(t) = \frac{\sum_{i=1}^n J_i(t) Z_{ik} \exp(\beta^T Z_i(t))}{\sum_{i=1}^n J_i(t) \exp(\beta^T Z_i(t))}$$

Los residuos se distribuyen aleatoriamente para cada covariante que cumpla con el modelo de Cox, por eso se usan para decidir sobre la hipótesis de proporcionalidad. También son útiles para determinar la influencia que cada individuo tiene en la estimación de los coeficientes.

5.5.5. Comprobación Analítica de la Hipótesis de Proporcionalidad

Una alternativa para comprobar el supuesto de proporcionalidad de los riesgos, se basa en el uso de una variable dependiente del tiempo. Para determinar si una covariante Z_j cumple el supuesto en el modelo, se define una nueva $Z_k(t) = Z_j * g(t)$, con g una función conocida del tiempo, y se valora la significancia de Z_k en un modelo con Z_j y Z_k . Si Z_k no es explicativa de T en el modelo, entonces se verifica el supuesto para Z_j . La función g más usual es $g(t) = \ln t$, aunque también se pueden contemplar $g(t) = t^2$, $g(t) = \sqrt{t}$ o $g(t) = t \ln t$.

Bibliografía

- [1] Bower, N. L., Gerber, H. U., Hickman, J. C., Jones, D. A. and Nesbitt C. J. Actuarial Mathematics. *Society of Actuaries*; 2nd edition (1997).
- [2] Cox, D. R. Regression Models and Life Tables (with discussion). *Journal of the Royal Statistical Society, Series B* (1972); **34**, 187-220.
- [3] London, D. Survival models and their estimation. *ACTEX Publications* (1997); 3rd edition (1997).
- [4] Hougaard, P. Analysis of Multivariate Survival Data. *Springer-Verlag* New York (2000).
- [5] Kalbfleisch, J. D. and Prentice, R. L. The Statistical Analysis of Failure Time Data. *John Wiley, New York*, 2nd edition (2002).
- [6] Klein, J. P. and Moeschberger, M. L. Survival Analysis: Techniques for Censored and Truncated Data. *Springer*; 3rd edition (2005).
- [7] Lawless, J. F. Statistical Models and Methods for Lifetime Data, 2nd edition. *Wiley* Hoboken (2003).
- [8] Prentice, R. Covariate Measurement Errors and Parameter Estimates in a Failure Time Regression Model. *Biometrika* (1982); **69** 331-342.