

Estimación actuarial de la tasa de mortalidad q_x a partir de datos reales con doble decremento y suavizamiento mediante regresión de polinomios locales

Jorge Andrés Sánchez Duarte

Departamento de Estadística, Universidad Nacional de Colombia

Estadística No Paramétrica

21 de junio de 2026

Resumen

Resumen. En este trabajo se estima la tasa anual de mortalidad q_x de una población real observada entre 2006 y 2015, caracterizada por censura tipo I generalizada y por la presencia de un decremento adicional al de muerte (retiro del estudio). A partir de la exposición actuarial de cada individuo se calcula la tasa central de mortalidad m_x y, bajo el supuesto de distribución uniforme de muertes, se obtienen las tasas asociadas de decremento simple, las cuales se combinan mediante la relación clásica de tablas de decremento múltiple para aislar la tasa de mortalidad dependiente $q_x^{(1)}$. Dado que la estimación cruda presenta alta variabilidad en edades avanzadas por la escasa exposición disponible, se aplica como técnica de suavizamiento no paramétrico una regresión ponderada por núcleo gaussiano con polinomios locales de grado tres, comparando dos anchos de banda. Los resultados muestran el patrón creciente característico de la mortalidad humana y evidencian el efecto del ancho de banda sobre el balance sesgo-varianza de la curva suavizada.

Palabras clave: tablas de mortalidad, decremento múltiple, estimación actuarial, regresión de polinomios locales, suavizamiento kernel.

Abstract. This paper estimates the annual mortality rate q_x of a real population observed between 2006 and 2015, characterized by generalized Type I censoring and by the presence of an additional decrement to death (withdrawal from the study). Using the actuarial exposure of each individual, the central mortality rate m_x is computed and, under the uniform distribution of deaths assumption, the associated single-decrement rates are obtained and combined through the classical multiple decrement table relationship to isolate the dependent mortality rate $q_x^{(1)}$. Since the crude estimates show high variability at advanced ages due to limited exposure, a nonparametric smoothing technique is applied: a Gaussian kernel-weighted local polynomial regression of degree three, comparing two bandwidths. The results display the typical increasing pattern of human mortality and illustrate how the bandwidth governs the bias–variance trade-off of the smoothed curve.

Key words: mortality tables, multiple decrement, actuarial estimation, local polynomial regression, kernel smoothing.

1. Introducción

La construcción de tablas de mortalidad constituye uno de los problemas centrales en estadística actuarial, pues de ella se derivan productos tan diversos como seguros de vida, rentas vitalicias, reservas de pensiones y estudios de longevidad. A diferencia de otros contextos de análisis de supervivencia, la estimación de la tasa de mortalidad q_x en una población real rara vez se hace sobre datos completos: los individuos ingresan al estudio en fechas distintas, algunos mueren, otros se retiran por razones ajenas a la muerte y el estudio finalmente se cierra en una fecha administrativa común, dejando a los sobrevivientes con información censurada. Esta estructura de observación, descrita formalmente como censura tipo I generalizada, exige metodologías de estimación que incorporen de manera explícita la exposición real de cada persona al riesgo de morir, en lugar de asumir un seguimiento completo y homogéneo.

Un segundo elemento que complejiza la estimación es la presencia simultánea de más de una causa de salida del estudio. En el conjunto de datos analizado en este trabajo, además de la muerte, existe un segundo decremento correspondiente al retiro voluntario de los individuos antes del cierre del estudio. Cuando coexisten dos o más decrementos que compiten por explicar la salida de un individuo, la tasa de mortalidad observada no equivale directamente a la tasa de mortalidad “pura”, sino que debe depurarse mediante la teoría de tablas de decremento múltiple, que permite separar, bajo un supuesto de independencia entre causas, la contribución específica de cada decremento a la probabilidad total de salida.

Una tercera dificultad, de naturaleza estrictamente estadística, surge porque la exposición disponible decrece fuertemente en las edades extremas de la tabla. En el caso de este estudio, mientras que en las edades centrales la exposición supera los miles de años-persona, en las edades cercanas a los 95 o 99 años apenas se dispone de unos pocos años-persona, lo que produce estimaciones extremadamente ruidosas y, en ocasiones, poco creíbles desde el punto de vista demográfico. Para atenuar este problema sin imponer una forma paramétrica específica a la curva de mortalidad (como la ley de Gompertz o de Makeham), en este trabajo se recurre a una técnica propia del curso de Estadística No Paramétrica: la regresión por polinomios locales ponderada mediante un núcleo gaussiano. Esta técnica permite obtener, en cada edad, una estimación suavizada de q_x que pondera más fuertemente las observaciones cercanas, controlando el grado de suavizamiento a través del ancho de banda.

El objetivo de este trabajo es, entonces, doble. Por un lado, se busca ilustrar la aplicación completa de la metodología actuarial de estimación de tasas de mortalidad a partir de datos reales con doble decremento y censura generalizada. Por otro lado, se busca mostrar cómo una técnica de suavizamiento no paramétrico (regresión local ponderada por núcleo) contribuye a obtener una curva de mortalidad más estable e interpretable, en particular en aquellas edades donde la exposición es escasa.

El documento se organiza de la siguiente manera. La Sección 2 presenta el marco teórico, limitado estrictamente a los conceptos usados en el análisis: la noción de censura generalizada, la estimación actuarial de la tasa central de mortalidad y su transformación bajo el supuesto de distribución uniforme de muertes, la relación de tablas de decremento múltiple, y finalmente la formulación de la regresión por polinomios locales ponderada por núcleo. La Sección 3 desarrolla el análisis sobre los datos reales, presentando los resultados numéricos y gráficos correspondientes. Finalmente, la Sección 4 resume las principales conclusiones del trabajo.

2. Marco teórico

2.1. Censura y exposición en estudios de mortalidad

Sea T el tiempo de vida de un individuo, con función de supervivencia $S(t) = \Pr(T > t)$ y función de riesgo $h(t)$, relacionadas mediante

$$h(t) = -\frac{\frac{d}{dt}S(t)}{S(t)}, \quad S(t) = \exp\left(-\int_0^t h(u) du\right). \quad (1)$$

En estudios de mortalidad poblacional es habitual que los individuos no ingresen simultáneamente al estudio, sino en instantes E_i distintos, y que la observación finalice para todos en una misma fecha de cierre administrativo C_R . Esta estructura corresponde a la censura tipo I generalizada, en la cual la muestra observada es el conjunto de parejas (Y_i, δ_i) , con $Y_i = \min(T_i, C_i)$, $C_i = C_R - E_i$, y

$$\delta_i = \begin{cases} 1 & \text{si } T_i \leq C_i \quad (\text{el individuo } i \text{ no está censurado}), \\ 0 & \text{si } T_i > C_i \quad (\text{el individuo } i \text{ está censurado}). \end{cases} \quad (2)$$

Para estimar la tasa de mortalidad en el intervalo de edad $(x, x+1]$ es necesario cuantificar cuánto tiempo estuvo cada individuo expuesto al riesgo de morir dentro de dicho intervalo, lo que se conoce como exposición actuarial. Si y_i y z_i denotan, respectivamente, la edad de entrada y la edad de salida programada del individuo i , y r_i , s_i las fracciones del intervalo $(x, x+1]$ efectivamente cubiertas por su entrada y su salida, la exposición programada del individuo en dicho intervalo es $s_i - r_i$. Sumando esta cantidad sobre todos los individuos vivos a edad x se obtiene la exposición total n_x , mientras que D_x denota el número observado de muertes en el intervalo.

2.2. Estimación de la tasa de mortalidad q_x

La tasa central de mortalidad en el intervalo $(x, x+1]$ se estima como el cociente entre el número de muertes observadas y la exposición total acumulada por el grupo en dicho intervalo:

$$\hat{m}_x = \frac{D_x}{n_x}. \quad (3)$$

A diferencia de la probabilidad de muerte q_x , que está acotada entre 0 y 1, la tasa central m_x puede en principio superar la unidad cuando la exposición es muy reducida. Para convertir $\hat{m}_x$ en una probabilidad de muerte propiamente dicha se recurre al supuesto de distribución uniforme de muertes dentro del año de edad (UDD, por sus siglas en inglés), bajo el cual se obtiene la aproximación clásica:

$$\hat{q}_x \approx \frac{\hat{m}_x}{1 + 0,5 \hat{m}_x}. \quad (4)$$

Esta es la expresión utilizada en este trabajo para convertir las tasas centrales estimadas, tanto para el decremento de muerte como para el decremento de retiro, en probabilidades anuales de salida.

2.3. Tablas de decremento múltiple

Cuando un individuo puede abandonar el estudio por más de una causa, en este caso, muerte (decremento 1) o retiro (decremento 2), la probabilidad de supervivencia conjunta dentro del año de edad puede expresarse, bajo el supuesto de independencia entre los decrementos, como el producto de las probabilidades asociadas a cada decremento considerado de manera individual:

$$p_x^{(\tau)} = p_x^{(1)} \cdot p_x^{(2)}, \quad q_x^{(\tau)} = 1 - p_x^{(\tau)}. \quad (5)$$

Esta relación es consistente con la propiedad general de la función de riesgo expuesta en (1): bajo independencia, el riesgo total es la suma de los riesgos específicos de cada causa, de modo que la función de riesgo acumulado total se reparte proporcionalmente entre las causas. Dado que $H_x^{(j)} = -\ln(p_x^{(j)})$, la fracción del riesgo total atribuible al decremento j permite obtener la tasa de mortalidad *dependiente*, es decir, la tasa de decremento j tal como se observa dentro del ambiente de decrementos múltiples:

$$q_x^{(j)} = \frac{\ln(p_x^{(j)})}{\ln(p_x^{(\tau)})} q_x^{(\tau)}, \quad j = 1, 2. \quad (6)$$

La ecuación (6) es la que permite, en la Sección 3, aislar la tasa de mortalidad “pura” $q_x^{(1)}$ a partir de las tasas asociadas obtenidas con (4) para cada decremento por separado.

2.4. Suavizamiento no paramétrico mediante regresión de polinomios locales

Las estimaciones $\hat{q}_x^{(1)}$ obtenidas a partir de (6) son, edad por edad, estimaciones puntuales independientes que no incorporan ninguna restricción de suavidad entre edades consecutivas. Cuando la exposición es pequeña, como ocurre en las edades avanzadas, dichas estimaciones presentan fluctuaciones poco realistas. Para suavizar la curva $\hat{q}_x^{(1)}$ en función de la edad x sin imponer una forma funcional paramétrica, se emplea una regresión local ponderada por núcleo (LOWESS), en la cual, para cada punto de evaluación x_0 , se ajusta un polinomio local de grado p por mínimos cuadrados ponderados:

$$\min_{\beta_0, \dots, \beta_p} \sum_{i=1}^n \left(y_i - \beta_0 - \beta_1(x_i - x_0) - \dots - \beta_p(x_i - x_0)^p \right)^2 w_i, \quad (7)$$

con pesos definidos en función de un núcleo K y un ancho de banda h :

$$w_i = \frac{K\left(\frac{x_i - x_0}{h}\right)}{\sum_{k=1}^n K\left(\frac{x_k - x_0}{h}\right)}. \quad (8)$$

El valor suavizado en x_0 corresponde al intercepto estimado, $\hat{y}(x_0) = \hat{\beta}_0(x_0)$, y el procedimiento se repite para una malla de valores de x_0 a lo largo del rango de edades observado. El ancho de banda h controla el balance entre sesgo y varianza: valores pequeños de h producen curvas muy ajustadas a los datos crudos (mayor varianza, menor sesgo), mientras que valores grandes de h producen curvas más suaves y estables, aunque potencialmente sesgadas si ocultan

patrones reales de la mortalidad.

Para la implementación concreta de este trabajo se fijó el grado del polinomio local en $p = 3$ y se utilizó un núcleo gaussiano,

$$K(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}u^2\right), \quad (9)$$

de modo que en cada x_0 se resuelve $\hat{y}(x_0) = \hat{\beta}_0(x_0)$ en el modelo $y_i = \beta_0 + \beta_1(x_i - x_0) + \beta_2(x_i - x_0)^2 + \beta_3(x_i - x_0)^3 + \varepsilon_i$. En este trabajo se comparan dos anchos de banda, $h = 2$ y $h = 10$, para ilustrar el efecto de este parámetro sobre la curva de mortalidad estimada.

3. Análisis de datos reales

3.1. Descripción de los datos

Los datos utilizados corresponden a un panel de $n = 20\,509$ individuos pertenecientes a un fondo previsional, observados entre el 1 de enero de 2006 y el 31 de diciembre de 2015. Las fechas de nacimiento de los individuos se ubican entre 1912 y 1996, mientras que las fechas de ingreso al estudio se distribuyen de manera escalonada entre el 1 de enero de 2006 y octubre de 2015, configurando exactamente el esquema de censura tipo I generalizada descrito en la ecuación (2): cada individuo tiene su propio origen temporal E_i , pero todos comparten la misma fecha de cierre administrativo $C_R = 31$ de diciembre de 2015.

Durante el periodo de estudio se observaron 962 muertes (4,7 % del total), 7 499 retiros voluntarios previos al cierre del estudio (36,6 %) y 12 048 individuos que permanecieron activos hasta la fecha de cierre, constituyendo censura administrativa pura (58,7 %). Para cada individuo se calculó la edad de ingreso y_i , la edad de salida programada z_i y, cuando aplica, la edad exacta de muerte o de retiro, usando años de 365.25 días. A partir de esta información se construyó la exposición actuarial n_x y el número de eventos D_x para cada uno de los dos decrementos, en cada edad entera entre 18 y 99 años, siguiendo el procedimiento de exposición programada descrito en la Sección 2.1.

3.2. Estimación cruda de q_x

Aplicando la ecuación (3) se obtuvo, para cada edad x , la tasa central de mortalidad $\hat{m}_x^{(1)}$ (decremento muerte) y $\hat{m}_x^{(2)}$ (decremento retiro); estas se transformaron en probabilidades asociadas $\hat{q}_x^{(1)\text{com}}$ y $\hat{q}_x^{(2)\text{com}}$ mediante la ecuación (4), y finalmente se combinaron mediante las ecuaciones (5) y (6) para obtener la tasa de mortalidad dependiente $\hat{q}_x^{(1)}$. La Tabla 1 resume los resultados para un subconjunto representativo de edades, evidenciando dos hechos relevantes: primero, el patrón esperado de mortalidad creciente con la edad; segundo, la fuerte caída en la exposición disponible a partir de los 70 años, que explica la alta variabilidad de las estimaciones crudas en ese rango.

La Figura 1 presenta la totalidad de las estimaciones crudas $\hat{q}_x^{(1)}$ obtenidas para el rango completo de edades (18 a 99 años). Se observa el comportamiento característico de la mortalidad humana adulta: una región relativamente plana entre los 25 y 60 años, seguida de un crecimiento marcado a partir de los 65 años. No obstante, también es evidente la irregularidad de las estimaciones después de los 85 años, generada por la escasa exposición remanente en esas edades (Tabla 1).

Tabla 1: Exposición, número de muertes y tasa de mortalidad estimada para edades seleccionadas.

Edad (x)	D_x (muertes)	Exposición n_x (años-persona)	$\hat{m}_x$	$\hat{q}_x^{(1)}$
18	1	33.7	0.0297	0.0292
20	0	211.2	0.0000	0.0000
30	13	2640.6	0.0049	0.0048
40	19	3431.9	0.0055	0.0054
50	17	2650.1	0.0064	0.0061
60	15	1118.8	0.0134	0.0118
70	2	26.7	0.0748	0.0721
80	3	28.1	0.1066	0.1012
90	1	4.4	0.2272	0.2040
99	2	1.3	1.5171	0.8627




Figura 1: Estimación cruda de la tasa de mortalidad $\hat{q}_x^{(1)}$ por edad, obtenida mediante las ecuaciones (3)–(6).

3.3. Suavizamiento mediante regresión de polinomios locales

Con el fin de obtener una curva de mortalidad más estable, se aplicó el procedimiento descrito en la Sección 2.4 a la serie $\hat{q}_x^{(1)}$ de la Figura 1, comparando dos anchos de banda: $h = 2$ y $h = 10$. La Figura 2 muestra, en paneles separados, el resultado de ajustar la regresión local ponderada por núcleo gaussiano (ecuaciones (7) y (8)) con cada uno de los dos anchos de banda.

Con $h = 2$ la curva suavizada sigue muy de cerca las fluctuaciones de los datos crudos, reproduciendo incluso las oscilaciones poco verosímiles observadas entre los 80 y 95 años; este resultado evidencia el riesgo de sobreajuste (varianza alta) cuando el ancho de banda es demasiado pequeño en presencia de exposición escasa. Con $h = 10$, en cambio, la curva resultante es monótona creciente y de apariencia mucho más cercana a la forma típica de una ley de mortalidad tipo Gompertz, a costa de promediar información de un rango más amplio de edades (lo que introduce algo de sesgo, particularmente cerca de los extremos del rango observado). La Figura 3 superpone ambas curvas suavizadas sobre los datos crudos para facilitar la comparación directa.




Figura 2: Suavizamiento de $\hat{q}_x^{(1)}$ mediante regresión de polinomios locales ponderada por núcleo gaussiano, con ancho de banda $h = 2$ (izquierda) y $h = 10$ (derecha).




Figura 3: Comparación de los suavizadores con $h = 2$ y $h = 10$ sobre la estimación cruda de q_x .

Este ejercicio ilustra de manera directa el compromiso sesgo-varianza propio de los métodos de suavizamiento no paramétrico: para esta aplicación particular, dado que la exposición en edades avanzadas es muy reducida y poco confiable punto a punto, un ancho de banda mayor ($h = 10$) resulta preferible, pues produce una tendencia de mortalidad demográficamente más razonable sin depender excesivamente de observaciones aisladas con muy poca exposición.

4. Conclusión

En este trabajo se estimó la tasa de mortalidad q_x de una población real de 20 509 individuos observados entre 2006 y 2015, en presencia de censura tipo I generalizada y de un segundo decremento (retiro) que compite con la muerte como causa de salida del estudio. La metodología actuarial empleada (cálculo de la exposición real por edad, estimación de la tasa central de mortalidad, transformación bajo el supuesto de distribución uniforme de muertes y separación de decrementos mediante la relación clásica de tablas de decremento múltiple), permitió aislar adecuadamente la tasa de mortalidad asociada únicamente a la causa de muerte, depurándola de la influencia del decremento de retiro.

Las estimaciones crudas mostraron el patrón esperado de mortalidad creciente con la edad, pero también una variabilidad considerable en las edades más avanzadas, directamente asociada a la fuerte reducción de la exposición disponible en dicho rango. Como técnica complementaria, se utilizó una regresión de polinomios locales ponderada por núcleo gaussiano para suavizar la curva q_x estimada. La comparación entre los anchos de banda $h = 2$ y $h = 10$ permitió ilustrar de manera concreta el compromiso sesgo-varianza inherente a cualquier procedimiento de suavizamiento: anchos de banda pequeños preservan el ruido de las estimaciones crudas, mientras que anchos de banda mayores producen curvas más estables y demográficamente más plausibles, a costa de promediar información entre edades distantes.

Como trabajo futuro resultaría natural seleccionar el ancho de banda mediante un criterio formal, como la validación cruzada generalizada, en lugar de la comparación visual realizada aquí, así como contrastar la curva suavizada con el ajuste de un modelo paramétrico de mortalidad (por ejemplo, Gompertz o Makeham) para evaluar si la flexibilidad adicional del enfoque no paramétrico se traduce en una mejora sustancial del ajuste en las edades centrales, donde la exposición es abundante y confiable.

Bibliografía

- [1] Bowers, N. L., Gerber, H. U., Hickman, J. C., Jones, D. A., & Nesbitt, C. J. (1997). *Actuarial Mathematics* (2nd ed.). Society of Actuaries.
- [2] Giraldo Henao, R. (2026). *Estadística No Paramétrica: Alternativas a Pruebas Clásicas, Estimación de la Densidad y Análisis de Regresión*. Departamento de Estadística, Universidad Nacional de Colombia, Sede Bogotá. Apuntes de Clase (Documento en Revisión).